

树张量网络上的 max-plus 随机层： 精确 CDF 收缩、树宽复杂度与信息预算

待填写作者姓名*

复旦大学，待填写院系名称，上海 200433，中国
Fudan University, [Department], Shanghai 200433, China

草稿日期：2026 年 7 月 30 日

摘要

本文研究树张量网络态 (TTNS) 表示的高维密度经过一层 max-plus 随机映射 $Y_a = \max_{k \in P_a} (X_k + E_{ka}) + D_a$ 之后的联合分布，给出四类结果。第一，若上游密度由树 T 上的 TTNS 表示，则下游联合 CDF 等于一组一维局部投影的 TTNS 收缩；当 node delay 各分量独立时，外层期望恰是逐轴卷积算子的张量积，因而在已持有 G^K 中间数组的前提下，额外的逐轴卷积代价对输出维数 K 为线性而非指数。第二，局部投影中的截断、求积与 edge CDF 近似误差按 TTNS sensitivity 加权进入联合 CDF 误差，而外层 node-delay 求积、卷积网格插值与边界钳制误差则通过非扩张平均算子的 telescoping 直接相加；结合 Kantorovich–Rubinstein 界得到含外层求积项的闭合单层误差预算与显式收敛条件，且当 telescoping 的坐标顺序取为树的后序遍历时，预算中出现的全部 d 个 hybrid sensitivity 可由两次上行加一次下行 sweep 同时算出，从而该预算可作为自适应精化判据。第三，我们把树结构与父集合族合成一张联合结构图，证明该图的树宽给出联合 CDF 计算代价的条件性上界（给定一个树分解即可达到），并给出与完整输出规模一致的下界；平方 TTNS 以平方后的域大小为底时改变底数而不改变指数（以原始 rank 与物理维计则幂次加倍）。第四，把每个下游节点视为一个局部 max-plus 通道，利用 max 映射的 ℓ_∞ 非扩张性与 node-delay 分布的平移重叠显式界定局部 Dobrushin 系数；再沿 total correlation 的链式分解逐项施加固定输入强数据处理不等式，得到整层收缩因子为各局部系数的最大值，不含随层宽显式增长的乘积信道惩罚因子——该论证不依赖（且我们给出反例说明一般不成立的）乘积信道 input-independent KL 系数张量化。据此得到 pair 互信息、整层 total correlation 与多层累计的信息预算：多层累计中初始依赖按层数几何衰减，而每层新增的 fan-out 注入使总上界一般停在一个显式的非零渐近上界（上界残余项）上；需要强调这是所选上界的极限，并不蕴含实际 total correlation 有非零下界。最后显式界定其有限状态版本的非平凡量化窗口。所有结果均不要求训练优化器达到全局最优。

目录

1 理论定位	2
2 基本设定	3
2.1 TTNS 密度和收缩	3
2.2 max-plus 随机层	4
3 TTNS 上 max-plus 层的精确 joint CDF 收缩	4
3.1 node-delay 外层期望的张量积结构	5

*通讯作者电子邮箱：待填写。

4 局部投影误差通过 TTNS 的传播	6
4.1 sensitivity 向量	6
4.2 局部 CDF 投影的数值误差	9
4.3 外层求积误差与完整单层预算	11
4.4 实现所使用的算子：网格插值与边界钳制	12
5 联合结构图的树宽与可计算代价	19
5.1 离散化后的张量网络形式	19
5.2 联合结构图	20
5.3 主复杂度定理	20
5.4 特例：与仓库现有实现的对应	22
5.5 具体拓扑上的树宽	23
5.6 平方 TTNS 的对应	25
6 max-plus 层的信息传递预算	26
6.1 局部 max-plus channel	26
6.2 max 的 Lipschitz 性给出显式 channel 系数	27
6.3 pair mutual information: 共享父与独占父的分解	28
6.4 整层 total correlation 与 fan-out 信息注入	29
6.5 量化窗口：有限状态界何时非平凡	34
6.6 与 tree projection 的连接：经典恒等式和新预算的组合	37
7 相关工作	39
7.1 max-plus 系统与随机最长路	39
7.2 张量网络密度表示	40
7.3 信息收缩与强数据处理不等式	40
7.4 本文的定位	41
8 适用范围与局限	42
8.1 本文结论的适用范围	42
8.2 不由本文结论推出的内容	43
8.3 必须保留的技术边界	43
8.4 可以扩张的方向	44
8.5 尚待完成的工作	44
8.6 主线的两种组织方式	45
9 符号表	45

1 理论定位

本文把一层传播写成

$$Q_{\ell-1} \xrightarrow{\mathcal{K}_\ell} \tilde{Q}_\ell \xrightarrow{\text{tree projection}} R_\ell^{T_Y} \xrightarrow{\text{optimization}} Q_\ell.$$

本文只处理前三个数学对象中的可证明部分：

$$Q_{\ell-1} \rightarrow \tilde{Q}_\ell, \quad \tilde{Q}_\ell \text{ 的数值 CDF 计算}, \quad \tilde{Q}_\ell \rightarrow R_\ell^{T_Y}.$$

最后一步 $R_\ell^{T_Y} \rightarrow Q_\ell$ 是优化问题。除非另外证明优化器达到全局最优或给出可验证 certificate, 否则它不应被写成本文三条主定理的一部分。这里 T_Y 表示下游输出坐标 $(Y_1, \dots, Y_K)$ 上的 tree projection 树 (见 §6.6), 与承载上游 TTNS 的树 T 一般不是同一个对象。

信息论部分进一步把精确传播

$$Q_{\ell-1} \xrightarrow{\mathcal{K}_\ell} \tilde{Q}_\ell$$

拆成一组条件独立的局部 max-plus channels。它分析的是精确传播目标 $\tilde{Q}_\ell$ 的依赖如何由上一层传递，不分析优化所得 Q_ℓ 。

本文中的 K 表示单层下游输出维数。它可以是任意有限正整数；实验中保存完整 joint table 时选择 $K = 3$ 只是计算限制，不是定理限制。

2 基本设定

2.1 TTNS 密度和收缩

令上游随机向量为

$$X = (X_1, \dots, X_d) \in \mathbb{R}^d.$$

对每个坐标 $k \in \{1, \dots, d\}$ ，给定 m_k 个 Borel 可测且绝对可积的一维基函数

$$b_{k,1}, \dots, b_{k,m_k} : \mathbb{R} \rightarrow \mathbb{R}.$$

设 $T = (V, E)$ 是一棵树， $V = \{1, \dots, d\}$ 。对每条边 $e \in E$ 给定一个 *bond dimension* $r_e \in \mathbb{Z}_{\geq 1}$ ，相应的 *bond index* 取值于

$$\alpha_e \in [r_e] := \{1, \dots, r_e\}. \quad (1)$$

记 $\delta_T(k) = \{e \in E : k \in e\}$ 为节点 k 的关联边集， $\deg_T(k) = |\delta_T(k)|$ 。TTNS 由每个节点上的一个 *core*

$$G^{(k)} \in \mathbb{R}^{m_k \times \prod_{e \in \delta_T(k)} r_e}, \quad G_{i_k, (\alpha_e)_{e \in \delta_T(k)}}^{(k)}, \quad k = 1, \dots, d, \quad (2)$$

给出；它诱导的有限系数张量 $A \in \mathbb{R}^{m_1 \times \dots \times m_d}$ 为全部 *bond index* 上的收缩

$$A_{i_1, \dots, i_d} = \sum_{(\alpha_e)_{e \in E} \in \prod_{e \in E} [r_e]} \prod_{k=1}^d G_{i_k, (\alpha_e)_{e \in \delta_T(k)}}^{(k)}. \quad (3)$$

本文另记最大 *bond dimension* 与最大物理维为

$$r := \begin{cases} \max_{e \in E} r_e, & E \neq \emptyset, \\ 1, & E = \emptyset, \end{cases} \quad m := \max_{1 \leq k \leq d} m_k. \quad (4)$$

$E = \emptyset$ 只在 $d = 1$ 的退化树上发生（此时 $A = G^{(1)} \in \mathbb{R}^{m_1}$ ，(2) 中的 *bond* 求和是空积）；约定 $r = 1$ 与“空 *bond product* 取 1”的 TTNS 约定一致，使命题 2、3 与定理 5 的代价表达式在 $d = 1$ 时仍然有定义并给出正确的 $O(m_1)$ 量级。下文的多数结论只需要 A 诱导的多线性收缩

$$C_T(z_1, \dots, z_d) = \sum_{i_1=1}^{m_1} \dots \sum_{i_d=1}^{m_d} A_{i_1, \dots, i_d} \prod_{k=1}^d z_{k, i_k},$$

其中 $z_k \in \mathbb{R}^{m_k}$ ；只有涉及收缩代价的结论（命题 2、3，定理 5 及其推论）才需要用到 (1)–(4) 的显式 *core* 结构。

若上游密度满足

$$p_X(x_1, \dots, x_d) = \sum_{i_1=1}^{m_1} \dots \sum_{i_d=1}^{m_d} A_{i_1, \dots, i_d} \prod_{k=1}^d b_{k, i_k}(x_k),$$

且 $p_X \geq 0$ 几乎处处、 $\int_{\mathbb{R}^d} p_X(x) dx = 1$ ，则 p_X 是合法概率密度。基函数本身可以带符号；概率性由最终密度的非负性和归一化保证。

引理 1 (可分离积分). 令 $w_k: \mathbb{R} \rightarrow \mathbb{R}$ 为 Borel 可测函数。若每个 $b_{k,i}w_k$ 绝对可积, 则

$$z_{k,i} = \int_{\mathbb{R}} b_{k,i}(x)w_k(x) dx$$

满足

$$\int_{\mathbb{R}^d} p_X(x) \prod_{k=1}^d w_k(x_k) dx = \mathcal{C}_T(z_1, \dots, z_d).$$

证明. 把 p_X 的有限展开代入左侧。由于求和有限, 求和与积分可以交换。由于 $b_{k,i}w_k$ 绝对可积, Fubini 定理把 d 维积分分解为一维积分乘积。所得表达式正是 $\mathcal{C}_T(z_1, \dots, z_d)$ 。□

2.2 max-plus 随机层

令下游维数为 $K \in \mathbb{N}$ 。对每个下游坐标 $a \in \{1, \dots, K\}$, 给定非空父节点集合

$$P_a \subseteq \{1, \dots, d\}.$$

定义单层 max-plus 随机映射

$$Y_a = \max_{k \in P_a} (X_k + E_{ka}) + D_a, \quad a = 1, \dots, K. \quad (5)$$

这里 E_{ka} 是 edge delay, $D = (D_1, \dots, D_K)$ 是 node-delay 向量。假设全部 edge delays 相互独立, 并且 X 、完整 edge-delay 族和 D 三者相互独立。记 E_{ka} 的 CDF 为 F_{ka} 。不要求 $D_1, \dots, D_K$ 相互独立, 除非希望把外层期望进一步写成乘积求积。

为区分维数与取值, 本文一律用 d 表示上游维数, 用

$$t = (t_1, \dots, t_K) \in \mathbb{R}^K$$

表示 node-delay 向量 D 的一个实现值。类似地, K 只表示下游维数, 局部 Markov kernel 记为 K_a , 其乘积信道记为 $K^\otimes$, 层映射记为 $\mathcal{K}_\ell$ 。

对每个上游坐标 k , 记它影响的下游坐标集合为

$$H_k = \{a \in \{1, \dots, K\} : k \in P_a\}.$$

3 TTNS 上 max-plus 层的精确 joint CDF 收缩

定理 1 (精确 CDF 收缩). 在基本设定下, 对固定 $y \in \mathbb{R}^K$ 和 node-delay 实现值 $t \in \mathbb{R}^K$, 定义局部投影向量 $M_k(y, t) \in \mathbb{R}^{m_k}$, 其第 i 个分量为

$$M_{k,i}(y, t) = \int_{\mathbb{R}} b_{k,i}(x) \prod_{a \in H_k} F_{ka}(y_a - t_a - x) dx.$$

若 $H_k = \emptyset$, 则空乘积定义为 1。于是下游随机向量 $Y = (Y_1, \dots, Y_K)$ 的 joint CDF 满足

$$F_Y(y) = \mathbb{P}(Y_1 \leq y_1, \dots, Y_K \leq y_K) = \mathbb{E}_D [\mathcal{C}_T(M_1(y, D), \dots, M_d(y, D))].$$

证明. 固定 $X = x$ 和 $D = t$ 。事件 $Y_a \leq y_a$ 等价于 $E_{ka} \leq y_a - t_a - x_k$ 对所有 $k \in P_a$ 同时成立。因此, 由 edge delays 相互独立,

$$\mathbb{P}(Y_1 \leq y_1, \dots, Y_K \leq y_K \mid X = x, D = t) = \prod_{a=1}^K \prod_{k \in P_a} F_{ka}(y_a - t_a - x_k).$$

按照上游坐标 k 重排乘积, 得到

$$\prod_{k=1}^d \prod_{a \in H_k} F_{ka}(y_a - t_a - x_k).$$

对 X 积分, 并对每个 k 取

$$w_k(x; y, t) = \prod_{a \in H_k} F_{ka}(y_a - t_a - x),$$

即可由可分离积分引理得到条件于 $D = t$ 的 TTNS 收缩表达式。最后对 D 取期望; 外层期望的良好定义性由下面的注保证。□

注 1 (外层期望的可测性与良定义性). 对每个 (k, i) , 被积函数 $(x, t) \mapsto b_{k,i}(x) \prod_{a \in H_k} F_{ka}(y_a - t_a - x)$ 关于 x 可测, 关于 t 逐点连续于每个 F_{ka} 的连续点集; 由于 F_{ka} 单调, 其不连续点至多可数, 故该函数在 $\mathbb{R} \times \mathbb{R}^K$ 上联合可测。又因为所有 CDF 取值于 $[0, 1]$, 被积函数被 $|b_{k,i}| \in L^1(\mathbb{R})$ 控制, 由控制收敛定理, $t \mapsto M_{k,i}(y, t)$ 有界可测, 且 $|M_{k,i}(y, t)| \leq \int_{\mathbb{R}} |b_{k,i}|$ 。由于 $\mathcal{C}_T$ 是有限多线性形式, $t \mapsto \mathcal{C}_T(M_1(y, t), \dots, M_d(y, t))$ 也有界可测, 从而 $\mathbb{E}_D[\cdot]$ 对 D 的任意联合分布都有定义且有限。

注 2 (共享父节点). 若某个上游坐标 k 同时属于 P_1 和 P_2 , 则局部投影中出现

$$\int b_{k,i}(x) F_{k1}(y_1 - t_1 - x) F_{k2}(y_2 - t_2 - x) dx.$$

因此共享父节点不会破坏一维局部化, 但也不能被错误地拆成两个独立上游变量。同一个积分变量 x 正是共享依赖被保留下来的位置。

3.1 node-delay 外层期望的张量积结构

定理 1 把外层写成 $\mathbb{E}_D[\cdot]$, 对 D 的任意联合分布都成立。但若写成这个形式, 外层期望看起来像一个不可约的 K 维积分: 在 G^K 输出网格上逐点做 K 维求积的代价是 $O(n_D^K G^K)$ 。本小节说明: 当 $D_1, \dots, D_K$ 互相独立时, 外层期望其实是 K 个一维卷积算子的张量积, 从而在已持有完整 G^K 中间数组 $\hat{F}_M$ 的前提下, 额外的逐轴卷积代价降为 $O(K n_D G^K)$ ——即求积点数的依赖从 n_D^K 变为 $K n_D$, 而 G^K 这个输出表规模本身不因该分解而减小。

先定义无 node-delay 的中间量。令

$$M_a = \max_{k \in P_a} (X_k + E_{ka}), \quad a = 1, \dots, K,$$

即 $Y_a = M_a + D_a$ 。由定理 1 在 $t = 0$ 处的特例, $M = (M_1, \dots, M_K)$ 的 joint CDF 为

$$F_M(y) = \mathcal{C}_T(M_1^\circ(y), \dots, M_d^\circ(y)), \quad M_{k,i}^\circ(y) = \int_{\mathbb{R}} b_{k,i}(x) \prod_{a \in H_k} F_{ka}(y_a - x) dx.$$

定义 1 (单轴卷积算子). 设 μ 是 $\mathbb{R}$ 上的概率测度, $a \in \{1, \dots, K\}$ 。对有界可测函数 $G: \mathbb{R}^K \rightarrow \mathbb{R}$, 定义

$$(\mathcal{K}_\mu^{(a)} G)(y) = \int_{\mathbb{R}} G(y_1, \dots, y_{a-1}, y_a - s, y_{a+1}, \dots, y_K) \mu(ds).$$

即沿第 a 个坐标轴与 μ 做卷积, 其余坐标不动。

命题 1 (node-delay 的张量积分解). 设 $D_1, \dots, D_K$ 互相独立, 且 D 与 $(X, \{E_{ka}\})$ 独立, $\text{Law}(D_a) = \mu_a$ 。则

$$F_Y = \left(\mathcal{K}_{\mu_1}^{(1)} \circ \dots \circ \mathcal{K}_{\mu_K}^{(K)} \right) F_M = \left(\bigotimes_{a=1}^K \mathcal{K}_{\mu_a}^{(a)} \right) F_M,$$

且各算子两两交换, 故复合次序任意。

证明. 由构造 $Y_a = M_a + D_a$, 且向量 M 与向量 D 独立。于是对任意 $y \in \mathbb{R}^K$,

$$F_Y(y) = \mathbb{P}(M_a + D_a \leq y_a, \forall a) = \mathbb{E}_D[F_M(y_1 - D_1, \dots, y_K - D_K)],$$

其中交换期望与事件由 $M \perp D$ 和 Fubini (被积函数有界可测, 见注 1) 保证。由 $D_1, \dots, D_K$ 互相独立, $\text{Law}(D) = \bigotimes_a \mu_a$, 故上式右侧的 K 维积分按 Fubini 分解为 K 次一维积分, 每次只作用在一个坐标上:

$$\mathbb{E}_D[F_M(y - D)] = \int_{\mathbb{R}} \cdots \int_{\mathbb{R}} F_M(y_1 - s_1, \dots, y_K - s_K) \mu_1(ds_1) \cdots \mu_K(ds_K).$$

这正是 $\mathcal{K}_{\mu_1}^{(1)} \circ \cdots \circ \mathcal{K}_{\mu_K}^{(K)}$ 作用于 F_M 。不同轴的算子作用在不同变量上, 由 Fubini 可交换。□

推论 1 (外层求积代价). 设输出网格在每个坐标轴上取 G 个点, 每个 μ_a 用 n_D 点求积公式近似。则在已知 F_M 于整个 G^K 网格上取值的前提下, 计算 F_Y 于同一网格上全部取值的额外代价为

$$O(K n_D G^K),$$

而非直接对 K 维联合分布求积所需的 $O(n_D^K G^K)$ 。

证明. 由命题 1, 只需依次沿每个轴做一维卷积。第 a 轴的一维卷积对每个网格点需 n_D 次加权求和, 共 G^K 个网格点, 代价 $O(n_D G^K)$; K 个轴顺序执行, 总代价 $O(K n_D G^K)$ 。□

注 3 (与实现的对应). 仓库中的实现已经采用这一结构, 而非 K 维联合求积: `simple_tttns_l2/maxplus_cdf.py` 中的 `pair_cdf` 对 $K = 2$ 先沿第一坐标、再沿第二坐标做加权求积; `simple_tttns_l2/maxplus_cdf_forest.py` 中的 `block_joint_cdf` 对一般 K 逐轴调用 `_delay_convolve_axis`。命题 1 说明: “逐轴依次执行一维算子”这一分解在 D_a 独立时是精确恒等式, 用它代替 K 维联合积分不引入任何额外误差。但这不等于说实现是精确的: 每个一维算子的离散化仍带有有限求积、插值、截断与 clipping 误差, 这些误差由定理 4 的完整误差预算统一控制。

注 4 (独立性不可去除). 若 $D_1, \dots, D_K$ 相关, 则 $\text{Law}(D)$ 不再是乘积测度, Fubini 分解失效, 张量积形式一般不成立; 此时只能保留定理 1 的 $\mathbb{E}_D[\cdot]$ 一般式。这与后文关于公共噪声的边界讨论一致: 相关的 node delay 会自行注入输出依赖, 既破坏外层求积的张量积结构, 也破坏信息预算定理的前提。

4 局部投影误差通过 TTNS 的传播

4.1 sensitivity 向量

对任意 k 和任意给定的其他输入向量 $u_{-k} = (u_1, \dots, u_{k-1}, u_{k+1}, \dots, u_d)$, 定义第 k 个 sensitivity 向量

$$S_k(u_{-k}) \in \mathbb{R}^{m_k}$$

为

$$[S_k(u_{-k})]_i = \mathcal{C}_T(u_1, \dots, u_{k-1}, e_i, u_{k+1}, \dots, u_d),$$

其中 e_i 是 $\mathbb{R}^{m_k}$ 中第 i 个标准基向量。换言之, S_k 是把除了第 k 个物理指标以外的整个 TTNS 全部收缩掉以后得到的局部敏感度。

按定义逐个计算 $S_1, \dots, S_d$ 需要 d 次独立的完整收缩。下面的命题说明这是不必要的: 全部 d 个 sensitivity 向量可以由两次 sweep 同时得到, 代价与一次收缩同阶。

命题 2 (一次上行加一次下行 sweep 给出全部 sensitivity). 把树 T 任取一个根定向。对每个 k , 记 $\delta_T(k)$ 为与 k 相邻的树边集合, $\deg_T(k) = |\delta_T(k)|$, core 为 $G_{i_k, (\alpha_e)_{e \in \delta_T(k)}}^{(k)}$, 输入向量为 $z_k \in \mathbb{R}^{m_k}$ 。定义沿每条边两个方向的消息: 对 k 的父边 $e_k = (k, \text{pa}(k))$,

$$U_{k \rightarrow \text{pa}(k)}(\alpha_{e_k}) = \sum_{i_k} z_{k, i_k} \sum_{(\alpha_e)_{e \in \delta_T(k) \setminus \{e_k\}}} G_{i_k, (\alpha_e)_{e \in \delta_T(k)}}^{(k)} \prod_{c \in \text{ch}(k)} U_{c \rightarrow k}(\alpha_{(c, k)}),$$

并对每个孩子 c 对称地定义下行消息 $U_{k \rightarrow c}$ (把 k 的父消息与除 c 以外的孩子消息一并收缩)。则

$$[S_k]_i = \sum_{(\alpha_e)_{e \in \delta_T(k)}} G_{i, (\alpha_e)_{e \in \delta_T(k)}}^{(k)} \prod_{e \in \delta_T(k)} U_{\rightarrow k}(\alpha_e),$$

其中 $U_{\rightarrow k}$ 表示沿边 e 指向 k 的那条消息。全部 $\{S_k\}_{k=1}^d$ 可由一次 leaf $\rightarrow$ root 上行 sweep 加一次 root $\rightarrow$ leaf 下行 sweep 得到, 总时间为

$$O\left(\sum_{k=1}^d (\deg_T(k) + 1) m_k \prod_{e \in \delta_T(k)} r_e\right) = O\left(d (\deg_T^{\max} + 1) m r^{\deg_T^{\max}}\right),$$

其中 $\deg_T^{\max} = \max_k \deg_T(k)$; $\deg_T(k)$ 之外的 $+1$ 计入读取 core $G^{(k)}$ 并与 z_k 收缩得到 S_k 本身这一步。对 $d \geq 2$ 的树这只改变常数; 但在 $d = 1$ 的退化树上唯一节点的度数为零, 若写成 $\deg_T(k)$ 则右侧为零, 而此时仍需读取该 core, 故 $+1$ 是必要的。消息存储为 $O(\sum_{e \in E} r_e) = O(dr)$ 。

证明. 恒等式部分即 C_T 关于第 k 个物理指标的多线性展开: 把 z_k 换成 e_i 后, 树上其余部分的收缩值与 i 无关, 恰好等于以 k 为中心、沿每条关联边汇入的消息之积。由于 T 是树, 去掉节点 k 后各分支互不相交, 故这些消息可以独立计算, 且每条边的两个方向消息合起来覆盖了所有分支。

代价部分: 上行 sweep 按拓扑序对每个非根节点计算一条消息; 下行 sweep 按逆序对每个非根节点计算一条反向消息。每条消息的计算是把 core 与 $\deg_T(k) - 1$ 条已知消息及 z_k 收缩, 代价 $O(m_k \prod_{e \in \delta_T(k)} r_e)$; 节点 k 共产生 $\deg_T(k)$ 条出边消息, 故该节点总代价 $O(\deg_T(k) m_k \prod_{e \in \delta_T(k)} r_e)$ 。最后由同样的一次收缩得到 S_k 自身, 这一步对每个节点各计一次, 即上式中的 $+1$; 对 $\deg_T(k) \geq 1$ 的节点它不改变阶, 对 $d = 1$ 的单节点树它是唯一的代价来源。求和即得。 $\square$

注 5 (相对逐个计算的收益与定位). 按定义逐个计算需 d 次完整收缩, 代价 $O(d^2 m r^{\deg_T^{\max}})$; 命题 2 把它降到 $O(d (\deg_T^{\max} + 1) m r^{\deg_T^{\max}})$, 即节省一个 d 因子。这使定理 3 与推论 2 从存在性估计变成可执行的自适应精化判据: 在同一次 sweep 内即可得到全部 $\|S_k\|_\infty$, 从而按 $E_k \|S_k\|_\infty$ 的大小决定在哪个上游坐标上加密求积网格或扩大截断区间。(这里得到的是同一输入配置下的 sensitivity; 定理 4 实际需要的有序 hybrid 版本见注 6 与命题 3, 代价同阶。)

该 sweep 是 DMRG environment tensor 与树上反向传播的标准技巧在本设定的实例化, 本文不主张其为新算法, 只主张上述复杂度结论及其与误差判据的组合。需要说明的是: 当前仓库实现 (simple_tttns_l2/maxplus_cdf.py 中的 UpperModel._contract) 每次调用都做一次完整收缩, 并未实现 sensitivity sweep; 即本命题属于“理论允许但当前实现未采用”, 若要按该判据做自适应精化需另行实现。

注 6 (命题 2 还不足以支撑误差预算的权重). 命题 2 给出的是同一个输入配置 $(z_1, \dots, z_d)$ 下的 d 个 sensitivity $S_k(u_{-k})$ 。但下面定理 2 的 telescoping 恒等式所需的第 k 个 sensitivity 是

$$S_k(\hat{z}_1, \dots, \hat{z}_{k-1}, z_{k+1}, \dots, z_d),$$

其输入环境随 k 改变: 前 $k - 1$ 个坐标取近似值、后 $d - k$ 个坐标取真值。这不是同一配置下的一族 sensitivity, 因此不能直接由命题 2 得到。命题 3 补上这一步: 只要把 telescoping 的坐标顺序取为 T 的一个后序遍历, 全部 d 个 hybrid sensitivity 仍可由常数次 sweep 同时得到。

命题 3 (后序 telescoping 下的 hybrid environment sweep). 把树 T 任取一个根 rt 定向, 并把坐标标号 $1, \dots, d$ 取为该有根树的一个后序遍历 (每个节点的编号大于其全部后代的编号, 且同一父节点的各子树按编号区间连续排列)。定义三族消息。

(a) 真值上行消息. 对每个非根节点 c ,

$$U_{c \rightarrow \text{pa}(c)}(\alpha_{e_c}) = \sum_{i_c} z_{c, i_c} \sum_{(\alpha_e)_{e \in \delta_T(c) \setminus \{e_c\}}} G_{i_c, (\alpha_e)_{e \in \delta_T(c) \setminus \{e_c\}}}^{(c)} \prod_{c' \in \text{ch}(c)} U_{c' \rightarrow c}(\alpha_{(c', c)}), \quad e_c = (c, \text{pa}(c)).$$

- (b) 近似值上行消息. $\hat{U}_{c \rightarrow \text{pa}(c)}$ 由同一公式给出, 但把 z_c 换成 $\hat{z}_c$ 、把 $U_{c' \rightarrow c}$ 换成 $\hat{U}_{c' \rightarrow c}$ 。
(c) hybrid 下行消息. 设节点 p 的孩子按后序编号递增排列为 $c_1, \dots, c_t$ 。对每个 j ,

$$V_{p \rightarrow c_j}(\alpha_{(p, c_j)}) = \sum_{i_p} z_{p, i_p} \sum_{(\alpha_e)_{e \in \delta_T(p) \setminus \{(p, c_j)\}}} G_{i_p, (\alpha_e)_{e \in \delta_T(p)}}^{(p)} V_{\text{pa}(p) \rightarrow p}(\alpha_{e_p}) \prod_{i < j} \hat{U}_{c_i \rightarrow p} \prod_{i > j} U_{c_i \rightarrow p},$$

其中最后两个乘积中的消息分别以 $\alpha_{(c_i, p)}$ 为自变量；当 $p = \text{rt}$ 时因子 $V_{\text{pa}(p) \rightarrow p}$ 与其 bond 指标一并省略（空乘积为 1）。则对每个 k ,

$$[S_k(u_{-k}^{\text{hyb}})]_i = \sum_{(\alpha_e)_{e \in \delta_T(k)}} G_{i, (\alpha_e)_{e \in \delta_T(k)}}^{(k)} V_{\text{pa}(k) \rightarrow k}(\alpha_{e_k}) \prod_{c \in \text{ch}(k)} \hat{U}_{c \rightarrow k}(\alpha_{(c, k)}),$$

其中沿用上面同一约定：当 $k = \text{rt}$ 时（此时 $\text{pa}(k)$ 与 e_k 均无定义）因子 $V_{\text{pa}(k) \rightarrow k}(\alpha_{e_k})$ 及求和指标 α_{e_k} 一并省略，该因子按空乘积取 1。其中 $u_{-k}^{\text{hyb}} = (\hat{z}_1, \dots, \hat{z}_{k-1}, z_{k+1}, \dots, z_d)$ 按上述后序编号理解。因此全部 d 个 hybrid sensitivity 可由两次上行 sweep 加一次下行 sweep 同时得到，总时间仍为

$$O\left(\sum_{k=1}^d (\deg_T(k) + 1) m_k \prod_{e \in \delta_T(k)} r_e\right) = O\left(d (\deg_T^{\max} + 1) m r^{\deg_T^{\max}}\right),$$

其中 $+1$ 的含义与命题 2 相同（读取 core 并收缩出 S_k 自身； $d = 1$ 时它是唯一代价来源）。消息存储为 $O(dr)$ 。

证明. 关键是一个纯组合观察。固定 k ，去掉节点 k 后 T 分裂为 $\deg_T(k)$ 个分支：每个孩子 $c \in \text{ch}(k)$ 对应的子树 T_c ，以及 k 的父方向分支（ $k = \text{rt}$ 时不存在）。按后序编号：

第一， T_c 中的每个节点都是 k 的后代，故编号小于 k ，从而在 u_{-k}^{hyb} 中一律取近似值 $\hat{z}$ 。因此该分支汇入 k 的消息正是 (b) 中的 $\hat{U}_{c \rightarrow k}$ 。

第二，父方向分支内部按“路径上的祖先取真值、路径左侧的兄弟子树取近似值、路径右侧的兄弟子树取真值”分层。理由：设 k 到根的路径为 $k, p_1 = \text{pa}(k), p_2, \dots, \text{rt}$ 。每个 p_l 都是 k 的祖先，后序编号大于 k ，故取 z_{p_l} 。对 p_l 的每个不在该路径上的孩子 c' ，子树 $T_{c'}$ 与含 k 的那棵子树在后序遍历中占据两个不相交的连续编号区间，因此 $T_{c'}$ 的全部编号要么都小于 k （ c' 在含 k 的孩子之前，取 $\hat{z}$ ），要么都大于 k （在其之后，取 z ）。这正是 (c) 中 $\prod_{i < j} \hat{U} \cdot \prod_{i > j} U$ 的含义，其中 c_j 是 p_l 通往 k 的那个孩子。

于是父方向分支汇入 k 的消息恰为 $V_{\text{pa}(k) \rightarrow k}$ ：对该式按 $l = 1, 2, \dots$ 递归展开，每一层的 z_{p_l} 、左侧 $\hat{U}$ 、右侧 U 与上述分层逐项对应。由于 T 是树，去掉 k 后各分支互不相交，各分支的收缩可以独立进行，把它们与 core $G^{(k)}$ 及第 k 个物理指标上的基向量 e_i 收缩即得 $[S_k(u_{-k}^{\text{hyb}})]_i$ 。这就是所断言的恒等式；它同时说明 V 的递归定义是良定义的（下行 sweep 按编号递减处理）。

代价：两次上行 sweep 各对每个非根节点算一条消息，代价 $O(m_k \prod_{e \in \delta_T(k)} r_e)$ ；下行 sweep 在节点 p 处对每个孩子算一条消息，共 $|\text{ch}(p)| \leq \deg_T(p)$ 条，单条代价同阶。求和即得上述总时间。三族消息各占 $O(\sum_e r_e) = O(dr)$ 。□

注 7 (后序要求是无代价的，但必须显式声明)。定理 2 的 telescoping 恒等式对坐标的任意排列都成立（它只是一个逐项相消的求和），因此把标号取成后序遍历不损失一般性，只是在若干等价的误差分解中选定一个。代价是：误差预算中出现的 $\|S_k(u_{-k}^{\text{hyb}})\|_\infty$ 依赖于所选顺序，故定理 4 与推论 3 中的这一项应理解为“在选定的后序标号下”的值。若不愿绑定顺序，可以退而使用与顺序无关的一致上界

$$\|S_k\|_\infty^{\sup} = \sup\{\|S_k(v_{-k})\|_\infty : v_b \in \{z_b, \hat{z}_b\} \text{ 对所有 } b \neq k\},$$

它同时控制全部 2^{d-1} 个 hybrid 环境，但一般比逐个后序值更松，且没有对应的 sweep 算法——本文采用前者。

定理 2 (TTNS 局部扰动恒等式和范数界). 令 $z_k, \hat{z}_k \in \mathbb{R}^{m_k}$. 定义 hybrid 输入

$$u_{-k}^{\text{hyb}} = (\hat{z}_1, \dots, \hat{z}_{k-1}, z_{k+1}, \dots, z_d).$$

(恒等式对坐标的任意排列成立; 按注 7 的约定, 本文一律把 $1, \dots, d$ 取为 T 的一个后序遍历, 以便由命题 3 同时算出全部 $S_k(u_{-k}^{\text{hyb}})$.) 则有精确 telescoping 恒等式

$$\mathcal{C}_T(z_1, \dots, z_d) - \mathcal{C}_T(\hat{z}_1, \dots, \hat{z}_d) = \sum_{k=1}^d \left\langle z_k - \hat{z}_k, S_k(u_{-k}^{\text{hyb}}) \right\rangle.$$

因此, 对任意共轭范数 $\|\cdot\|_p$ 和 $\|\cdot\|_q$,

$$|\mathcal{C}_T(z_1, \dots, z_d) - \mathcal{C}_T(\hat{z}_1, \dots, \hat{z}_d)| \leq \sum_{k=1}^d \|z_k - \hat{z}_k\|_p \|S_k(u_{-k}^{\text{hyb}})\|_q.$$

特别地,

$$|\mathcal{C}_T(z_1, \dots, z_d) - \mathcal{C}_T(\hat{z}_1, \dots, \hat{z}_d)| \leq \sum_{k=1}^d \|z_k - \hat{z}_k\|_1 \|S_k(u_{-k}^{\text{hyb}})\|_\infty.$$

证明. 定义

$$V^{(k)} = \mathcal{C}_T(\hat{z}_1, \dots, \hat{z}_k, z_{k+1}, \dots, z_d), \quad V^{(0)} = \mathcal{C}_T(z_1, \dots, z_d).$$

则

$$\mathcal{C}_T(z_1, \dots, z_d) - \mathcal{C}_T(\hat{z}_1, \dots, \hat{z}_d) = \sum_{k=1}^d (V^{(k-1)} - V^{(k)}).$$

由于 $\mathcal{C}_T$ 对第 k 个输入向量线性,

$$V^{(k-1)} - V^{(k)} = \left\langle z_k - \hat{z}_k, S_k(u_{-k}^{\text{hyb}}) \right\rangle.$$

对每一项应用 Hölder 不等式即得范数界。 □

4.2 局部 CDF 投影的数值误差

固定 $y \in \mathbb{R}^K$ 和 node-delay 实现值 $t \in \mathbb{R}^K$. 设 $H_k \neq \emptyset$ 时

$$f_{k,i}(x; y, t) = b_{k,i}(x) \prod_{a \in H_k} F_{ka}(y_a - t_a - x),$$

若 $H_k = \emptyset$, 则乘积仍定义为 1. 选择有限积分区间

$$I_{k,i} = [\alpha_{k,i}, \beta_{k,i}]$$

和步长 $h_{k,i} = (\beta_{k,i} - \alpha_{k,i})/n_{k,i}$. 令 $Q_{k,i}$ 表示 $I_{k,i}$ 上的复合梯形公式. 若 edge CDF 用近似函数 $\hat{F}_{ka}$, 则实际计算的局部投影记为

$$\widehat{M}_{k,i}(y, t) = Q_{k,i} \left[b_{k,i}(x) \prod_{a \in H_k} \hat{F}_{ka}(y_a - t_a - x) \right].$$

假设 1 (近似 edge CDF 的取值范围). 每个近似函数满足 $\hat{F}_{ka} : \mathbb{R} \rightarrow [0, 1]$.

该假设不是技术性赘述: 下面误差分解的第三项使用乘积 telescoping $|\prod_a u_a - \prod_a v_a| \leq \sum_a |u_a - v_a|$, 而该不等式要求两组因子都落在 $[0, 1]$ 内. 真实 CDF 自动满足, 插值或拟合得到的 $\hat{F}_{ka}$ 则不一定; 实现中通过对近似值做 $[0, 1]$ 截断 (clipping) 来强制满足, 见 `simple_tttns_l2/maxplus_cdf.py` 中对 F 的 `np.clip` 处理. 截断本身不增大近似误差, 因为真值已在 $[0, 1]$ 内.

定理 3 (局部 CDF 投影误差估计). 在假设 1 下, 假设在 $I_{k,i}$ 上 $f_{k,i}$ 二阶可导, 且

$$\sup_{x \in I_{k,i}} |f_{k,i}''(x; y, t)| \leq B_{k,i}^{(2)}(y, t).$$

再假设 edge CDF 近似误差满足

$$\varepsilon_{k,i,a}^{\text{cdf}}(y, t) = \sup_{x \in I_{k,i}} |F_{ka}(y_a - t_a - x) - \widehat{F}_{ka}(y_a - t_a - x)| < \infty.$$

定义尾部项

$$\tau_{k,i}(y, t) = \int_{\mathbb{R} \setminus I_{k,i}} |b_{k,i}(x)| dx$$

和梯形权重下的基函数绝对质量

$$\Lambda_{k,i} = h_{k,i} \left[\frac{1}{2} |b_{k,i}(\alpha_{k,i})| + \sum_{r=1}^{n_{k,i}-1} |b_{k,i}(\alpha_{k,i} + rh_{k,i})| + \frac{1}{2} |b_{k,i}(\beta_{k,i})| \right].$$

则

$$|M_{k,i}(y, t) - \widehat{M}_{k,i}(y, t)| \leq \tau_{k,i}(y, t) + \frac{\beta_{k,i} - \alpha_{k,i}}{12} h_{k,i}^2 B_{k,i}^{(2)}(y, t) + \Lambda_{k,i} \sum_{a \in H_k} \varepsilon_{k,i,a}^{\text{cdf}}(y, t).$$

证明. 把误差分成三项:

$$\begin{aligned} |M_{k,i} - \widehat{M}_{k,i}| &\leq \left| \int_{\mathbb{R} \setminus I_{k,i}} f_{k,i}(x) dx \right| \\ &\quad + \left| \int_{I_{k,i}} f_{k,i}(x) dx - Q_{k,i}[f_{k,i}] \right| \\ &\quad + \left| Q_{k,i}[f_{k,i}] - Q_{k,i} \left[b_{k,i} \prod_{a \in H_k} \widehat{F}_{ka} \right] \right|. \end{aligned}$$

第一项由所有 CDF 取值在 $[0, 1]$ 内得到

$$\left| \int_{\mathbb{R} \setminus I_{k,i}} f_{k,i}(x) dx \right| \leq \int_{\mathbb{R} \setminus I_{k,i}} |b_{k,i}(x)| dx.$$

第二项是复合梯形公式的标准误差界。第三项使用乘积 telescoping: 若 $0 \leq u_a, v_a \leq 1$, 则

$$\left| \prod_a u_a - \prod_a v_a \right| \leq \sum_a |u_a - v_a|,$$

其中真值因子 $u_a = F_{ka}(\cdot) \in [0, 1]$ 自动成立, 近似因子 $v_a = \widehat{F}_{ka}(\cdot) \in [0, 1]$ 由假设 1 保证。再利用梯形公式权重非负, 得到 $\Lambda_{k,i} \sum_{a \in H_k} \varepsilon_{k,i,a}^{\text{cdf}}$ 。□

假设 2 (外层期望的可积性). 记

$$E_k(y, t) = \sum_{i=1}^{m_k} \left[\tau_{k,i}(y, t) + \frac{\beta_{k,i} - \alpha_{k,i}}{12} h_{k,i}^2 B_{k,i}^{(2)}(y, t) + \Lambda_{k,i} \sum_{a \in H_k} \varepsilon_{k,i,a}^{\text{cdf}}(y, t) \right].$$

假设对每个 k , 随机变量

$$E_k(y, D) \| S_k(u_{-k}^{\text{hyb}}(y, D)) \|_{\infty}$$

关于 $\text{Law}(D)$ 可积。

该假设不可省略： $B_{k,i}^{(2)}(y, t)$ 与 $\|S_k(\cdot)(y, t)\|_\infty$ 都是 t 的函数，因而在 D 随机时是随机变量，其 $\mathbb{E}_D$ 未必有限。一个便于核验的充分条件是： $b_{k,i} \in C_c^2(\mathbb{R})$ ，每个相关的 $F_{ka} \in C^2(\mathbb{R})$ 且 F'_{ka}, F''_{ka} 有与平移参数 t_a 无关的一致上界，同时 edge CDF 近似误差 $\varepsilon_{k,i,a}^{\text{cdf}}$ 与 sensitivity 范数 $\|S_k\|_\infty$ 也有与 t 无关的一致上界；此时由乘积求导法则可显式控制 $B_{k,i}^{(2)}$ ，被积函数一致有界，可积性自动满足。仅设 F_{ka} 为 Lipschitz 是不够的：Lipschitz 不蕴含二阶可导，甚至不蕴含处处一阶可导。例如取 $[0, 1]$ 上均匀分布的 CDF $F(u) = \min\{\max\{u, 0\}, 1\}$ （它是 1-Lipschitz 的）与任一满足 $b(c) \neq 0$ 的 $b \in C_c^2(\mathbb{R})$ ，则 $x \mapsto b(x)F(c-x)$ 在 $x=c$ 与 $x=c-1$ 处一般有导数折点，不满足定理 3 所需的区间内 C^2 假设。这与注 14 中关于均匀 delay 端点不光滑的说明一致。若确实只能假设 Lipschitz（或更一般的有界变差）edge CDF，则应把梯形项换成适用于分段光滑函数的一阶误差估计，而不能继续使用二阶导上界。

推论 2 (局部误差到 joint CDF 误差). 在假设 1 与 2 下，若外层 node-delay 期望精确计算，则由定理 1 和 TTNS 局部扰动定理，

$$\left| F_Y(y) - \widehat{F}_Y(y) \right| \leq \mathbb{E}_D \left[\sum_{k=1}^d \mathbb{E}_k(y, D) \|S_k(u_{-k}^{\text{hyb}}(y, D))\|_\infty \right],$$

其中 $u_{-k}^{\text{hyb}}(y, D)$ 使用 $(\widehat{M}_1, \dots, \widehat{M}_{k-1}, M_{k+1}, \dots, M_d)$ 。若 D 的外层期望也用数值求积近似，则需要额外加入外层求积误差项，见后文定理 4。

4.3 外层求积误差与完整单层预算

命题 1 把外层期望化为逐轴一维卷积，因此外层求积误差也可以逐轴分离。设第 a 轴用 n_D 点求积公式近似 μ_a ，即取非负权重 $w_{a,1}, \dots, w_{a,n_D}$ 与节点 $s_{a,1}, \dots, s_{a,n_D}$ ，令

$$\widehat{\mu}_a = \sum_{j=1}^{n_D} w_{a,j} \delta_{s_{a,j}}, \quad \sum_j w_{a,j} = 1,$$

并记对应算子为 $\mathcal{K}_{\widehat{\mu}_a}^{(a)}$ 。要求 $\widehat{\mu}_a$ 是概率测度是本质的：它保证该算子仍是平均算子，从而在 $\|\cdot\|_\infty$ 下算子范数不超过 1。

引理 2 (卷积算子的非扩张性). 对任意概率测度 μ 与任意 a ，算子 $\mathcal{K}_\mu^{(a)}$ 在 $\|\cdot\|_\infty$ 下的算子范数不超过 1。

证明. $|(\mathcal{K}_\mu^{(a)} G)(y)| \leq \int |G(\dots, y_a - s, \dots)| \mu(ds) \leq \|G\|_\infty \mu(\mathbb{R}) = \|G\|_\infty$. $\square$

引理 3 (单轴求积误差的 Kantorovich–Rubinstein 界). 设 $G: \mathbb{R}^K \rightarrow \mathbb{R}$ 有界，且关于第 a 个坐标一致 L_a -Lipschitz，即

$$|G(\dots, y_a, \dots) - G(\dots, y'_a, \dots)| \leq L_a |y_a - y'_a|$$

对所有其余坐标一致成立。则

$$\|\mathcal{K}_{\mu_a}^{(a)} G - \mathcal{K}_{\widehat{\mu}_a}^{(a)} G\|_\infty \leq L_a W_1(\mu_a, \widehat{\mu}_a),$$

其中 W_1 是 $\mathbb{R}$ 上的 1-Wasserstein 距离。

证明. 固定 y ，令 $\varphi(s) = G(y_1, \dots, y_a - s, \dots, y_K)$ 。由假设 φ 是 L_a -Lipschitz 的一元函数，且

$$(\mathcal{K}_{\mu_a}^{(a)} G)(y) - (\mathcal{K}_{\widehat{\mu}_a}^{(a)} G)(y) = \int_{\mathbb{R}} \varphi d\mu_a - \int_{\mathbb{R}} \varphi d\widehat{\mu}_a.$$

由 Kantorovich–Rubinstein 对偶，该差的绝对值不超过 $L_a W_1(\mu_a, \widehat{\mu}_a)$ 。对 y 取上确界即得。 $\square$

本文把外层求积项统一记为

$$\varrho_a(n_D) = W_1(\mu_a, \hat{\mu}_a).$$

若 μ_a 有有限一阶矩, 且 $\hat{\mu}_a$ 取其 n_D 点分位数离散或复合中点离散, 则 $\varrho_a(n_D) \rightarrow 0$. 但仅有有限一阶矩不足以保证 $O(n_D^{-1})$ 的速率, 见注 8.

注 8 (W_1 收敛率需要额外的尾部或正则性条件). 有限一阶矩只给出 $\varrho_a(n_D) \rightarrow 0$, 不给出速率. 设 μ_a 的分位数函数在 $u \rightarrow 1^-$ 时满足

$$Q(u) = (1-u)^{-\alpha}, \quad 0 < \alpha < 1.$$

该分布有有限一阶矩, 但等概率分位数离散的最后一个区间 $[1 - 1/n_D, 1)$ 单独贡献

$$\int_{1-1/n_D}^1 |Q(u) - Q(u^*)| du = \Theta(n_D^{\alpha-1}),$$

故 $\varrho_a(n_D) = \Theta(n_D^{\alpha-1})$, 慢于 n_D^{-1} ; 例如 $\alpha = 1/2$ 时只有 $\Theta(n_D^{-1/2})$, 且随 $\alpha \uparrow 1$ 可以任意接近不收敛. 因此速率断言必须附加条件.

下面给出一个可直接验证的充分条件. 设 Q 绝对连续且 $Q' \in L^p([0, 1])$ 对某个 $p > 1$ 成立, $\hat{\mu}_a$ 取 n_D 个等概率区间 I_j 上的任意代表点. 由 $|Q(u) - Q(u_j)| \leq \int_{I_j} |Q'|$ 与 Hölder 不等式, $\int_{I_j} |Q'| \leq |I_j|^{1/p'} \|Q'\|_{L^p(I_j)}$ ($1/p + 1/p' = 1$), 故

$$\varrho_a(n_D) \leq \sum_{j=1}^{n_D} |I_j|^{1+1/p'} \|Q'\|_{L^p(I_j)} = n_D^{-(1+1/p')} \sum_{j=1}^{n_D} \|Q'\|_{L^p(I_j)},$$

再对求和用 Hölder (指数 p', p) 得 $\sum_j \|Q'\|_{L^p(I_j)} \leq n_D^{1/p'} \|Q'\|_{L^p}$, 于是

$$\varrho_a(n_D) \leq \frac{\|Q'\|_{L^p([0,1])}}{n_D}. \quad (6)$$

特别地, 有界支撑且密度有正下界 (此时 $Q' \in L^\infty$) 给出 $\varrho_a(n_D) \leq \|Q'\|_\infty n_D^{-1}$. 上面的反例与 (6) 不矛盾: $Q(u) = (1-u)^{-\alpha}$ 的导数 $Q'(u) = \alpha(1-u)^{-\alpha-1}$ 对任何 $p \geq 1$ 都不属于 L^p .

本文其余部分只使用 $\varrho_a(n_D)$ 这一记号本身与 $\varrho_a(n_D) \rightarrow 0$, 凡出现具体速率 $O(n_D^{-1})$ 之处 (推论 3) 都显式引用条件 $Q' \in L^p, p > 1$.

4.4 实现所使用的算子: 网格插值与边界钳制

命题 1 与引理 3 都假定 $\hat{F}_M$ 可在任意移位点 $y_a - s$ 上准确求值. 实际实现并非如此. 中间 CDF 只在有限输出网格上计算; 做逐轴卷积时, $\hat{F}_M(y_a - s)$ 用沿该轴的分段线性插值求值, 并把落到网格之外的求值点钳制到首尾网格点 (simple_tttns_l2/maxplus_cdf.py 的 pair_cdf 与 simple_tttns_l2/maxplus_cdf_forest.py 的 _delay_convolve_axis, 二者都以 np.interp(grid-d, grid, arange(G), left=0, right=G-1) 取索引). 钳制相当于把 CDF 沿该轴作常数外延, 而不是使用精确的边界外取值. 因此仅有引理 3 的求积项还不足以覆盖实现误差, 必须另外计入两项. 本小节先把实现算子写清楚, 再给出这两项的显式界.

定义 2 (实现所使用的逐轴卷积算子). 设第 a 轴的输出网格为 $\mathcal{Y}_a = \{y_a^{(1)} < \dots < y_a^{(G)}\}$, 记 $y_a^{\min} = y_a^{(1)}$ 、 $y_a^{\max} = y_a^{(G)}$, 网格步长

$$h_a^{\text{out}} = \max_{1 \leq j \leq G-1} (y_a^{(j+1)} - y_a^{(j)}).$$

令钳制映射

$$\pi_a(v) = \min\{\max\{v, y_a^{\min}\}, y_a^{\max}\},$$

并令 Π_a 为沿第 a 轴在 $\mathcal{Y}_a$ 上的分段线性插值算子。定义 实现算子

$$(\tilde{\mathcal{K}}_a G)(y) = \sum_{j=1}^{n_D} w_{a,j} (\Pi_a G)(y_1, \dots, y_{a-1}, \pi_a(y_a - s_{a,j}), y_{a+1}, \dots, y_K),$$

以及 $\tilde{\mathcal{A}} = \tilde{\mathcal{K}}_K \circ \dots \circ \tilde{\mathcal{K}}_1$ 。实际数值结果是 $\tilde{F}_Y = \tilde{\mathcal{A}} \hat{F}_M$ ，而不是理想化的 $(\bigotimes_a \mathcal{K}_{\hat{\mu}_a}^{(a)}) \hat{F}_M$ 。

引理 4 (插值误差与边界钳制误差). 设 $G : \mathbb{R}^K \rightarrow [0, 1]$ 有界, 且关于第 a 个坐标一致 L_a -Lipschitz。定义越界振幅

$$\theta_a^-(G) = \sup_{y-a} \sup_{v \leq y_a^{\min}} |G(y_a^{\min}, y-a) - G(v, y-a)|,$$

$$\theta_a^+(G) = \sup_{y-a} \sup_{v \geq y_a^{\max}} |G(v, y-a) - G(y_a^{\max}, y-a)|.$$

则:

- (i) $\tilde{\mathcal{K}}_a$ 是平均算子: $(\tilde{\mathcal{K}}_a G)(y)$ 是 G 在有限多个点上取值的凸组合。因此它保持常数、保序、在 $\|\cdot\|_\infty$ 下非扩张; 并且对任意 b , 它不增大 G 关于第 b 个坐标的 Lipschitz 常数; 对任意 $b \neq a$, 还有 $\theta_b^\pm(\tilde{\mathcal{K}}_a G) \leq \theta_b^\pm(G)$ 。

(ii)

$$\|\tilde{\mathcal{K}}_a G - \mathcal{K}_{\hat{\mu}_a}^{(a)} G\|_\infty \leq \underbrace{\frac{1}{2} L_a h_a^{\text{out}}}_{=: \varepsilon_a^{\text{grid}}} + \underbrace{\theta_a^-(G) + \theta_a^+(G)}_{=: \varepsilon_a^{\text{bdry}}}.$$

若 G 关于第 a 个坐标为 C^2 且 $|\partial_{y_a}^2 G| \leq B_a^{\text{out}}$ 一致成立, 则 $\varepsilon_a^{\text{grid}}$ 可改进为 $(h_a^{\text{out}})^2 B_a^{\text{out}} / 8$ 。

证明. (i) 求积权重 $w_{a,j} \geq 0$ 且 $\sum_j w_{a,j} = 1$; Π_a 在任一点的取值是相邻两个网格节点取值的凸组合 $(1-\vartheta)G(y_a^{(j)}, \cdot) + \vartheta G(y_a^{(j+1)}, \cdot)$; π_a 只是点映射。三者复合后 $(\tilde{\mathcal{K}}_a G)(y)$ 仍是 G 取值的凸组合, 故保持常数、保序、 $\|\cdot\|_\infty$ 非扩张。关于 Lipschitz 常数: 对 $b \neq a$, 凸组合中每个点的第 b 个坐标都等于 y_b , 故沿第 b 轴的 Lipschitz 常数直接继承; 对 $b = a$, 分段线性插值的斜率是 G 的差商, 绝对值不超过 L_a , π_a 是 1-Lipschitz, 凸组合保持 Lipschitz 界。关于 $\theta_b^\pm$ ($b \neq a$): $\theta_b^\pm(\tilde{\mathcal{K}}_a G)$ 中的差是 G 在若干第 b 坐标相同的点对上的差的加权平均, 故其绝对值不超过 $\theta_b^\pm(G)$ 。

(ii) 逐个求积节点比较:

$$(\tilde{\mathcal{K}}_a G - \mathcal{K}_{\hat{\mu}_a}^{(a)} G)(y) = \sum_{j=1}^{n_D} w_{a,j} \left[(\Pi_a G)(\pi_a(y_a - s_{a,j}), y_{-a}) - G(y_a - s_{a,j}, y_{-a}) \right].$$

记 $v = y_a - s_{a,j}$, 并插入 $G(\pi_a(v), y_{-a})$:

$$\begin{aligned} |(\Pi_a G)(\pi_a(v), y_{-a}) - G(v, y_{-a})| &\leq |(\Pi_a G)(\pi_a(v), y_{-a}) - G(\pi_a(v), y_{-a})| \\ &\quad + |G(\pi_a(v), y_{-a}) - G(v, y_{-a})|. \end{aligned}$$

第一项是插值误差, 求值点 $\pi_a(v)$ 必落在网格区间内: 若 $\pi_a(v) \in [y_a^{(j_0)}, y_a^{(j_0+1)}]$ 且 ϑ 是其相对位置, 则

$$|G - \Pi_a G| \leq (1-\vartheta)|G(\pi_a(v)) - G(y_a^{(j_0)})| + \vartheta|G(\pi_a(v)) - G(y_a^{(j_0+1)})| \leq 2\vartheta(1-\vartheta)L_a h_a^{\text{out}} \leq \frac{1}{2} L_a h_a^{\text{out}},$$

C^2 情形则是分段线性插值的标准界 $(h_a^{\text{out}})^2 B_a^{\text{out}} / 8$ 。第二项在 v 落在网格区间内时为 0; 在 $v < y_a^{\min}$ 时不超过 $\theta_a^-(G)$, 在 $v > y_a^{\max}$ 时不超过 $\theta_a^+(G)$ 。两种越界情形互斥、权重之和不超过 1, 故第二项的加权平均不超过 $\theta_a^-(G) + \theta_a^+(G)$ 。对 y 取上确界即得。□

注 9 (越界振幅的概率含义). 本注需要一个比“逐坐标非降且取值于 $[0, 1]$ ”更强的假设。

假设 (合法联合 CDF). 设 $\hat{F}_M$ 是 $\mathbb{R}^K$ 上某个随机向量 $\widehat{M} = (\widehat{M}_1, \dots, \widehat{M}_K)$ 的联合分布函数, 即除逐坐标非降、取值于 $[0, 1]$ 外, 还满足 K -增性 (所有矩形的测度非负)、右连续, 以及 $\lim_{y \rightarrow -\infty} \text{某坐标 } \hat{F}_M = 0$ 、 $\lim_{y \rightarrow +\infty} \text{全部坐标 } \hat{F}_M = 1$ 。

在该假设下, 记 $\hat{F}_{M_a}$ 为 $\widehat{M}_a$ 的一维边缘分布函数, 即令其余阈值趋于 $+\infty$ 的极限 $\hat{F}_{M_a}(u) = \lim_{y_{-a} \rightarrow +\infty} \hat{F}_M(u, y_{-a})$ (不是对 y_{-a} 的平均), 则两个越界振幅可以精确计算:

$$\theta_a^-(\hat{F}_M) = \hat{F}_{M_a}(y_a^{\min}), \quad \theta_a^+(\hat{F}_M) = 1 - \hat{F}_{M_a}(y_a^{\max}), \quad (7)$$

从而

$$\varepsilon_a^{\text{bdry}} = \theta_a^- + \theta_a^+ = \Pr[\widehat{M}_a \notin (y_a^{\min}, y_a^{\max}]].$$

证明. 对 θ_a^- : 由 $\hat{F}_M$ 是联合 CDF, $\lim_{v \rightarrow -\infty} \hat{F}_M(v, y_{-a}) = 0$, 故内层上确界等于 $\hat{F}_M(y_a^{\min}, y_{-a})$; 它关于 y_{-a} 非降, 故外层上确界等于 $y_{-a} \rightarrow +\infty$ 的极限, 即 $\hat{F}_{M_a}(y_a^{\min})$ 。对 θ_a^+ : 内层上确界为 $\lim_{v \rightarrow +\infty} \hat{F}_M(v, y_{-a}) - \hat{F}_M(y_a^{\max}, y_{-a}) = \Pr[\widehat{M}_a > y_a^{\max}, \widehat{M}_{-a} \leq y_{-a}]$, 它作为一个随 y_{-a} 增大的事件的概率关于 y_{-a} 非降, 故外层上确界等于 $\Pr[\widehat{M}_a > y_a^{\max}] = 1 - \hat{F}_{M_a}(y_a^{\max})$ 。□

该假设不可省略。 仅设逐坐标非降且取值于 $[0, 1]$ 时, 即使 (7) 的不等号形式 $\theta_a^- + \theta_a^+ \leq \hat{F}_{M_a}(y_a^{\min}) + [1 - \hat{F}_{M_a}(y_a^{\max})]$ 也不成立。反例: 取 $K = 2$, 先在单位方块上令

$$G(u, v) = v u^{1+10(1-v)}, \quad (u, v) \in [0, 1]^2,$$

再用坐标截断把它延拓到整个 $\mathbb{R}^2$:

$$\hat{F}_M(u, v) := G(\text{clip}_{[0,1]}(u), \text{clip}_{[0,1]}(v)), \quad \text{clip}_{[0,1]}(t) := \min\{\max\{t, 0\}, 1\}.$$

延拓后的 $\hat{F}_M$ 在 $\mathbb{R}^2$ 上逐坐标非降、取值于 $[0, 1]$, 且满足 (8) 型归一化: $\hat{F}_M(u, v) \rightarrow 0 (u \rightarrow -\infty)$ 、 $\hat{F}_M(u, v) \rightarrow \hat{F}_{M_1}(u) (v \rightarrow +\infty)$ 。由 $G(u, 1) = u$ 、 $G(1, v) = v$ 得边缘 $\hat{F}_{M_1}(u) = \text{clip}_{[0,1]}(u)$ 。取 $y_1^{\min} = 0$ 、 $y_1^{\max} = 1/2$: 因 $\hat{F}_M(v, y_2) = \hat{F}_M(0, y_2)$ 对一切 $v \leq 0$ 成立, 故 $\theta_1^- = 0 = \hat{F}_{M_1}(0)$; 而

$$\theta_1^+ \geq \hat{F}_M(1, 0.9) - \hat{F}_M(1/2, 0.9) = 0.675 > 0.5 = 1 - \hat{F}_{M_1}(1/2),$$

于是 $\theta_1^- + \theta_1^+ > \hat{F}_{M_1}(y_1^{\min}) + [1 - \hat{F}_{M_1}(y_1^{\max})]$, 不等号形式被破坏。该函数不是 2-增的 (存在负测度矩形), 因此不是任何随机向量的联合 CDF——这正是上述假设排除的情形。

对本文的意义。 $\varepsilon_a^{\text{bdry}}$ 等于中间变量 $\widehat{M}_a$ 落在半开区间 $(y_a^{\min}, y_a^{\max}]$ 之外的质量,

$$\theta_a^- + \theta_a^+ = \Pr[\widehat{M}_a \leq y_a^{\min}] + \Pr[\widehat{M}_a > y_a^{\max}] = \Pr[\widehat{M}_a \notin (y_a^{\min}, y_a^{\max}]],$$

区间取半开是因为 $\theta_a^- = \hat{F}_{M_a}(y_a^{\min})$ 已经计入 $\widehat{M}_a$ 恰好落在左端点处的原子质量, 而右端点处的原子不计入 θ_a^+ 。这给出一个可直接核验的设计准则: 输出网格必须覆盖 $\widehat{M}_a$ 的有效支撑, 否则钳制误差随网格加密而减小。若实现中的 $\hat{F}_M$ 因数值近似 (截断、求积、钳制) 而不能保证是合法联合 CDF, 则应放弃这一概率解释, 只把 $\theta_a^\pm$ 当作引理 4 中定义的确定性越界振幅使用; 下面命题 4 的两个下界会分别标明它们依赖哪一种读法。该项与 $\varepsilon_a^{\text{grid}}$ 被相反方向的参数控制——前者要求网格区间变宽, 后者要求网格变密——在固定网格点数 G 下二者不能同时任意小。下面的命题 4 把这一说法量化为一个只依赖 G 的显式正下界。

命题 4 (固定 G 下的预算地板). 沿用引理 4 的记号, 设 $\hat{F}_M$ 关于每个坐标非降、取值于 $[0, 1]$, 关于第 a 个坐标一致 L_a -Lipschitz。定义第 a 个一维边缘为极限 $\hat{F}_{M_a}(u) := \lim_{y_{-a} \rightarrow +\infty} \hat{F}_M(u, y_{-a})$, 并设归一化条件

$$\lim_{v \rightarrow -\infty} \hat{F}_M(v, y_{-a}) = 0 \quad (\forall y_{-a}), \quad \hat{F}_{M_a}(-\infty) = 0, \quad \hat{F}_{M_a}(+\infty) = 1. \quad (8)$$

本命题不要求 $\hat{F}_M$ 是合法联合 CDF (不需要 K -增性): 它只用到上述单调性与归一化。需要强调, 这不意味着任何实现近似量都自动满足本命题的假设——截断、求积、钳制未必保持逐

坐标单调性与全局归一化 (8)；准确的说法是：若某个实现量另经核验满足上述单调性与归一化，则无须再核验 K -增性即可套用本命题。注 9 的等式 (7) 是更强假设下的加细，本证明只需要其中一个方向的不等式（见证明第一步）。则对第 a 轴上任意 $G \geq 2$ 点网格（网格位置任意，可不等距），

$$\varepsilon_a^{\text{grid}} + \varepsilon_a^{\text{bdry}} \geq \frac{1}{2(G-1)}. \quad (9)$$

若改用引理 4(ii) 的 C^2 改进式 $\varepsilon_a^{\text{grid}} = (h_a^{\text{out}})^2 B_a^{\text{out}}/8$ ，并设边缘 $\hat{F}_{M_a}$ 可微且 $\hat{F}'_{M_a}$ 是 B_a^{out} -Lipschitz 的（见下方证明第三步：这由引理 4(ii) 对各切片的假设经极限传递到边缘），则

$$\varepsilon_a^{\text{grid}} + \varepsilon_a^{\text{bdry}} \geq \frac{1}{8(G-1)^2}.$$

两个下界都与网格区间宽度、与 $\hat{F}_M$ 的具体形状无关，只由 G 决定；因此在固定 G 下这两项之和不能同时任意小，要压低预算只能增大 G 。

证明. 记 $p = \varepsilon_a^{\text{bdry}} = \theta_a^- + \theta_a^+$ ， $W = y_a^{\text{max}} - y_a^{\text{min}}$ 为网格区间宽度，并记网格内部的爬升量

$$\nu := \hat{F}_{M_a}(y_a^{\text{max}}) - \hat{F}_{M_a}(y_a^{\text{min}}).$$

第一步： $p \geq 1 - \nu$ 。这一步只用 $\theta_a^\pm$ 的定义与归一化条件 (8)，不需要 $\hat{F}_M$ 是合法联合 CDF。在 θ_a^- 的定义中，先取 y_{-a} 使其充分大、再令 $v \rightarrow -\infty$ ：由 (8) 的第一式，内层量趋于 $\hat{F}_M(y_a^{\text{min}}, y_{-a})$ ，再对 y_{-a} 取上确界（由关于 y_{-a} 的非降性，上确界即 $y_{-a} \rightarrow +\infty$ 的极限，也就是边缘）得

$$\theta_a^- \geq \hat{F}_{M_a}(y_a^{\text{min}}).$$

同理，在 θ_a^+ 的定义中取 $y_{-a} \rightarrow +\infty$ 与 $v \rightarrow +\infty$ ，由 $\hat{F}_{M_a}(+\infty) = 1$ 得 $\theta_a^+ \geq 1 - \hat{F}_{M_a}(y_a^{\text{max}})$ 。两式相加即

$$p \geq \hat{F}_{M_a}(y_a^{\text{min}}) + 1 - \hat{F}_{M_a}(y_a^{\text{max}}) = 1 - \nu.$$

若额外假设 $\hat{F}_M$ 是合法联合 CDF，则注 9 的 (7) 把这两个不等式加强为等式，从而 $p = 1 - \nu$ ；本证明不需要这一加强，只需上面的 $\geq$ 方向。由 $\hat{F}_{M_a}$ 取值于 $[0, 1]$ 且非降，有 $\nu \in [0, 1]$ ， $p \geq 1 - \nu \geq 0$ 。

第二步： *Lipschitz 情形*。一个 L_a -Lipschitz 函数在长度 W 的区间上的总变差不超过 $L_a W$ ，故 $L_a W \geq \nu$ ，即

$$L_a \geq \frac{\nu}{W}.$$

另一方面 G 个点把长度 W 的区间分成 $G - 1$ 段，最大段长满足 $h_a^{\text{out}} \geq W/(G - 1)$ 。两式相乘， W 恰好抵消，再用第一步的 $p \geq 1 - \nu$ ：

$$\varepsilon_a^{\text{grid}} + \varepsilon_a^{\text{bdry}} = \frac{1}{2} L_a h_a^{\text{out}} + p \geq \frac{\nu}{2(G-1)} + (1 - \nu) \geq \frac{1}{2(G-1)},$$

最后一步因为 $\nu \mapsto \frac{\nu}{2(G-1)} + (1 - \nu)$ 关于 ν 非增（ $G \geq 2$ 时斜率 $\frac{1}{2(G-1)} - 1 \leq 0$ ），在 $\nu = 1$ 处取最小值 $\frac{1}{2(G-1)}$ 。

第三步： C^2 情形。先说明边缘为何继承二阶界。引理 4(ii) 的假设是 $|\partial_{y_a}^2 \hat{F}_M| \leq B_a^{\text{out}}$ 一致成立，等价于每个切片 $f_{y_{-a}}(u) := \hat{F}_M(u, y_{-a})$ 满足二阶差分界

$$|f_{y_{-a}}(u+h) + f_{y_{-a}}(u-h) - 2f_{y_{-a}}(u)| \leq B_a^{\text{out}} h^2, \quad \forall u \in \mathbb{R}, h > 0.$$

边缘 $\hat{F}_{M_a}$ 是这族切片在 $y_{-a} \rightarrow +\infty$ 时的逐点极限（不是平均），而上式对逐点极限保持，故 $\hat{F}_{M_a}$ 也满足同一个二阶差分界。于是 $u \mapsto \hat{F}_{M_a}(u) + \frac{1}{2} B_a^{\text{out}} u^2$ 中点凸、 $u \mapsto \hat{F}_{M_a}(u) - \frac{1}{2} B_a^{\text{out}} u^2$ 中点凹； $\hat{F}_{M_a}$ 单调故可测，中点凸（凹）加可测即凸（凹）。比较二者的单侧导数得：对任意 $u < u'$ ， $|\hat{F}'_{M_a}(u') - \hat{F}'_{M_a}(u)| \leq B_a^{\text{out}}(u' - u)$ ，这同时迫使左右导数重合。故 $\hat{F}_{M_a}$ 可微且 $\hat{F}'_{M_a}$ 是 B_a^{out} -Lipschitz 的，且由非降性 $\hat{F}'_{M_a} \geq 0$ 。记 $s = \sup_{\mathbb{R}} \hat{F}'_{M_a} \in [0, +\infty]$ 。

先排除 $B_a^{\text{out}} = 0$ ：此时 $\hat{F}'_{M_a}$ 是 0-Lipschitz 的，即恒等于某个常数 $c \geq 0$ ，于是 $\hat{F}_{M_a}(u) = \hat{F}_{M_a}(0) + cu$ ； $c = 0$ 给出常值函数、 $c > 0$ 给出无界函数，两者都与归一化 $\hat{F}_{M_a}(-\infty) = 0$ 、 $\hat{F}_{M_a}(+\infty) = 1$ 矛盾。故 $B_a^{\text{out}} > 0$ ，下面可以除以它。若 $\nu = 0$ ，则待证的 $B_a^{\text{out}} \geq \nu^2/W^2$ 自动成立，故以下设 $\nu > 0$ 。

上确界未必取到，故取一列 $y_n \in \mathbb{R}$ 使 $s_n := \hat{F}'_{M_a}(y_n) \uparrow s$ ，并对每个有限的 s_n 做估计。由 $\hat{F}'_{M_a}$ 的 B_a^{out} -Lipschitz 性，对 $|y - y_n| \leq s_n/B_a^{\text{out}}$ 有 $\hat{F}'_{M_a}(y) \geq s_n - B_a^{\text{out}}|y - y_n| \geq 0$ ，该三角形的面积为 s_n^2/B_a^{out} 。关键在于这个三角形未必落在网格区间内，因此只能用 $\hat{F}'_{M_a}$ 在整条实轴上的积分来控制它，而不是用网格内部的爬升量 ν ：

$$\frac{s_n^2}{B_a^{\text{out}}} \leq \int_{\mathbb{R}} \hat{F}'_{M_a}(y) dy = \hat{F}_{M_a}(+\infty) - \hat{F}_{M_a}(-\infty) = 1, \quad \text{即} \quad s_n \leq \sqrt{B_a^{\text{out}}}.$$

令 $n \rightarrow \infty$ 得 $s \leq \sqrt{B_a^{\text{out}}} < \infty$ 。（若改用 ν 作右端就需要额外假设该三角形被网格区间包含，那不是现有假设的推论；这也是本证明与只用 Lipschitz 常数的第二步的区别所在。）另一方面由均值定理 $s \geq \nu/W$ 。两式合并消去 s ：

$$B_a^{\text{out}} \geq s^2 \geq \frac{\nu^2}{W^2}.$$

代入 $h_a^{\text{out}} \geq W/(G-1)$ 并用 $p \geq 1 - \nu$ ， W 同样抵消：

$$\frac{(h_a^{\text{out}})^2 B_a^{\text{out}}}{8} + p \geq \frac{W^2}{(G-1)^2} \cdot \frac{\nu^2}{W^2} \cdot \frac{1}{8} + (1 - \nu) = \frac{\nu^2}{8(G-1)^2} + (1 - \nu) \geq \frac{1}{8(G-1)^2},$$

最后一步同样在 $\nu = 1$ 处取最小值： $\nu \mapsto \frac{\nu^2}{8(G-1)^2} + (1 - \nu)$ 在 $[0, 1]$ 上的导数为 $\frac{\nu}{4(G-1)^2} - 1 \leq 0$ ($G \geq 2$ 时 $\frac{1}{4(G-1)^2} \leq \frac{1}{4}$)，故在 $\nu = 1$ 处最小。此处未追求常数最优：结论只需下界为正且以 $\Omega(1/G^2)$ 的阶随 G 衰减，这正是本命题的全部内容。□

注 10 (这是预算项的下界，不是真实误差的下界)。命题 4 约束的是引理 4 中被定义为 $\frac{1}{2}L_a h_a^{\text{out}}$ 与 $\theta_a^- + \theta_a^+$ 的两个预算项，而不是实际发生的插值与钳制误差。后者可以为零：取 $M_a \sim \text{Uniform}[0, 1]$ 、两点网格 $\mathcal{Y}_a = \{0, 1\}$ ，则 $\hat{F}_{M_a}$ 在 $[0, 1]$ 上是线性的，分段线性插值完全精确，区间外的常数外延也恰好等于真实 CDF，真实误差为 0；而预算项给出 $\frac{1}{2} \cdot 1 \cdot 1 + 0 = \frac{1}{2}$ ，恰好等于 (9) 在 $G = 2$ 时的值 $\frac{1}{2}$ 。这说明：(i) 下界 (9) 是紧的；(ii) 在 $\hat{F}_M$ 恰好分段线性且与网格对齐这类特殊情形下，预算远不紧，此时应直接使用真实误差而非本预算。一般情形下 $\hat{F}_M$ 的形状事先未知，预算才是可用的量，命题 4 说明它必然带有一个与 G 有关的非零地板。需要区分两种预算：使用 Lipschitz 插值项 $\frac{1}{2}L_a h_a^{\text{out}}$ 时地板为 $\Omega(G^{-1})$ ；改用二阶插值项 $(h_a^{\text{out}})^2 B_a^{\text{out}}/8$ 时，当前证明给出的地板是 $\Omega(G^{-2})$ 。两者阶数不同，不能笼统合写成 $\Omega(1/G)$ 。

定理 4 (完整单层 CDF 误差预算)。设假设 1 与 2 成立， $D_1, \dots, D_K$ 互相独立，各轴求积权重非负且归一。设 $\hat{F}_M$ 是按定理 3 的局部投影近似与 TTNS 收缩得到的中间 CDF 近似，取值于 $[0, 1]$ ，并设它关于第 a 个坐标一致 $\hat{L}_a$ -Lipschitz。按定义 2 令实际数值结果为 $\tilde{F}_Y = \tilde{\mathcal{A}}\hat{F}_M$ ，并记 $\theta_a^\pm = \theta_a^\pm(\hat{F}_M)$ 。则对每个 y ，

$$|F_Y(y) - \tilde{F}_Y(y)| \leq \varepsilon^{\text{loc}}(y) + \varepsilon^{\text{nq}} + \varepsilon^{\text{grid}} + \varepsilon^{\text{bdry}},$$

其中

$$\begin{aligned}
\varepsilon^{\text{loc}}(y) &= \sup_t \sum_{k=1}^d \mathbb{E}_k(y, t) \|S_k(u_{-k}^{\text{hyb}}(y, t))\|_{\infty} \quad (\text{截断} + \text{局部求积} + \text{edge CDF 近似}), \\
\varepsilon^{\text{nq}} &= \sum_{a=1}^K \widehat{L}_a \varrho_a(n_D) \quad (\text{外层 node-delay 求积}), \\
\varepsilon^{\text{grid}} &= \sum_{a=1}^K \frac{1}{2} \widehat{L}_a h_a^{\text{out}} \quad (\text{逐轴卷积中的输出网格插值}), \\
\varepsilon^{\text{bdry}} &= \sum_{a=1}^K [\theta_a^- + \theta_a^+] \quad (\text{网格外求值的钳制 / 常数外延}).
\end{aligned}$$

若最终还需把 $\widetilde{F}_Y$ 从输出网格插值到其他求值点，且该插值算子的一致误差为 ε^{itp} ，则右侧再加上 ε^{itp} 。

证明. 记 $\mathcal{A} = \bigotimes_a \mathcal{K}_{\widehat{\mu}_a}^{(a)}$ 、 $\widehat{\mathcal{A}} = \bigotimes_a \mathcal{K}_{\widehat{\mu}_a}^{(a)}$ 。理想算子沿不同轴作用，故互相交换，可写成任意顺序的复合；特别取 $\widehat{\mathcal{A}} = \mathcal{K}_{\widehat{\mu}_K}^{(K)} \circ \dots \circ \mathcal{K}_{\widehat{\mu}_1}^{(1)}$ 。由命题 1， $F_Y = \mathcal{A}F_M$ 。作三段分解

$$F_Y - \widetilde{F}_Y = \underbrace{\mathcal{A}(F_M - \widehat{F}_M)}_{\text{(I)}} + \underbrace{(\mathcal{A} - \widehat{\mathcal{A}})\widehat{F}_M}_{\text{(II)}} + \underbrace{(\widehat{\mathcal{A}} - \widetilde{\mathcal{A}})\widehat{F}_M}_{\text{(III)}}.$$

(I) 由引理 2， $\mathcal{A}$ 是若干非扩张算子之复合，故 $\|\mathcal{A}(F_M - \widehat{F}_M)\|_{\infty} \leq \|F_M - \widehat{F}_M\|_{\infty}$ 。而 $F_M - \widehat{F}_M$ 在每个求值点上正是推论 2 中 t 固定时的被积量，故被 $\varepsilon^{\text{loc}}(y)$ 控制。

(II) 沿坐标轴做算子 telescoping,

$$\mathcal{A} - \widehat{\mathcal{A}} = \sum_{a=1}^K \left(\prod_{b < a} \mathcal{K}_{\widehat{\mu}_b}^{(b)} \right) \left(\mathcal{K}_{\widehat{\mu}_a}^{(a)} - \mathcal{K}_{\widehat{\mu}_a}^{(a)} \right) \left(\prod_{b > a} \mathcal{K}_{\widehat{\mu}_b}^{(b)} \right).$$

每一项中前缀与后缀都非扩张（引理 2；此处用到 $\widehat{\mu}_b$ 是概率测度），中间因子由引理 3 控制为 $\widehat{L}_a \varrho_a(n_D)$ ——注意后缀算子作用于 $\widehat{F}_M$ 后仍关于第 a 坐标 $\widehat{L}_a$ -Lipschitz，因为沿其他轴的卷积是关于该坐标的逐点平均。对 a 求和得 ε^{nq} 。

(III) 同样做 telescoping，但这次前缀取实现算子、后缀取理想算子：

$$\widehat{\mathcal{A}} - \widetilde{\mathcal{A}} = \sum_{a=1}^K \left(\prod_{b > a} \mathcal{K}_{\widehat{\mu}_b}^{(b)} \right) \left(\mathcal{K}_{\widehat{\mu}_a}^{(a)} - \widetilde{\mathcal{K}}_a \right) \left(\prod_{b < a} \widetilde{\mathcal{K}}_b \right),$$

其中两侧的乘积分别按下标递减与递增复合。直接验证： $K = 2$ 时右侧为 $\mathcal{K}_{\widehat{\mu}_2}(\mathcal{K}_{\widehat{\mu}_1} - \widetilde{\mathcal{K}}_1) + (\mathcal{K}_{\widehat{\mu}_2} - \widetilde{\mathcal{K}}_2)\widetilde{\mathcal{K}}_1$ ，两个交叉项相消后即为 $\widehat{\mathcal{A}} - \widetilde{\mathcal{A}}$ ；一般 K 同理。

对第 a 项，令 $H_a = (\prod_{b < a} \widetilde{\mathcal{K}}_b) \widehat{F}_M$ 。由引理 4(i)，每个 $\widetilde{\mathcal{K}}_b$ ($b \neq a$) 都不增大关于第 a 坐标的 Lipschitz 常数，也不增大 $\theta_a^{\pm}$ ，故

$$H_a \text{ 关于第 } a \text{ 坐标 } \widehat{L}_a\text{-Lipschitz}, \quad \theta_a^{\pm}(H_a) \leq \theta_a^{\pm}(\widehat{F}_M) = \theta_a^{\pm};$$

又因平均算子保持取值范围， H_a 仍取值于 $[0, 1]$ 。于是引理 4(ii) 给出

$$\|(\mathcal{K}_{\widehat{\mu}_a}^{(a)} - \widetilde{\mathcal{K}}_a)H_a\|_{\infty} \leq \frac{1}{2} \widehat{L}_a h_a^{\text{out}} + \theta_a^- + \theta_a^+.$$

外层前缀 $\prod_{b > a} \mathcal{K}_{\widehat{\mu}_b}^{(b)}$ 非扩张（引理 2）。对 a 求和得 $\varepsilon^{\text{grid}} + \varepsilon^{\text{bdry}}$ 。

把 (I)(II)(III) 三项相加即得结论。最后一句关于 ε^{itp} 的断言是一次额外的三角不等式。□

注 11 (四项误差的独立可控性并不对称). ε^{loc} 由局部积分区间与局部步长控制, ε^{ng} 由 n_D 控制, 二者可独立加细。但 $\varepsilon^{\text{grid}}$ 与 $\varepsilon^{\text{bdry}}$ 共用同一个输出网格: 在网格点数 G 固定时, h_a^{out} 与网格区间宽度 $y_a^{\text{max}} - y_a^{\text{min}}$ 成正比, 故两项之和存在非零下界 (定量下界见命题 4; $\theta_a^\pm$ 的概率含义见注 9)。要同时压小这两项, 只能增大 G , 而全表代价按 G^K 增长——这正是第 5 节树宽分析要量化的对象。

注 12 (Lipschitz 常数的来源). $\hat{L}_a$ 可由 M_a 的密度上界控制: 若 F_M 关于 y_a 的偏导 (即 M_a 的边缘密度上界) 不超过 L_a , 则精确量满足该 Lipschitz 条件; 数值近似 $\hat{F}_M$ 的常数 $\hat{L}_a$ 可由基函数与 edge CDF 的光滑性直接估计。若 edge delay 有有界密度, 则 $\max_k (X_k + E_{ka})$ 的密度也有界, 该条件自动满足。

推论 3 (单层收敛性). 在定理 4 的假设下, 考虑一系列离散化方案, 并设它们满足下列全部条件:

(C1) 局部积分区间 $I_{k,i} = [\alpha_{k,i}, \beta_{k,i}] \uparrow \mathbb{R}$ 使尾部项 $\sup_{y,t} \tau_{k,i}(y, t) \rightarrow 0$;

(C2) 局部梯形项整体趋零, 即

$$\sup_{y,t} [(\beta_{k,i} - \alpha_{k,i}) h_{k,i}^2 B_{k,i}^{(2)}(y, t)] \rightarrow 0,$$

而不只是 $h_{k,i} \rightarrow 0$ ——因为区间长度 $\beta_{k,i} - \alpha_{k,i}$ 在 (C(C1)) 下趋于无穷, 两者之积未必趋零;

(C3) edge CDF 近似误差 $\sup_{y,t} \varepsilon_{k,i,a}^{\text{cdf}}(y, t) \rightarrow 0$;

(C4) 下列各量在整个精化过程中一致有界: 梯形权重下的基函数绝对质量 $\Lambda_{k,i}$, sensitivity 范数 $\sup_{y,t} \|S_k(u_{-k}^{\text{hyb}}(y, t))\|_\infty$, 以及各轴的 Lipschitz 常数 $\hat{L}_a$;

(C5) 外层求积满足 $\varrho_a(n_D) \rightarrow 0$;

(C6) 输出网格同时加密并扩张, 即 $h_a^{\text{out}} \rightarrow 0$ 且 $\theta_a^- + \theta_a^+ \rightarrow 0$ 。

则

$$\sup_y |F_Y(y) - \tilde{F}_Y(y)| \rightarrow 0.$$

更精确地,

$$\sup_y |F_Y(y) - \tilde{F}_Y(y)| = O\left(\tau + \bar{h}^2 + \varepsilon^{\text{cdf}} + \max_a \varrho_a(n_D) + \max_a h_a^{\text{out}} + \max_a [\theta_a^- + \theta_a^+]\right),$$

其中 $\tau = \max_{k,i} \sup_{y,t} \tau_{k,i}$, $\varepsilon^{\text{cdf}} = \max_{k,i,a} \sup_{y,t} \varepsilon_{k,i,a}^{\text{cdf}}$, 而

$$\bar{h}^2 = \max_{k,i} \sup_{y,t} [(\beta_{k,i} - \alpha_{k,i}) h_{k,i}^2 B_{k,i}^{(2)}(y, t)]$$

是 (C(C2)) 中的复合量。若还希望把外层项写成显式速率 $\max_a \varrho_a(n_D) = O(n_D^{-1})$, 必须额外引用注 8 的条件 (μ_a 的分位数函数满足 $Q' \in L^p([0, 1])$, 某个 $p > 1$); 仅有有限一阶矩是不够的。若 $\hat{F}_M$ 关于第 a 坐标为 C^2 且二阶偏导一致有界, 则 h_a^{out} 一项可改进为 $(h_a^{\text{out}})^2$ 。

证明. 把各项代入定理 4 的右侧。

ε^{loc} : 由 (C(C1))–(C(C3)), E_k 的三项分别是 $O(\tau)$ 、 $O(\bar{h}^2)$ 、 $O(\varepsilon^{\text{cdf}})$, 其中第二项的系数是 $1/12$ 、第三项的系数是 $\Lambda_{k,i}$ 。由 (C(C4)), 这些系数与 $\|S_k\|_\infty$ 一致有界, 故 ε^{loc} 被 $O(\tau + \bar{h}^2 + \varepsilon^{\text{cdf}})$ 控制, 且常数与离散化参数无关。这里必须保留 (C(C2)) 的复合形式: 要把 $(\beta_{k,i} - \alpha_{k,i}) h_{k,i}^2 B_{k,i}^{(2)}$ 写成 $O(h_{k,i}^2)$, 需要区间长度与二阶导界都一致有界, 而 (C(C1)) 恰恰使区间长度发散。

ε^{ng} : 由 (C(C4)) 与 (C(C5)), $\sum_a \hat{L}_a \varrho_a(n_D) = O(\max_a \varrho_a(n_D))$ 。

$\varepsilon^{\text{grid}} + \varepsilon^{\text{bdry}}$: 由 (C(C4)) 与 (C(C6)), $\sum_a \frac{1}{2} \hat{L}_a h_a^{\text{out}} = O(\max_a h_a^{\text{out}})$ 且 $\sum_a [\theta_a^- + \theta_a^+] = O(\max_a [\theta_a^- + \theta_a^+])$ 。 C^2 情形的改进直接来自引理 4(ii) 的第二个界。

四项之和趋零, 即得结论。 $\square$

注 13 (一致性条件不是形式上的赘述). (C(C4)) 中的三个量都可能随精化而发散, 因此不能省略。\$\Lambda_{k,i}\$ 是 \$|b_{k,i}|\$ 在 \$I_{k,i}\$ 上的梯形近似质量, 若 \$I_{k,i} \uparrow \mathbb{R}\$ 而 \$b_{k,i}\$ 不绝对可积, 它会发散; \$\|S_k\|_\infty\$ 由其余坐标的投影向量决定, 注 1 给出的 \$|M_{k,i}| \leq \int |b_{k,i}|\$ 只在 \$b_{k,i}\$ 绝对可积时是一致界; \$\hat{L}_a\$ 由 edge CDF 与基函数的光滑性决定, 若近似 CDF 在精化中变陡 (例如逼近阶跃), 它同样发散。(C(C6)) 的两半互相牵制: 网格点数固定时不能同时实现, 见注 11 与 9。因此本推论是一个条件性收敛结论, 不应读作“加密网格必然收敛”。

注 14 (二阶率的前提). 上式中 \$\bar{h}^2\$ 的二阶依赖来自 \$f_{k,i}\$ 在 \$I_{k,i}\$ 上的 \$C^2\$ 光滑性与二阶导界。若 edge CDF 只是分段光滑 (例如 uniform delay 的 CDF 在端点处一阶导不连续), 或基函数为低次样条, 则复合梯形公式的实际阶可能低于二阶。此外, \$\varepsilon^{\text{grid}}\$ 在只有 Lipschitz 假设时是一阶 \$O(h_a^{\text{out}})\$, 故即使局部求积达到二阶, 整体也可能被输出网格插值项压到一阶。因此不应在未核实验光滑性时宣称二阶收敛。

注 15 (与已有数值证据的一致性). 仓库中的数值验证报告给出: 固定输出网格与 \$q_{\text{grid}}\$ 时, pair CDF 相对高分辨率参考的最大绝对误差随 \$n_d\$ 增大从 \$5.75 \times 10^{-3}\$ (\$n_d = 2\$) 降至 \$4.33 \times 10^{-6}\$ (\$n_d = 16\$) 后出现平台。这与定理 4 的结构相容: 四项中只有 \$\varepsilon^{\text{na}} = \sum_a \hat{L}_a \varrho_a(n_D)\$ 随 \$n_D\$ 下降, 而 \$\varepsilon^{\text{loc}}\$、\$\varepsilon^{\text{grid}}\$、\$\varepsilon^{\text{bdry}}\$ 都与 \$n_D\$ 无关, 故总误差在外层项降到其余三项之和以下后不再下降。但必须强调: 上界的分解只能说明该现象与误差分解所预测的多误差源竞争相容, 不能据此断定平台一定由某一项造成。插值误差、边界钳制、浮点舍入以及不同误差项之间的符号抵消都可能产生平台; 区分它们需要逐项独立扫描 (固定 \$n_D\$ 改变 \$G\$、固定 \$G\$ 改变局部积分区间等), 而不是仅凭一条上界。该数值现象同样不能反过来用于宣称一般收敛阶。

5 联合结构图的树宽与可计算代价

定理 1 给出了精确收缩公式, 但没有回答“代价是多少”。命题 1 只解决了 node delay 一项, \$F_M\$ 在整个输出网格上的取值仍可能是指数的。本节说明: 真正的判据既不是上游树 \$T\$ 单独给出, 也不是父集合族 \$\{P_a\}\$ 单独给出, 而是二者合成的一张图的树宽。

5.1 离散化后的张量网络形式

固定每个上游坐标 \$k\$ 的一维求积公式: 节点 \$x_1^{(k)}, \dots, x_q^{(k)}\$, 权重 \$w_1^{(k)}, \dots, w_q^{(k)}\$ (为记号简洁取统一点数 \$q\$, 非统一情形只需把 \$q\$ 理解为 \$\max_k q_k\$)。输出网格在每个坐标轴上取 \$G\$ 个点 \$y_1^{(a)}, \dots, y_G^{(a)}\$。

定义 3 (投影 core). 对每个 \$k\$ 定义

$$\tilde{G}_{j,(\alpha_e)_{e \in \delta_T(k)}}^{(k)} = \sum_{i=1}^{m_k} G_{i,(\alpha_e)_{e \in \delta_T(k)}}^{(k)} w_j^{(k)} b_{k,i}(x_j^{(k)}), \quad j = 1, \dots, q.$$

预计算全部投影 core 的代价为 \$O(\sum_k q m_k \prod_{e \in \delta_T(k)} r_e)\$。

引理 5 (离散化 \$F_M\$ 的张量网络展开). 把定理 1 中每个局部投影 \$M_{k,i}\$ 的一维积分用上述求积公式代替, 所得的离散化中间 CDF 满足

$$\hat{F}_M(y) = \sum_{j_1=1}^q \cdots \sum_{j_d=1}^q \sum_{(\alpha_e)_{e \in E(T)}} \prod_{k=1}^d \tilde{G}_{j_k,(\alpha_e)_{e \in \delta_T(k)}}^{(k)} \prod_{a=1}^K \prod_{k \in P_a} F_{ka}(y_a - x_{j_k}^{(k)}).$$

证明. 把 \$M_{k,i}(y) \approx \sum_j w_j^{(k)} b_{k,i}(x_j^{(k)}) \prod_{a \in H_k} F_{ka}(y_a - x_j^{(k)})\$ 代入 \$\mathcal{C}_T(M_1(y), \dots, M_d(y))\$, 展开系数张量 \$A_{i_1 \dots i_d} = \sum_{(\alpha_e)} \prod_k G_{i_k,(\alpha_e)}^{(k)}\$, 先对每个 \$i_k\$ 求和得到定义 3 的 \$\tilde{G}^{(k)}\$, 再把 \$\prod_k \prod_{a \in H_k} = \prod_a \prod_{k \in P_a}\$ 按下游坐标重排即得。□

引理 5 的右侧是一个标准的 sum-product 表达式。它的 变量为

$$\xi_k \in [q] \ (k = 1, \dots, d), \quad \alpha_e \in [r_e] \ (e \in E(T)), \quad v_a \in [G] \ (a = 1, \dots, K),$$

因子为投影 core $\tilde{G}^{(k)}$ (scope 为 $\{\xi_k\} \cup \{\alpha_e : e \in \delta_T(k)\}$) 与 edge-CDF 因子

$$\Phi_{ka}(\xi_k, v_a) = F_{ka}(y_{v_a}^{(a)} - x_{\xi_k}^{(k)}), \quad k \in P_a$$

(scope 为 $\{\xi_k, v_a\}$)。

5.2 联合结构图

定义 4 (联合结构图). 设 $S \subseteq \{1, \dots, K\}$, $|S| = s$ 。称无向图 $\mathcal{G}_S = (V_{\mathcal{G}}, E_{\mathcal{G}})$ 为该 max-plus 层关于 S 的 **联合结构图**, 其中

$$V_{\mathcal{G}} = \{\xi_k\}_{k=1}^d \sqcup \{\alpha_e\}_{e \in E(T)} \sqcup \{v_a\}_{a \in S},$$

$E_{\mathcal{G}}$ 由如下两族团 (clique) 的并给出:

- (i) 对每个 k , $\{\xi_k\} \cup \{\alpha_e : e \in \delta_T(k)\}$ 构成一个团;
- (ii) 对每个 $a \in S$ 与每个 $k \in P_a$, $\{\xi_k, v_a\}$ 是一条边。

即 $\mathcal{G}_S$ 是引理 5 中因子图的 primal graph。进一步记 $\mathcal{G}_S^+$ 为在 $\mathcal{G}_S$ 中额外把 $\{v_a\}_{a \in S}$ 补成团后所得的图。

定义 4 的第 (i) 类团来自树 T 的 core 结构, 第 (ii) 类边来自父集合族 $\{P_a\}$ 。二者缺一不可: 只看 T 会漏掉 reconvergent fan-out 造成的下游耦合, 只看 $\{P_a\}$ 会漏掉 bond 结构造成的 core 代价。这也是本文中树结构第一次真正进入结论而不只是记号。

注 16 (与简化形式的关系). 若把每个 α_e 视为树边 e 的细分点并加以压缩, 则 $\mathcal{G}_S$ 收缩为顶点集 $\{1, \dots, d\} \sqcup \{a' : a \in S\}$ 、边集 $E(T) \cup \{\{k, a'\} : k \in P_a\}$ 的图。该简化形式便于画图与直觉判断, 但它抹掉了 hub 节点的 core 代价: $\mathcal{G}_S$ 中 ξ_k 与其全部 bond 变量构成团, 故

$$\text{tw}(\mathcal{G}_S) \geq \deg_T^{\max},$$

这正对应 core 的 $r^{\deg_T^{\max}}$ 存储与收缩代价。下文一律使用定义 4 的完整形式。

5.3 主复杂度定理

本节起沿用 (4) 定义的最大 bond dimension r ($E(T) = \emptyset$ 时 $r = 1$) 与最大物理维 $m = \max_{1 \leq k \leq d} m_k$, 并记

$$W = \max\{q, r, m, G\}, \quad (10)$$

其中 q 是每个上游坐标的局部求积节点数、 G 是每个输出轴的网格点数。 W 是本节所有变量域大小的统一上界。

定理 5 (联合 CDF 的树宽复杂度). 设 $S \subseteq \{1, \dots, K\}$, $|S| = s$, 并对 $a \notin S$ 取 $y_a = +\infty$ (即只求 S 上的边缘联合 CDF)。设已给定 $\mathcal{G}_S^+$ 的一个宽度为 w 的树分解。则整个 G^s 输出网格上 $\hat{F}_M^S$ 的全部取值可在

$$O\left(\underbrace{\sum_k q m_k \prod_{e \in \delta_T(k)} r_e}_{\text{投影 core 预计算}} + \underbrace{(d + |E(T)| + \sum_{a \in S} |P_a|) \cdot W^{w+1}}_{\text{sum-product 收缩}}\right)$$

次算术运算内算出, 内存为 $O((d+s)W^{w+1})$ 。若进一步需要含 node delay 的 $\hat{F}_Y^S$, 由命题 1 只需再加 $O(s n_D G^s)$ 。特别地, 取 $w = \text{tw}(\mathcal{G}_S^+)$ 并用 (10) 的 W 一并控制两项, 得到

$$O\left(\text{poly}(d, K) \cdot W^{\text{tw}(\mathcal{G}_S^+)+2} + s n_D G^s\right). \quad (11)$$

注 17 (为什么简写中的指数是 $\text{tw}+2$ 而不是 $\text{tw}+1$). sum-product 项本身是 W^{w+1} , 但投影 core 预计算项不能被 $W^{\text{tw}+1}$ 控制。取 $q = m = r = W$ 与某节点度数 $\Delta = \deg_T(k)$, 该节点的预计算代价为 $q m_k \prod_{e \in \delta_T(k)} r_e = W^{\Delta+2}$; 而联合结构图只保证 $\text{tw}(\mathcal{G}_S) \geq \deg_T^{\max}$ (注 16), 故在 $\text{tw} = \Delta$ 时 $W^{\text{tw}+1} = W^{\Delta+1}$ 恰好少一个 W 因子。由 $\Delta \leq \deg_T^{\max} \leq \text{tw}(\mathcal{G}_S) \leq \text{tw}(\mathcal{G}_S^+)$ 得 $W^{\Delta+2} \leq W^{\text{tw}(\mathcal{G}_S^+)+2}$, 于是 (11) 的 $\text{tw}+2$ 同时控制两项。

因此本文的规范是：凡需要精确复杂度处一律引用定理 5 的分项表达式；(11) 只用于口头概述。若在特定设定下把 q 或 m 视为与 W 无关的固定常数，或把 qm 整体视为单一基数，则可以恢复 $\text{tw}+1$ ；本文不作这类假设。

证明. 由引理 5, 去掉 $a \notin S$ 的因子 ($F_{ka}(+\infty) = 1$) 后, $\hat{F}_M^S$ 是上述因子集合关于变量 $\{\xi_k\} \cup \{\alpha_e\}$ 的 sum-product , $\{v_a\}_{a \in S}$ 为自由指标。由定义 4, 每个因子的 scope 在 $\mathcal{G}_S$ (从而在 $\mathcal{G}_S^+$) 中是一个团, 故在任意树分解中都存在包含该 scope 的 bag , 可以把每个因子指派给这样一个 bag 。于是标准的 $\text{bucket elimination}$ / junction tree 算法适用：以任一 bag 为根, 按后序对每条树分解边计算一条消息；每条消息的计算是在其 bag 上枚举全部赋值、乘入该 bag 的因子与已到达的子消息、再对不在父 bag 中的变量求和, 代价 $O(W^{|\text{bag}|}) \leq O(W^{w+1})$, 乘入因子的次数总计为因子个数 $d + \sum_{a \in S} |P_a|$, 边数 $|E(T)|$ 体现在 bond 变量个数上。 bag 个数可取为 $O(|V_G|) = O(d + s)$, 故总代价与内存如式所示。

由于 $\mathcal{G}_S^+$ 中 $\{v_a\}_{a \in S}$ 是团, 必存在包含全部 v_a 的 bag ; 取它为根, 则根处得到的正是 G^s 维输出数组, 无需额外重组。最后的 node-delay 项即推论 1 在 s 个轴上的形式。 $\square$

注 18 (两个方向的紧性). 定理 5 的指数在两个方向上都被卡住, 但两侧的含义不同：

- (1) **下界.** $\mathcal{G}_S^+$ 含 s 个顶点的团, 故 $\text{tw}(\mathcal{G}_S^+) \geq s - 1$, 于是 $W^{\text{tw}+1} \geq G^s$ 。这与“输出数组本身就有 G^s 个元素”的平凡下界一致, 说明定理 5 在 s 这一维度上不可改进。必须强调这一侧只是输出规模下界：它由人为加入的输出团得到, 与实例的真实收缩难度无关。本文不主张任何形式的 treewidth 复杂度下界——特殊的因子取值即使联合图树宽很高也可能容易收缩 (例如全体因子恒等于常数), 因此“树宽刻画实际复杂度”这类说法在本文证明的范围之外。
- (2) **上界.** 取树 T 自身的自然树分解 ($\text{bag } \{\xi_k\} \cup \{\alpha_e : e \in \delta_T(k)\}$, 宽度 $\deg_T^{\max}$), 再把全部 s 个 v_a 加进每个 bag , 即得

$$\text{tw}(\mathcal{G}_S^+) \leq \deg_T^{\max} + s.$$

代入定理 5 恰好还原“对 G^s 个输出点各做一次树收缩”的朴素算法。因此定理 5 的内容不是“总能更快”, 而是给出一个介于朴素算法与结构可分离情形之间的连续判据。

推论 4 (不显式材料化整表时的代价). 若所需的不是 G^s 全表, 而是

- (a) 任意单点值 $\hat{F}_M^S(y)$,
- (b) 任意可分离泛函 $\sum_y \prod_{a \in S} g_a(y_a) \hat{F}_M^S(y)$,
- (c) 或任意落在同一 bag 内的低维边缘,

则可以去掉 $\{v_a\}$ 上的团, 代价的 sum-product 项降为 $O(\text{poly}(d, K) \cdot W^{\text{tw}(\mathcal{G}_S)+1})$ (投影 core 预计算项不变, 按注 17 与之合并后为 $W^{\text{tw}(\mathcal{G}_S)+2}$)。此时 $\text{tw}(\mathcal{G}_S)$ 可以远小于 s : 例如 T 为路径、 $P_a = \{a, a+1\}$ (局部 fan-in 、无长程 reconvergence) 时 $\mathcal{G}_S$ 是梯形图, $\text{tw}(\mathcal{G}_S) = O(1)$, 代价对 s 是多项式而非指数。

证明. 情形 (a) 把每个 v_a 固定为常数, 等价于删去这些变量；情形 (b) 把因子 $g_a(y_{v_a}^{(a)})$ 乘入任一含 v_a 的 bag 后对 v_a 求和；情形 (c) 以该 bag 为根。三种情形都不要求 $\{v_a\}_{a \in S}$ 同时出现在一个 bag 中, 故只需 $\mathcal{G}_S$ 的树分解。其余同定理 5 的证明。 $\square$

注 19 (树宽本身的计算与非平凡性). 精确计算 $\text{tw}(\mathcal{G}_S)$ 是 NP-难的, 定理 5 是“给定一个树分解即可达到”的条件性上界; 实践中用 min-fill、min-degree 等启发式即可得到可用的消去序。另一方面, 一般 DAG 上最长路 (PERT / SSTA 意义下的 project completion time) 分布的精确计算是难的: Hagstrom [16] 证明了在 edge 长度取离散随机变量时该问题是 #P-完全的 (经网络可靠性问题的归约), Ando [2] 把 #P-难性推广到 i.i.d. 连续 edge 长度。因此定理 1 的精确可计算性并不平凡: 它依赖两个额外结构, 即上游密度具有树张量网络表示, 以及 $\mathcal{G}_S$ 的树宽有界。定理 5 的作用正是把这两个条件量化为单一参数。

注 20 (与 treewidth-parameterized 最长路算法的关系). Ando [2, Theorem 1.10] 给出了一个以树宽为参数的算法: 当 edge 长度 i.i.d. 服从 $[0, 1]$ (或 $[-1, 0]$) 上均匀分布时, 给定宽度为 k 的树分解, s - t 最长 / 最短路长度的分布函数可在 $O(n^{2k^2+2k+2})$ 内算出, 其中 k 是底层无向图的树宽。该结果与定理 5 处理的是不同问题, 需明确区分:

- (1) **对象不同**. [2] 计算单个标量量 $\max_{\pi} \sum_{e \in \pi} X_e$ 的一维分布函数, s, t 固定; 本文计算的是 s 个下游输出的联合 CDF F_Y^S , 并允许 $s > 1$ 。 $s = 1$ 时两者才在同一量纲上, $s \geq 2$ 时 G^s 输出规模本身就是本文的下界 (注 18(1))。
- (2) **随机性来源不同**. [2] 的随机性全在 edge 上, 且要求 i.i.d.; 本文的上游 X 有任意相依的联合分布 (由 TTNS 给出), edge delay 只要求相互独立、不要求同分布, 另有 node delay D_a 。 [2] 的模型不含 node delay。
- (3) **参数图不同**. [2] 的 k 是问题图本身的树宽; 本文的 $\text{tw}(\mathcal{G}_S^+)$ 是联合结构图的树宽, 同时编码上游 TTNS 的树 T 、fan-in 结构 $\{P_a\}$ 与输出集合 S (定义 4)。两者不可直接比较。
- (4) **指数形式不同**. [2] 是 $n^{O(k^2)}$ (XP), 本文是 $W^{\text{tw}+O(1)}$, 即在 (10) 的 W 上单指数、指数为 $\text{tw}+1$ (sum-product 项) 或 $\text{tw}+2$ (与投影 core 预计算合并后, 注 17)。本文的更好指数来自更强的输入假设 (给定 TTNS 表示、离散化的输出网格), 不是同一问题上的改进。

简言之: [2] 说明“连续 i.i.d. 情形下标量最长路分布仍是 #P-难、但对树宽是 XP”, 本文说明“若上游有 TTNS 表示且联合结构图树宽有界, 则多输出联合 CDF 有单指数算法”。前者是本文非平凡性的背景, 不是本文结论的特例, 也不被本文结论覆盖。

5.4 特例: 与仓库现有实现的对应

以下推论把定理 5 落到三种已实现的情形。为简洁设 $\Delta_T^{\max} := \deg_T^{\max}$ 。

推论 5 ($s = 1$: 单点边缘 CDF). 取 $S = \{a\}$ 。此时 $\mathcal{G}_S^+ = \mathcal{G}_S$, 且由注 18(2) 有 $\text{tw} \leq \Delta_T^{\max} + 1$, 故全部 G 个网格点上的 $\hat{F}_M^{\{a\}}$ 可在 $O(\text{poly}(d) \cdot W^{\Delta_T^{\max}+2})$ 内算出。该情形对应 simple_tttns_l2/maxplus_cdf.py 的 marginal_cdf。

推论 6 ($s = 2$: pair CDF 与共享父节点). 取 $S = \{a, b\}$, $\text{tw}(\mathcal{G}_S^+) \leq \Delta_T^{\max} + 2$, 故 G^2 全表可在 $O(\text{poly}(d) \cdot W^{\Delta_T^{\max}+3})$ 内算出。共享父节点 $k \in P_a \cap P_b$ 在 $\mathcal{G}_S$ 中表现为 ξ_k 同时与 v_a 和 v_b 相邻, 从而 $\{\xi_k, v_a, v_b\}$ 落入同一 bag; 这正是共享父依赖被保留在同一个积分变量内的图论对应 (参见 §3 的共享父节点注)。该情形对应 pair_cdf。

推论 7 (一般 s 与全 K : 块联合 CDF). 取 $S = \{1, \dots, K\}$ 。由注 18, $K - 1 \leq \text{tw}(\mathcal{G}_S^+) \leq \Delta_T^{\max} + K$, 故代价在 G^K 与 $W^{\Delta_T^{\max}+K+1}$ 之间, 对 K 是指数的。该情形对应 simple_tttns_l2/maxplus_cdf_forest.py 的 block_joint_cdf; 下界部分说明该实现只适合小 K 不是实现缺陷, 而是“要求 G^K 全表”这一目标本身的代价。若把目标改为推论 4 中的低维边缘或可分离泛函, 则 sum-product 项的指数可以降到 $\text{tw}(\mathcal{G}_S) + 1$ (合并投影 core 预计算后为 $\text{tw}(\mathcal{G}_S) + 2$)。

推论 8 (forest 情形的分量分解). 设 T 是 forest, 连通分量为 $T_1, \dots, T_c$, 且每个 $a \in S$ 的父集合 P_a 完全落在单个分量内。进一步设上游密度按分量独立分解

$$p_X(x) = \prod_{j=1}^c p_j(x_{V(T_j)}), \quad (12)$$

其中每个 p_j 是分量树 T_j 上按 (2)–(3) 表示的非负、归一化密度 (即 $p_j \geq 0$ 且 $\int p_j = 1$)。令 $S_j = \{a \in S : P_a \subseteq V(T_j)\}$, $s_j = |S_j|$, 并约定 $S_j = \emptyset$ 时相应因子取 1 (空乘积)。则 $\mathcal{G}_S$ 按分量分解为 c 个互不相连的子图, 且

$$\hat{F}_M^S(y) = \prod_{j=1}^c \hat{F}_M^{S_j}(y_{S_j}),$$

总代价为 $O\left(\sum_j \text{poly}(d, K) W^{\text{tw}(\mathcal{G}_{S_j}^+) + 2}\right)$ (指数中的 +2 按注 17), 其中因子化表示的总存储规模由 G^S 降为 $\sum_j G^{s_j}$ 。该情形对应 UpperForest。

证明. $\mathcal{G}_S$ 中不存在跨分量的边: 第 (i) 类团在单个分量内, 第 (ii) 类边由 $P_a \subseteq V(T_j)$ 也在单个分量内。因子集合据此划分为 c 组、变量集合亦然, sum-product 随之分解为乘积。这给出代数上的因子分解; 要把第 j 个因子读作分量 CDF $\hat{F}_M^{S_j}$, 还需要 (12): 由它, $\{X_{V(T_j)}\}_{j=1}^c$ 相互独立且每块自身归一化, 故 $\{Y_a\}_{a \in S_j}$ 只依赖第 j 块, 分量之间独立, 联合 CDF 等于各分量 CDF 之积, 且每个因子取值于 $[0, 1]$ 。若缺少归一化, 上式仍是恒等的代数分解, 但各因子不再是概率意义下的 CDF。□

注 21 (“因子化表示规模”不是“完整全表规模”)。推论 8 中的 $\sum_j G^{s_j}$ 是按分量分开保存 $\{\hat{F}_M^{S_j}\}_{j=1}^c$ 时的总存储规模。它不是完整 s 维数组的规模: 若下游仍要求显式材料化 $\hat{F}_M^S$ 在整个 G^S 网格上的取值, 则仍需生成并保存 $G^S = \prod_j G^{s_j}$ 个元素, 此时分解只把计算代价从 $W^{\text{tw}(\mathcal{G}_S^+) + 2}$ 降为 $\sum_j W^{\text{tw}(\mathcal{G}_{S_j}^+) + 2}$ (外加 $O(G^S)$ 的逐点相乘), 并不降低输出规模。因此在报告复杂度时必须区分两个目标:

1. **因子化表示:** 只保存各分量表并按需在单点上求值——存储 $\sum_j G^{s_j}$, 单点求值 $O(c)$ 次乘法;
2. **完整材料化:** 输出整张 s 维表——存储与写出代价下界为 G^S , 与是否 forest 无关。

本文其余处凡出现“全表”“材料化整张 G^S 表”的表述均指第 2 类目标; 推论 8 的收益属于第 1 类。

注 22 (跨分量父集合会破坏分解)。若某个 a 的父集合跨越两个分量, 则 v_a 把这两个分量连起来, 分解失效, tw 一般随之上升。因此推论 8 的前提是块划分与 fan-out 结构相容, 而不是任意 forest 都可分解。

5.5 具体拓扑上的树宽

定理 5 的判据只有落到具体拓扑上才有内容。本小节给出若干代表性层结构的 $\text{tw}(\mathcal{G}_S)$ 与 $\text{tw}(\mathcal{G}_S^+)$ 。表中 $s = |S|$, T 为上游树。

数值来源与可复算性. 本表全部数字由脚本

simple_ttms_l2/experiments/audit_joint_structure_treewidth.py

生成, 输出 simple_ttms_l2/reports/joint_structure_treewidth.json。该脚本只做小图组合计算: 不读任何数据、不使用随机数、不依赖仓库其他模块, 单线程数秒内完成, 因此不属于数值实验。它按定义 4 逐字构造 $\mathcal{G}_S$ 与 $\mathcal{G}_S^+$, 并对每一行记录拓扑名、上游树边集、完整父集合族 $\{P_a\}$ 、输出子集 S 、联合结构图的完整边表、所用算法、以及该数字是精确值还是上界。JSON 同时记录注 18 两侧界的逐例核对结果。

树宽的计算方式为: 所审计的联合结构图 ($\mathcal{G}_S$ 与 $\mathcal{G}_S^+$, 二者顶点集相同) 的顶点数不超过 21 时用按顶点子集的动态规划给出 精确树宽; 超过时给出 min-fill 与 min-degree 两种消元启发式的较小者, 即上界 (表中以 $\leq$ 标出)。两种启发式都按顶点名破平, 故结果确定。

三类层结构.

- **banded**: 节点 a 的父集合为上一层中一段连续下标 $P_a = \{a, a+1\}$ ($|P_a| = 2$, 模 d wrap)。层间共享父节点, 存在真实的 reconvergent fanout。
- **clustered+crossed**: $d = K = 20$ 分为 4 个大小为 5 的簇; 簇内 fan-in 为 4 (簇内 wrap), 另对簇对 $(0, 1)$ 与 $(2, 3)$ 让下层簇的节点各额外从上层配对簇取 1 个父节点, 故 $|P_a| \leq 5$ 。这是仓库 `dag_pipeline.py` 中 `build_crossed_spec` 的层内结构。
- **long-range dense**: 同样 $|P_a| = 5$, 但把第 5 个父节点放在距离 12 处 ($a + 3 \cdot 4 \bmod 20$), 作为“长程 reconvergence”的对照行。

层结构	T	d	s	$\text{tw}(\mathcal{G}_S)$	$\text{tw}(\mathcal{G}_S^+)$
banded $K = 4$	path	4	4	3	4
banded $K = 6$	path	6	6	3	6
banded $K = 7$	path	7	7	3	7
banded $K = 6$	star	6	6	6	7
banded $K = 7$	star	7	7	7	8
banded $K = 6$	path	6	1	2	2
banded $K = 6$	path	6	2	2	3
clustered+crossed	path	20	20	≤ 7	≤ 20
clustered+crossed	二叉树	20	20	≤ 13	≤ 20
clustered+crossed	star	20	20	≤ 19	≤ 23
clustered+crossed	path	20	1	≤ 3	≤ 3
clustered+crossed	path	20	2	≤ 4	≤ 4
long-range dense	path	20	20	≤ 16	≤ 21
long-range dense	path	20	1	≤ 3	≤ 3
long-range dense	path	20	2	≤ 4	≤ 4

前七行的顶点数不超过 21, 为精确树宽; 后八行为上界。

注 23 (表中四个可读的结论). 第一, $\text{tw}(\mathcal{G}_S)$ 在该族中不随层宽增长, 而 $\text{tw}(\mathcal{G}_S^+)$ 随 s 增长。对 banded 下游 + path 上游树, 脚本在 $K = 4, \dots, 32$ 上逐项核对: $\text{tw}(\mathcal{G}_S)$ 在 $K = 4, \dots, 7$ 上精确等于 3, 在 $K = 8, \dots, 32$ 上启发式上界仍为 3; 而 $\text{tw}(\mathcal{G}_S^+)$ 在 $K = 4, \dots, 7$ 上精确等于 K , 在 $K = 8, \dots, 32$ 上上界等于 K 、下界由注 18(1) 给出 $K - 1$ 。这把推论 4 从“存在这样的例子”变成“实际使用的层结构就是这样的例子”: 只要不材料化整张 G^K 表, 代价的树宽指数部分在该族中保持常数; 一旦材料化, 指数就等于层宽 (至多相差 1)。两点限定必须一并说明。其一, “指数部分保持常数”不等于“总代价与层宽无关”: 定理 5 的界含 $\text{poly}(d, K)$ 前因子, 层变宽时总代价仍按多项式增长。其二, $K \geq 8$ 各行只是 min-fill/min-degree 消元给出的确定性启发式上界 (脚本按顶点名破平, 故可复现), 并非精确树宽; 因此这里只能说“在扫描到的 $K \leq 32$ 范围内该上界恒为 3”, 不能仅凭有限扫描断言对任意 K 成立——要得到对任意 K 的结论, 需要另行给出一族与 K 无关宽度的显式树分解构造, 本文未做这件事。

第二, **上游树的形状直接改变指数**。同一个下游层, T 取 path 时 $\text{tw}(\mathcal{G}_S)$ 为 3 (banded) 或 ≤ 7 (clustered+crossed), 取 star 时升到 6、7 (banded) 与 ≤ 19 (clustered+crossed), 即 $\deg_T^{\max}$ 主导。这说明定理 5 中的树结构不是记号上的摆设: Chow-Liu 选出的树是链状还是星状, 会实际改变可计算性。

第三, **低维泛函在稠密层上依然便宜**。 $d = 20$ 、 $|P_a| \leq 5$ 的 clustered+crossed 层在 $s = 1, 2$ 时树宽上界只有 3, 4, 而 $s = 20$ 时 $\text{tw}(\mathcal{G}_S^+) \leq 20$ 。这与仓库中 `marginal_cdf` / `pair_cdf` 可在稠密配置上直接使用、而 `block_joint_cdf` 只用于小块的实际情况一致, 也给推论 7 的“指数来自目标本身”提供了具体数字。

第四, **父集合的几何位置而非大小影响可获得的树宽上界**。clustered+crossed 与 long-range dense 两行的 $|P_a|$ 相同 (都是 5)、上游树相同 (path)、 d 与 s 相同, 但整表情形下消元启发式给出的 $\text{tw}(\mathcal{G}_S)$ 上界从 ≤ 7 升到 ≤ 16 。差别只在第 5 个父节点是落在同一簇内还是落在距离

12 处。必须严格限定这一比较的含义：两个数都只是 min-fill / min-degree 给出的上界（顶点数 > 21 ，见 §5.5 的分类），上界更大不能推出真实树宽更大，更不能推出真实收缩代价一定更大；要证明真实树宽增加，需要给第二张图一个严格超过第一张图上界的下界，或直接精确计算两者。因此这里只能说：在这两个配置上，父集合的几何位置显著改变了消元启发式所能达到的上界，从而改变了本文可以保证的代价。

同样不能由“两者在 $s = 1, 2$ 时的上界相同 (3 与 4)”推出“长程 reconvergence 只在材料化整表时才付出代价”——后者作为一般命题是错的。一个可精确计算的小反例：上游树取 $d = 4$ 的 path, $s = 2$ ，父集合 $P_0 = \{0, 1\}$ 、 $P_1 = \{1, 2\}$ 时 $\text{tw}(\mathcal{G}_S) = 2$ ；把第二个父集合改为 $P_1 = \{0, 2\}$ （大小不变，只是跨度变大）后 $\text{tw}(\mathcal{G}_S) = 3$ 。两者顶点数均为 $9 \leq 21$ ，故均为精确树宽；这里既未加输出团也未材料化整表，长程连接已经抬高了 $\text{tw}(\mathcal{G}_S)$ 。可以保留的是弱得多的读法：在本文所列的 $s = 1, 2$ 配置上，两类拓扑的启发式上界相同，因而低维泛函在两者上都便宜；这为“何时该用 block_joint_cdf、何时该退回低维泛函”给出一个可直接从层拓扑读出的启发式判据，而不是一个已证明的分界。

注 24 (与两侧紧性的一致性核对). 注 18 断言 $s - 1 \leq \text{tw}(\mathcal{G}_S^+) \leq \deg_T^{\max} + s$ 。上述脚本对表中全部 15 行以及 $K = 4, \dots, 32$ 的整个扫描逐例核对该式 (JSON 中的 bounds_respected 字段)，无一违反。在 banded + path 的整表情形下 $\text{tw}(\mathcal{G}_S^+) = s$ ，落在两界之间而与上界 $\deg_T^{\max} + s = s + 2$ 相差常数。这说明该上界在这类结构上不是紧的，但也没有松到无用。

注 25 (本小节数值的边界). 四点限制。第一，判据是联合结构图的顶点数而非上游维数 d ：当 $|V_{\mathcal{G}_S}| > 21$ （等价地 $|V_{\mathcal{G}_S^+}| > 21$ ，二者顶点集相同）时给出的是上界而非精确树宽（精确树宽的计算是 NP-难的，见注 19），故后八行的数字只能用来说明“至多这么贵”，不能用来说明“至少这么贵”；唯一可用的下界是注 18(1) 的 $s - 1$ 。第二，上游树 T 在实际流程中由 Chow-Liu 从数据估计，本表改为对 path、star、二叉树三种代表形状分别列出，用以显示 T 的影响范围，而不是断言实际学到的树是哪一种。第三，表中 clustered+crossed 一行复刻的是仓库层生成器的拓扑，不涉及其任何参数取值或训练结果。第四，本表只涉及图的组合量，不含任何统计结论，也未使用任何实验产物；反过来说，它也不能替代定理 5 复杂度标度的实测（见 §8.5）。

5.6 平方 TTNS 的对应

推论 9 (doubled network 的复杂度). 设上游密度取平方形式 $p_X = \psi^2/Z$ ，其中 ψ 由树 T 上 bond dimension r_e 、物理维 m_k 的 TTNS 按 (2)–(3) 表示， $\psi \in L^2(\mathbb{R}^d)$ ，且归一化常数

$$Z := \int_{\mathbb{R}^d} \psi(x)^2 dx \quad \text{满足} \quad 0 < Z < \infty \quad (13)$$

($Z < \infty$ 即 $\psi \in L^2$ ； $Z > 0$ 即 ψ 不是几乎处处为零，二者共同保证 $p_X = \psi^2/Z$ 是合法概率密度)。则 p_X 本身是同一棵树上 bond dimension r_e^2 、物理维 m_k^2 的 TTNS，其联合结构图 $\mathcal{G}_S$ 与 $\mathcal{G}_S^+$ 完全不变。因此定理 5 的指数不变，只是把 (10) 中的 r 换成 r^2 、 m 换成 m^2 ：分项复杂度为

$$O\left(\sum_k q m_k^2 \prod_{e \in \delta_T(k)} r_e^2 + (d + |E(T)| + \sum_{a \in S} |P_a|) \cdot W_2^{\text{tw}(\mathcal{G}_S^+)+1} + s n_D G^s\right),$$

其中 $W_2 = \max\{q, r^2, m^2, G\}$ ；相应的单一表达式（按注 17 的同一理由取指数 $\text{tw}+2$ ）为

$$O\left(\text{poly}(d, K) \cdot W_2^{\text{tw}(\mathcal{G}_S^+)+2} + s n_D G^s\right).$$

注意这里的 +2 同样不可省： $q = m^2 = r^2 = W_2$ 时某度数为 Δ 的节点预计算代价为 $q m_k^2 \prod_{e \in \delta_T(k)} r_e^2 = W_2^{\Delta+2}$ ，而 $\text{tw}(\mathcal{G}_S^+) \geq \deg_T^{\max} \geq \Delta$ 。

证明. $\psi(x)^2$ 的系数张量是 ψ 的系数张量与自身的 Hadamard 型乘积，可由逐节点的 doubled core $G^{(k)} \otimes G^{(k)}$ 表示：物理指标为 (i, i') 、每条边的 bond 指标为 (α_e, α'_e) 。树拓扑、 $\delta_T(k)$ 与父集合族均未改变，故由定义 4， $\mathcal{G}_S$ 逐字相同。定义 3 中 $b_{k,i} b_{k,i'}$ 起 m_k^2 个基函数的作用， q

与 G 不变。归一化常数 $1/Z$ 是与所有指标无关的标量，把它并入任意一个 core（例如根 core $G^{(\text{rt})} \otimes G^{(\text{rt})}$ 整体乘以 $1/Z$ ）即得 $p_X = \psi^2/Z$ 本身的 TTNS 表示；这一步既不改变 bond 与物理维，也不改变树拓扑，因而 $\mathcal{G}_S$ 、 $\mathcal{G}_S^+$ 与全部复杂度指数均不受影响。代入定理 5 即得。 $\square$

注 26 (非负性不改变结构，只改变常数)。推论 9 说明：把线性 TTNS 换成平方 TTNS 以换取逐点非负性，代价是 bond 与物理维的平方，而不改变可计算性的结构判据。这一点对方法选择是实质性的——非负化不会把一个 tractable 的拓扑变成 intractable 的拓扑。必须注意“指数不变”是相对于替换后的域大小 $W_2 = \max\{q, r^2, m^2, G\}$ 而言：树宽 $\text{tw}(\mathcal{G}_S^+)$ 由图决定，而图未变，故以 W_2 为底的幂次不变；若改用原始的 r 与 m 表示同一代价，则 rank 与物理维上的幂次相应加倍（ W_2^{w+2} 中来自 r^2, m^2 的部分等于 r, m 的 $2(w+2)$ 次幂）。因此该推论说的是“结构判据不变、底数平方”，而不是“以原始 r, m 计的代价不变”。仓库中已有的低维一致性证据（doubled contraction 与显式平方系数张量的差为 10^{-15} 量级）只验证了恒等式，未验证本推论的复杂度标度；后者需要独立的计时实验。

6 max-plus 层的信息传递预算

6.1 局部 max-plus channel

本节要求不同下游节点使用相互独立的局部 delay 随机源。具体地，对每个 $a \in \{1, \dots, K\}$ ，令

$$\mathcal{E}_a = (E_{ka})_{k \in P_a}$$

表示节点 a 的 edge-delay 向量，并假设随机对象

$$(\mathcal{E}_1, D_1), \dots, (\mathcal{E}_K, D_K)$$

相互独立且都与 X 独立。这个假设比定理 1 更强；它是下游条件通道分解为乘积所必需的。

对父状态 $u = (u_k)_{k \in P_a}$ ，定义局部 Markov kernel

$$K_a(B | u) = \mathbb{P} \left(\max_{k \in P_a} (u_k + E_{ka}) + D_a \in B \right), \quad B \in \mathcal{B}(\mathbb{R}).$$

若 E_{ka} 相互独立，则该 channel 的条件 CDF 为

$$K_a((-\infty, y] | u) = \mathbb{E}_{D_a} \left[\prod_{k \in P_a} F_{ka}(y - D_a - u_k) \right].$$

若 E_{ka} 还有密度 f_{ka} ，则 max 之前的条件密度为

$$q_a(z | u) = \sum_{r \in P_a} f_{ra}(z - u_r) \prod_{\substack{k \in P_a \\ k \neq r}} F_{ka}(z - u_k),$$

所以在 D_a 有密度或一般概率测度时， K_a 可以通过一维卷积确定性计算。

定义 channel 的 Dobrushin 系数

$$\delta_a = \sup_{u, u'} \|K_a(\cdot | u) - K_a(\cdot | u')\|_{\text{TV}}.$$

这里 total variation 采用

$$\|P - Q\|_{\text{TV}} = \sup_B |P(B) - Q(B)|$$

的归一化；若 P, Q 有密度 p, q ，则它等于 $\frac{1}{2} \int |p - q|$ 。经典 contraction-coefficient 结果给出

$$\eta_{\text{KL}}(K_a) \leq \delta_a,$$

其中

$$\eta_{\text{KL}}(K_a) = \sup_{\substack{P \neq Q \\ 0 < D_{\text{KL}}(P \| Q) < \infty}} \frac{D_{\text{KL}}(PK_a \| QK_a)}{D_{\text{KL}}(P \| Q)}$$

是 KL contraction coefficient [7, 11]。

6.2 max 的 Lipschitz 性给出显式 channel 系数

令 $\mathcal{U}_a \subset \mathbb{R}^{|P_a|}$ 是允许的父状态集合, 并定义

$$\Delta_a = \text{diam}_\infty(\mathcal{U}_a) = \sup_{u, u' \in \mathcal{U}_a} \|u - u'\|_\infty.$$

对 node delay 定义平移 TV 模量

$$\omega_{D_a}(t) = \sup_{|h| \leq t} \|\text{Law}(D_a) - \text{Law}(D_a + h)\|_{\text{TV}}, \quad t \geq 0.$$

这是一个只依赖一维 node-delay 分布的量。若 D_a 有密度 g_a , 则

$$\omega_{D_a}(t) = \sup_{|h| \leq t} \frac{1}{2} \int_{\mathbb{R}} |g_a(z) - g_a(z - h)| dz,$$

可以用确定性一维积分计算。

定理 6 (max-plus channel 的显式 Dobrushin 上界). 在上述设定下, 把 K_a 限制在输入集合 $\mathcal{U}_a$, 则

$$\delta_a \leq \omega_{D_a}(\Delta_a).$$

若 g_a 绝对连续且弱导数 $g'_a \in L^1(\mathbb{R})$, 则进一步有

$$\delta_a \leq \min \left\{ 1, \frac{\Delta_a}{2} \|g'_a\|_{L^1} \right\}.$$

特别地, 若 $D_a \sim \mathcal{N}(0, \sigma_a^2)$, 则

$$\delta_a \leq 2\Phi\left(\frac{\Delta_a}{2\sigma_a}\right) - 1 < 1 \quad (\Delta_a < \infty),$$

其中 Φ 是标准正态 CDF。若 $D_a \sim \text{Uniform}[0, w_a]$, 则

$$\delta_a \leq \min \left\{ 1, \frac{\Delta_a}{w_a} \right\}.$$

证明. 对固定 edge-delay realization e , 记

$$z(u, e) = \max_{k \in P_a} (u_k + e_k).$$

max 映射关于 ℓ_∞ 范数是 1-Lipschitz, 因此

$$|z(u, e) - z(u', e)| \leq \|u - u'\|_\infty.$$

在比较 $K_a(\cdot | u)$ 和 $K_a(\cdot | u')$ 时, 对两边使用同一个 edge-delay realization。由 TV 对混合分布的凸性,

$$\begin{aligned} \|K_a(\cdot | u) - K_a(\cdot | u')\|_{\text{TV}} &\leq \mathbb{E}_{\mathcal{E}_a} [\|\text{Law}(D_a + z(u, \mathcal{E}_a)) - \text{Law}(D_a + z(u', \mathcal{E}_a))\|_{\text{TV}}] \\ &\leq \omega_{D_a}(\|u - u'\|_\infty). \end{aligned}$$

对 $u, u' \in \mathcal{U}_a$ 取上确界得到第一式。

若 $g'_a \in L^1$, 则对任意 h ,

$$\begin{aligned} \frac{1}{2} \int_{\mathbb{R}} |g_a(z) - g_a(z - h)| dz &= \frac{1}{2} \int_{\mathbb{R}} \left| \int_{z-h}^z g'_a(s) ds \right| dz \\ &\leq \frac{|h|}{2} \|g'_a\|_{L^1}. \end{aligned}$$

再使用 TV 不超过 1 得第二式。Gaussian 和 uniform 的公式由两个平移密度的重叠面积直接计算得到。□

注 27 (可改进性和紧性). 该上界故意没有使用 edge noise 的额外平滑作用, 因此容易计算但不一定最紧。在单父节点、edge delay 为常数、输入集合包含两个距离为 Δ_a 的状态时, channel 恰好退化为 D_a 的两个平移; 此时上界可以取等。因此, 如果只知道 Δ_a 和 D_a , 一般不能得到统一更小的常数。若希望利用 edge noise, 应从上面的局部条件 CDF 或密度直接计算 δ_a 。

注 28 (项目中的两类 delay). 对于 uniform node delay, 若父状态直径不小于区间宽度, 则上述全局系数等于 1, 不产生严格 SDPI。对于项目使用的 log-skew-normal node delay, $\omega_{D_a}(t)$ 可由其一维密度平移积分确定性计算; 只要 $t < \infty$ 且任意有限平移后的支撑仍有正重叠, $\omega_{D_a}(t) < 1$ 。这只说明严格 contraction 存在, 不应在未计算该积分前宣称 contraction 很强 [10, 12]。

6.3 pair mutual information: 共享父与独占父的分解

固定两个不同下游节点 a, b 。把上一层父变量分成

$$C_{ab} = X_{P_a \cap P_b}, \quad A_{ab} = X_{P_a \setminus P_b}, \quad B_{ab} = X_{P_b \setminus P_a}.$$

其中任一向量都允许为空。对固定 $C_{ab} = c$, 令 $\delta_{a|c}^{\text{ex}}$ 表示只改变 A_{ab} 时, 节点 a 的条件 channel Dobrushin 系数; 类似定义 $\delta_{b|c}^{\text{ex}}$ 。令

$$\bar{\delta}_a^{\text{ex}} = \sup_c \delta_{a|c}^{\text{ex}}, \quad \bar{\delta}_b^{\text{ex}} = \sup_c \delta_{b|c}^{\text{ex}}.$$

若独占父状态集合的 ℓ_∞ 直径分别为 Δ_a^{ex} 和 Δ_b^{ex} , 则上一条定理给出

$$\bar{\delta}_a^{\text{ex}} \leq \omega_{D_a}(\Delta_a^{\text{ex}}), \quad \bar{\delta}_b^{\text{ex}} \leq \omega_{D_b}(\Delta_b^{\text{ex}}).$$

定理 7 (连续共享父变量下的 pair 信息预算). 假设下式中的 mutual information 都有定义且有限。则

$$\begin{aligned} I(Y_a; Y_b) &\leq \min\{I(C_{ab}; Y_a), I(C_{ab}; Y_b)\} \\ &\quad + \min\{\bar{\delta}_a^{\text{ex}}, \bar{\delta}_b^{\text{ex}}\} I(A_{ab}; B_{ab} | C_{ab}). \end{aligned}$$

第一项是共享父变量实际传到两个输出中较弱一侧的信息; 第二项是独占父之间剩余的条件依赖经过两个局部 max-plus channels 后最多保留的信息。

证明. 由 chain rule 和 conditional mutual information 的非负性,

$$\begin{aligned} I(Y_a; Y_b) &\leq I(Y_a; Y_b, C_{ab}) \\ &= I(Y_a; C_{ab}) + I(Y_a; Y_b | C_{ab}). \end{aligned}$$

交换 a, b 后也成立, 所以共享父项可以取两者的最小值。固定 $C_{ab} = c$ 后, 由局部 delay 独立性得到 Markov chain

$$Y_a - A_{ab} - B_{ab} - Y_b \quad \text{在条件 } C_{ab} = c \text{ 下.}$$

先对一侧使用 KL strong data-processing inequality, 再对另一侧使用普通 data-processing inequality, 得到

$$I(Y_a; Y_b | C_{ab} = c) \leq \min\{\delta_{a|c}^{\text{ex}}, \delta_{b|c}^{\text{ex}}\} I(A_{ab}; B_{ab} | C_{ab} = c).$$

对 c 平均并用统一上界即得结论。 □

推论 10 (有限状态 pair 的完全显式分解). 若上一层父变量为有限状态变量, 令

$$U_a = X_{P_a}, \quad U_b = X_{P_b}, \quad \beta_{ab} = \min\{\delta_a, \delta_b\}.$$

则

$$\begin{aligned} I(Y_a; Y_b) &\leq \beta_{ab} I(U_a; U_b) \\ &= \beta_{ab} [H(C_{ab}) + I(A_{ab}; B_{ab} | C_{ab})]. \end{aligned}$$

证明. 局部条件独立性给出 Markov chain

$$Y_a - U_a - U_b - Y_b.$$

分别从两侧使用 KL contraction coefficient 不超过 Dobrushin 系数的事实, 得到第一行。第二行由有限状态 entropy chain rule:

$$I((A_{ab}, C_{ab}); (B_{ab}, C_{ab})) = H(C_{ab}) + I(A_{ab}; B_{ab} | C_{ab}).$$

□

6.4 整层 total correlation 与 fan-out 信息注入

本小节令上一层变量 X_i 取值于有限集合 $\mathcal{X}_i \subset \mathbb{R}$ 。定义父块

$$U_a = X_{P_a}, \quad \mathcal{P} = \bigcup_{a=1}^K P_a,$$

以及父节点 $i \in \mathcal{P}$ 的 fan-out 次数

$$\phi_i = |\{a : i \in P_a\}|.$$

对任意随机向量 $Z = (Z_1, \dots, Z_m)$, 定义

$$\text{TC}(Z) = D_{\text{KL}} \left(P_Z \left\| \prod_{j=1}^m P_{Z_j} \right\| \right). \quad (14)$$

在标准 Borel 空间上该量恒有定义并取值于 $[0, \infty]$ 。当各 Z_j 取有限多个值时它等于 entropy 差 $\sum_j H(Z_j) - H(Z)$; 连续情形下不使用该 entropy 表达式, 因为各微分熵可能同时为 $\pm\infty$ 而使差式成为未定义的 $\infty - \infty$ 。

假设 3 (父状态限制与支撑). 定理 6 中的系数 δ_a 是把 K_a 限制在允许父状态集合 $\mathcal{U}_a$ 上得到的。因此在下面使用 δ_a 的所有结论中, 须假设被比较的父块分布支撑在 $\mathcal{U}_a$ 内, 即

$$\text{supp}(P_{U_a}) \subseteq \mathcal{U}_a, \quad a = 1, \dots, K,$$

从而联合分布 P_U 与乘积分布 $Q_U = \prod_a P_{U_a}$ 都支撑在 $\prod_{a=1}^K \mathcal{U}_a$ 内。若不作此限制而取全局上确界, 则对常见 additive-noise channel 往往有 $\delta_a = 1$, 结论退化为平凡。

由于 Q_U 的各边缘与 P_U 相同, $\text{supp}(P_{U_a}) \subseteq \mathcal{U}_a$ 已蕴含 $\text{supp}(Q_U) \subseteq \prod_a \mathcal{U}_a$, 故该假设只需对边缘核验。

定义 5 (source-dependent KL contraction coefficient). 对 Markov kernel K 与参考分布 Q , 定义

$$\eta_{\text{KL}}(K, Q) = \sup_{\substack{P \neq Q \\ 0 < D_{\text{KL}}(P \| Q) < \infty}} \frac{D_{\text{KL}}(PK \| QK)}{D_{\text{KL}}(P \| Q)}, \quad \eta_{\text{KL}}(K) = \sup_Q \eta_{\text{KL}}(K, Q),$$

其中约定 $\sup \emptyset = 0$ 。前者称为固定输入参考分布下的 source-dependent (或 fixed-input) 系数, 后者称为 input-independent 系数。二者满足 $\eta_{\text{KL}}(K, Q) \leq \eta_{\text{KL}}(K)$, 且由 [11, Theorem 1] 与 [7, Theorem 4.1], 对任意 f -divergence 有 $\eta_f(K) \leq \eta_{\text{TV}}(K)$, 故

$$\eta_{\text{KL}}(K, Q) \leq \eta_{\text{KL}}(K) \leq \eta_{\text{TV}}(K).$$

本文中 $\eta_{\text{TV}}(K_a)$ 就是定理 6 的 Dobrushin 系数 δ_a 。

注 29 (退化参考分布). $\sup \emptyset = 0$ 的约定使 $\eta_{\text{KL}}(K, Q)$ 对一切参考分布有定义, 包括点质量 $Q = \delta_u$ 。此时约束集 $\{P \neq \delta_u : 0 < D_{\text{KL}}(P \parallel \delta_u) < \infty\}$ 为空——任何 $P \neq \delta_u$ 都不绝对连续于 δ_u , 故 $D_{\text{KL}}(P \parallel \delta_u) = \infty$ 。因此

$$\eta_{\text{KL}}(K, \delta_u) = 0.$$

这不是人为规定, 而是定义在退化情形下的直接取值, 且与其信息论含义一致: 确定的输入不携带与其他输入的互信息, 对应项应当为零。下面引理 6 与定理 8 中若某个父块 U_a 退化 (P_{U_a} 为点质量), 则 $\eta_a = 0$, 而该坐标本来也满足 $I(U_a; U_{<a}) = 0$, 两侧一致; 等价地也可先把全部确定坐标删去再应用引理, 所得的 $\max_a \eta_a$ 相同。

引理 6 (逐分量 SDPI 给出整层 total correlation 的收缩). 设 $U = (U_1, \dots, U_K)$ 是任意 (可以任意相关的) 随机元组, Y_a 由 U_a 经 Markov kernel K_a 生成, 并设给定 U 时 $Y_1, \dots, Y_K$ 条件独立, 即联合 channel 是乘积 $K^\otimes = \bigotimes_a K_a$ 。记 P_{U_a} 为 U_a 的边缘分布, 并按定义 5 令

$$\eta_a = \eta_{\text{KL}}(K_a, P_{U_a}).$$

若 $\text{TC}(U) < \infty$, 则

$$\text{TC}(Y_1, \dots, Y_K) \leq \left(\max_{1 \leq a \leq K} \eta_a \right) \text{TC}(U_1, \dots, U_K).$$

证明. 固定任一坐标次序, 记 $Y_{<a} = (Y_1, \dots, Y_{a-1})$, $U_{<a} = (U_1, \dots, U_{a-1})$, $a = 1$ 时约定为空。

第零步 (链式分解)。由相对熵的链式法则直接作用于定义 (14),

$$\text{TC}(Y) = D_{\text{KL}}\left(P_Y \parallel \prod_a P_{Y_a}\right) = \sum_{a=2}^K I(Y_a; Y_{<a}), \quad \text{TC}(U) = \sum_{a=2}^K I(U_a; U_{<a}). \quad (15)$$

这里不经过 entropy 差 $\sum_a H(Y_a) - H(Y)$: 本引理允许 Y_a 连续, 此时各微分熵可能为 $\pm\infty$, 该差式未必有定义。而 (15) 中每一项都是互信息, 在一般标准 Borel 空间上按扩展非负实数理解, 恒有定义; 链式法则在 $[0, \infty]$ 中逐项成立, 无需可积性假设。(引理已设 $\text{TC}(U) < \infty$, 故右侧各项有限。)

第一步 (条件独立结构)。把第 a 个局部 channel 写成 $Y_a = g_a(U_a, \zeta_a)$, 其中 ζ_a 汇总该 channel 的全部噪声 (本文设定中为 $(E_{ka})_{k \in P_a}$ 与 D_a)。按假设 $\zeta_1, \dots, \zeta_K$ 相互独立且与 U 独立。给定 U_a 时 ζ_a 的条件分布不变, 且仍与 $(U_{<a}, \zeta_{<a})$ 独立; 而 $Y_{<a}$ 只是 $(U_{<a}, \zeta_{<a})$ 的函数。因此 $Y_a \perp Y_{<a} \mid U_a$, 即

$$Y_{<a} \rightarrow U_a \rightarrow Y_a$$

是 Markov 链。同理 $\zeta_{<a}$ 与 U 独立给出

$$U_a \rightarrow U_{<a} \rightarrow Y_{<a}$$

也是 Markov 链。

第二步 (对单个局部 channel 施加 SDPI)。由 [11, Theorem 4], source-dependent 系数具有互信息刻画

$$\eta_{\text{KL}}(K_a, P_{U_a}) = \sup \left\{ \frac{I(W; Y_a)}{I(W; U_a)} : W \rightarrow U_a \rightarrow Y_a, 0 < I(W; U_a) < \infty \right\}, \quad (16)$$

其中上确界在联合分布 $P_{U_a Y_a} = P_{U_a} \circ K_a$ 固定的条件下取。对 $W = Y_{<a}$ 应用 (16),

$$I(Y_a; Y_{<a}) \leq \eta_a I(U_a; Y_{<a}).$$

若 $I(U_a; Y_{<a}) = 0$, 则由第一步的 Markov 链与普通 DPI 左侧亦为零, 不等式自动成立。

第三步 (回到上游)。对第一步的第二条 Markov 链用普通 DPI,

$$I(U_a; Y_{<a}) \leq I(U_a; U_{<a}).$$

合并三步并对 $a = 2, \dots, K$ 求和,

$$\text{TC}(Y) = \sum_{a=2}^K I(Y_a; Y_{<a}) \leq \sum_{a=2}^K \eta_a I(U_a; U_{<a}) \leq \left(\max_a \eta_a \right) \sum_{a=2}^K I(U_a; U_{<a}) = \left(\max_a \eta_a \right) \text{TC}(U).$$

左右两端都与坐标次序无关, 故结论对任一次序成立。 $\square$

注 30 (本文不使用“乘积信道全局 KL 系数等于各分量最大值”). 一个看似自然的捷径是先断言 input-independent 系数张量化,

$$\eta_{\text{KL}}(K^{\otimes}) \stackrel{?}{=} \max_{1 \leq a \leq K} \eta_{\text{KL}}(K_a), \quad (17)$$

再把它直接用到 $D_{\text{KL}}(P_U K^{\otimes} \| Q_U K^{\otimes})$ 上。等式 (17) 一般不成立, 本文明确不使用它。

反例: 取 $K_1 = K_2 = \text{BSC}(0.1)$ 。由 [11, eq. (16)], $\eta_{\text{KL}}(\text{BSC}(0.1)) = (1 - 2 \times 0.1)^2 = 0.64$ 。令 $U \sim \text{Bern}(1/2)$ 并把同一比特重复送入两个信道 ($X_1 = X_2 = U$, 即一个二重 repetition code), 则 $I(U; X_1, X_2) = 1$, 而

$$I(U; Y_1, Y_2) = 1 - \left[0.82 h_2 \left(\frac{0.01}{0.82} \right) + 0.18 \right] = 0.742085 \dots,$$

其中 h_2 是二元熵函数。由 input-independent 系数的互信息刻画 [11, eq. (17)] 得

$$\eta_{\text{KL}}(\text{BSC}(0.1)^{\otimes 2}) \geq 0.742 > 0.64,$$

(17) 被否定。更一般地, [11, eq. (39)–(40)] 用 n 重 repetition code 给出

$$\eta_{\text{KL}}(\text{BSC}(\delta)^{\otimes n}) \geq 1 - (4\delta(1 - \delta))^{n/2 + O(\log n)} \xrightarrow{n \rightarrow \infty} 1,$$

即乘积信道的 input-independent KL 系数随分量数趋于 1, 而不是停在 $\max_a \eta_{\text{KL}}(K_a)$ 。

失效的根源在于两个不同对象的混用: input-independent 系数要对乘积空间上所有输入分布取上确界, 其中包含让各输入坐标高度相关的分布 (如上面的 repetition); 而 η_{χ^2} 的最大相关刻画 [11, eq. (9)] 是对固定输入边缘成立的, Witsenhausen 的最大相关张量化 [25, Theorem 1] 又只适用于相互独立的随机对。因此不能先在独立乘积输入上张量化、再对所有 (可相关的) 输入取上确界。此外 [11] 明确指出, 对 fixed-input 系数 $\eta_{\text{KL}}(K, Q)$ 并没有像 $\eta_{\text{KL}}(K) = \eta_{\chi^2}(K)$ [11, Theorem 3] 那样的 χ^2 归约, 所以经 η_{χ^2} 绕行的路线在 source-dependent 层面同样走不通。

引理 6 完全绕开了这个陷阱: 它不使用乘积信道的任何 contraction coefficient, 而是沿 total correlation 的链式分解, 逐项对单个局部 channel K_a 施加固定输入边缘下的 SDPI (16)。所需的量只是 $\eta_a = \eta_{\text{KL}}(K_a, P_{U_a})$, 它由局部 Dobrushin 系数控制 (定义 5)。这样得到的收缩因子取 $\max_a \eta_a$ 的形式, 不含随 K 显式增长的 product-channel 惩罚因子, 结论形式与 (17) 想要的相同, 但推导成立。需要提醒: 这不是说 $\max_a \eta_a$ 与层宽无关——向该层加入一个 η 更大的 channel 会抬高这个最大值; 只有在存在与层宽无关的一致上界 $\eta_a \leq \bar{\eta} < 1$ ($\forall a$) 时, 才能得到宽度一致的系数界。

注 31 (TV 型系数与乘积信道). 用 maximal coupling 直接估计乘积信道的 Dobrushin 系数只能得到

$$\eta_{\text{TV}}(K^{\otimes}) \leq 1 - \prod_{a=1}^K (1 - \delta_a),$$

它随输出数 K 增大趋于 1; 该上界在各分量独立达到最坏情形时基本是紧的。由注 30, KL 型的 input-independent 系数同样不张量化, 所以“TV 不行、KL 行”并不是二者的分界。真正的分界在于是否固定输入参考分布: 固定边缘后逐分量施加 SDPI 可以避免对乘积输入取上确界, 见引理 6 与注 32。

定理 8 (max-plus 层的 fan-out 信息预算). 在假设 3 下, 令 P_{U_a} 为父块 $U_a = X_{P_a}$ 的边缘分布, 并按定义 5 令

$$\eta^* = \max_{1 \leq a \leq K} \eta_{\text{KL}}(K_a, P_{U_a}) \leq \max_{1 \leq a \leq K} \eta_{\text{KL}}(K_a) \leq \max_{1 \leq a \leq K} \delta_a =: \delta^*.$$

则下游层的 total correlation 满足

$$\text{TC}(Y_1, \dots, Y_K) \leq \eta^* \left[\sum_{a=1}^K H(X_{P_a}) - H(X_{\mathcal{P}}) \right] \leq \delta^* \left[\sum_{a=1}^K H(X_{P_a}) - H(X_{\mathcal{P}}) \right].$$

进一步,

$$\text{TC}(Y_1, \dots, Y_K) \leq \delta^* \left[\text{TC}(X_{\mathcal{P}}) + \sum_{i \in \mathcal{P}} (\phi_i - 1) H(X_i) \right].$$

右侧第一项 $\text{TC}(X_{\mathcal{P}})$ 是上一层已有依赖; 第二项是同一个父变量被多个局部 channels 重复读取时产生的 fan-out 信息预算。三个系数 $\eta^* \leq \max_a \eta_{\text{KL}}(K_a) \leq \delta^*$ 都是各局部系数的最大值, 其中不含随层宽 K 显式增长的乘积信道惩罚因子; 但 $\max$ 本身当然取遍该层的全部 K 个 channel, 增加新 channel 可能抬高该最大值。要得到一个真正与 K 无关的常数, 需额外假设各局部系数有一致上界 $\delta_a \leq \bar{\delta}$, 此时整层系数也由同一个 $\bar{\delta}$ 控制。

证明. 令 P_U 是重叠父块元组 $(U_1, \dots, U_K)$ 的联合分布。局部 delay 独立性说明给定 U 时 $Y_1, \dots, Y_K$ 条件独立, 即从 U 到 Y 的联合 channel 是乘积

$$K^{\otimes} = \bigotimes_{a=1}^K K_a,$$

这正是引理 6 的前提。于是

$$\text{TC}(Y) \leq \left(\max_{1 \leq a \leq K} \eta_{\text{KL}}(K_a, P_{U_a}) \right) \text{TC}(U_1, \dots, U_K) = \eta^* \text{TC}(U_1, \dots, U_K).$$

由定义 5, 并由假设 3 ($\text{supp}(P_{U_a}) \subseteq \mathcal{U}_a$, 故定理 6 的 δ_a 适用),

$$\eta_{\text{KL}}(K_a, P_{U_a}) \leq \eta_{\text{KL}}(K_a) \leq \eta_{\text{TV}}(K_a) = \delta_a \quad [11, \text{Theorem 1}], [7],$$

故 $\eta^* \leq \delta^*$ 。注意此处只用到单个局部 channel K_a 在其自身输入边缘下的系数, 不需要乘积信道 $K^{\otimes}$ 的 contraction coefficient; 后者一般不等于各分量的最大值, 见注 30。

从 $X_{\mathcal{P}}$ 到 $(U_1, \dots, U_K)$ 的映射只是把坐标复制到各父块中。因为每个 $i \in \mathcal{P}$ 至少出现一次, 该映射在其像上可逆, 故

$$H(U_1, \dots, U_K) = H(X_{\mathcal{P}}).$$

因此

$$\text{TC}(U_1, \dots, U_K) = \sum_{a=1}^K H(X_{P_a}) - H(X_{\mathcal{P}}),$$

得到第一式。最后由 entropy subadditivity,

$$\sum_a H(X_{P_a}) \leq \sum_a \sum_{i \in P_a} H(X_i) = \sum_{i \in \mathcal{P}} \phi_i H(X_i).$$

代入并使用 $\text{TC}(X_{\mathcal{P}}) = \sum_{i \in \mathcal{P}} H(X_i) - H(X_{\mathcal{P}})$, 得到第二式。 $\square$

注 32 (为什么可以取 $\max$ 而不是 $1 - \prod_a(1 - \delta_a)$). 用 maximal coupling 直接估计乘积信道的 Dobrushin 系数只能得到

$$\eta_{\text{TV}}(K^\otimes) \leq \Gamma := 1 - \prod_{a=1}^K (1 - \delta_a),$$

它随输出数 K 增大而趋于 1: 即使每个 δ_a 都很小, 宽层的整层界也会退化为平凡。定理 8 的 $\max$ 形式不是靠断言乘积信道系数等于各分量最大值得到的 (那一断言是错的, 见注 30), 而是靠把 total correlation 沿链式法则分解成 $K - 1$ 个两两互信息项, 再对每一项单独使用一个局部 channel 的固定输入 SDPI (引理 6)。层宽 K 只出现在求和项数上, 而求和恰好重新组装成 $\text{TC}(U)$, 因此收缩系数中不含随 K 显式增长的惩罚因子。这仍不等于说该系数与层宽无关: 加入一个 η 更大的 channel 会抬高 $\max_a \eta_a$; 宽度一致的结论需要一致上界 $\eta_a \leq \bar{\eta} < 1$ 。由于 $\eta^* \leq \delta^* \leq \Gamma$ (后一不等式对 $K \geq 1$ 恒成立), 定理 8 在任何情形下都不弱于 Γ 版本, 且在宽层时严格更强。保留 Γ 只作为 TV 型对照。

注 33 (为什么 fan-out 项不是“凭空创造信息”)。若上一层坐标相互独立, 则 $\text{TC}(X_{\mathcal{P}}) = 0$, 而且

$$\text{TC}(U_1, \dots, U_K) = \sum_{i \in \mathcal{P}} (\phi_i - 1) H(X_i).$$

这正是公共父节点被复制到多个局部输入块所产生的冗余。下游相关性来自这份已存在的父信息被多路读取; max-plus channel 只能按 δ^* 进一步保留或压缩它。

推论 11 (有限状态多层累计信息界). 考虑 L 层有限状态 max-plus DAG, 且每层都满足假设 3。令第 ℓ 层输出为 $X^{(\ell)}$,

$$\mathsf{T}_\ell = \text{TC}(X^{(\ell)}).$$

对从第 $\ell - 1$ 层到第 ℓ 层的传播, 令 $\phi_{\ell i}$ 为上一层节点 i 的 fan-out, 令

$$B_\ell = \sum_{i \in \mathcal{P}_\ell} (\phi_{\ell i} - 1) H(X_i^{(\ell-1)}),$$

并令

$$\delta_\ell^* = \max_{a \in V_\ell} \delta_{\ell, a}.$$

则

$$\mathsf{T}_\ell \leq \delta_\ell^* (\mathsf{T}_{\ell-1} + B_\ell),$$

并且

$$\mathsf{T}_L \leq \mathsf{T}_0 \prod_{j=1}^L \delta_j^* + \sum_{\ell=1}^L B_\ell \prod_{j=\ell}^L \delta_j^*.$$

特别地, 收缩因子 $\delta_\ell^* = \max_{a \in V_\ell} \delta_{\ell, a}$ 只取决于该层中最弱的单个局部 channel: 它是各局部系数的最大值, 不含任何随层宽 $|V_\ell|$ 显式增长的乘积信道惩罚因子 (对照注 31 中 $\Gamma \rightarrow 1$ 的 TV 型上界)。需要强调这不等于是说 δ_ℓ^* 与层宽无关: 向该层加入一个局部系数更大的 channel 会抬高这个最大值 (与定理 8 后的同一说明一致)。准确的表述是: 若存在与层宽无关的一致上界 $\delta_{\ell, a} \leq \bar{\delta} < 1$ ($\forall a \in V_\ell$), 则单纯扩大层宽本身不会改变该一致上界, 因而 (18) 型结论对任意宽度成立。

若进一步存在一致上界 $\delta_\ell^* \leq \bar{\delta} < 1$ 与 $B_\ell \leq \bar{B}$, 则

$$\mathsf{T}_L \leq \bar{\delta}^L \mathsf{T}_0 + \frac{\bar{\delta} \bar{B}}{1 - \bar{\delta}} (1 - \bar{\delta}^L) \xrightarrow{L \rightarrow \infty} \frac{\bar{\delta} \bar{B}}{1 - \bar{\delta}}. \quad (18)$$

注 34 (几何衰减的是初始依赖, 不是总界). 式 (18) 的两项必须分开读, 不能笼统说“累计界随层数几何衰减”。

- (1) 初始依赖 T_0 的贡献按 $\bar{\delta}^L$ 几何衰减；任一固定早期层注入的 B_ℓ 对远端层的贡献同样按 $\bar{\delta}^{L-\ell+1}$ 几何衰减。这两点是收缩性的真实内容。
- (2) 但每层都会注入新的 fan-out 项 B_ℓ 。若这些注入不衰减，累计上界一般收敛到非零渐近上界 $\bar{\delta}B/(1-\bar{\delta})$ ，而不是零。取 $\bar{\delta} = \frac{1}{2}$ 、 $B_\ell \equiv B > 0$ 、 $T_0 = 0$ 即得 $T_L \leq B(1-2^{-L})$ ，随 L 单调上升趋于 B 。这里说的是 (18) 右端这一上界表达式的极限为正常数；它不蕴含实际的 T_L 不趋于零——把它读成误差下界是错误的。为避免这一误读，下文一律称之为“上界残余项”或“非零渐近上界”，不使用“误差地板”。
- (3) 要得到 $T_L \rightarrow 0$ ，需要额外条件：或者 $B_\ell = 0$ （无 fan-out，即每层每个父节点至多被读取一次），或者 $B_\ell \rightarrow 0$ 。后者足够： $\sum_{\ell \leq L} B_\ell \bar{\delta}^{L-\ell+1}$ 是有界零序列与可和核的卷积，故也趋于零。

换言之，本文的多层结论是“上一层依赖被几何遗忘、每层新增依赖被一致压缩到一个可控的上界残余项”，而非“多层之后依赖消失”。

证明. 由定理 8，

$$T_\ell \leq \delta_\ell^* \left[\text{TC}(X_{\mathcal{P}_\ell}^{(\ell-1)}) + B_\ell \right].$$

total correlation 在删除坐标时不增加，这是 KL data processing 的直接结果，所以

$$\text{TC}(X_{\mathcal{P}_\ell}^{(\ell-1)}) \leq T_{\ell-1}.$$

得到单层递推式。对该递推式逐层代入即得累计式。式 (18) 则由在累计式中把 δ_j^* 换成 $\bar{\delta}$ 、 B_ℓ 换成 $\bar{B}$ ，再对几何级数 $\sum_{\ell=1}^L \bar{\delta}^{L-\ell+1} = \bar{\delta}(1-\bar{\delta}^L)/(1-\bar{\delta})$ 求和得到。□

6.5 量化窗口：有限状态界何时非平凡

定理 8 与推论 11 都是有限状态结论，需要先把连续变量量化。本小节明确指出：量化间距同时出现在界的两个因子中，且方向相反，因此必须显式给出非平凡性条件，不能默认“取足够细的网格”就能同时改善两侧。

本小节把量化半径记为 $R_q > 0$ ，以免与层数 L （推论 11）冲突：全文中 L 一律是层数， R_q 一律是量化范围 $[-R_q, R_q]$ 的半径。

设每一层的坐标都被量化到同一个以 $-R_q$ 为起点、间距为 ε 、含于 $[-R_q, R_q]$ 的均匀网格

$$\mathcal{Y}^q := \left\{ -R_q + j\varepsilon : 0 \leq j \leq \lfloor 2R_q/\varepsilon \rfloor \right\} \subset [-R_q, R_q]. \quad (19)$$

(注意 ε 一般不整除 $2R_q$ ，此时右端点 R_q 不一定是格点，网格直径 $\lfloor 2R_q/\varepsilon \rfloor \varepsilon$ 只是至多为 $2R_q$ ；下文只用到“直径 $\leq 2R_q$ ”这一侧。) 为避免“bins 还是 grid points”的歧义，下文一律令

$$N := |\mathcal{Y}^q| = \text{该网格的格点个数} = \left\lfloor \frac{2R_q}{\varepsilon} \right\rfloor + 1, \quad (20)$$

即每个坐标量化后取值于一个基数为 N 的有限集合；本小节全程假设 $N \geq 2$ （等价地 $\varepsilon \leq 2R_q$ ）与 $K \geq 2$ ，此时 $\log N > 0$ 。所有关于熵的估计只用到基数 N 这一件事，不再出现 $\log(2R_q/\varepsilon) + O(1)$ 之类的渐近替代。

量化映射。 仅给出网格集合 (19) 并不足以定义一个有限状态随机过程：还必须指定实数被送到哪个格点。把网格点按升序记为 $y_j := -R_q + j\varepsilon$ ($0 \leq j \leq N-1$)， $y_{\min} := y_0 = -R_q$ 、 $y_{\max} := y_{N-1}$ 。定义带饱和的逐坐标量化器

$$q_{R_q, \varepsilon} : \mathbb{R} \rightarrow \mathcal{Y}^q, \quad q_{R_q, \varepsilon}(u) := \begin{cases} y_{\min}, & u \leq y_{\min}, \\ y_{\min} + \varepsilon \lceil (u - y_{\min})/\varepsilon \rceil, & y_{\min} < u \leq y_{\max}, \\ y_{\max}, & u > y_{\max}, \end{cases} \quad (21)$$

即区间内部取右侧最近格点（上取整），区间外部饱和到最近端点而不是丢弃或另开 overflow bin。等价地， $q_{R_q, \varepsilon}$ 的取值 cell 为

$$C_0 = (-\infty, y_0], \quad C_j = (y_{j-1}, y_j] \quad (1 \leq j \leq N-2), \quad C_{N-1} = (y_{N-2}, +\infty), \quad (22)$$

即 $q_{R_q, \varepsilon}(u) = y_j \iff u \in C_j$ 。饱和保证 $q_{R_q, \varepsilon}$ 处处有定义且值域恰为 $\mathcal{Y}^q$ ，从而量化后的变量确实取值于一个基数为 N 的字母表——本小节所有熵估计只用到这一点。向量情形逐坐标作用，仍记为 $q_{R_q, \varepsilon}$ 。

这里采用上取整而非“取最近格点”是一个有实质后果的选择，需要说明理由。两种约定给出的字母表与熵估计完全相同，但 cell 的端点不同：上取整给出的 (22) 是左开右闭区间，且端点恰好落在网格点 y_j 上，因此量化后的 PMF 是联合 CDF 在已有网格阈值上的普通混合有限差分（见 (32)），既不需要在格点之外补算 CDF 值，也不需要左极限处理边界上的原子；而“取最近格点”给出的 cell 端点是相邻格点的中点 $(y_{j-1} + y_j)/2$ ，它们一般不属于输出网格 $\mathcal{Y}_a$ ，恢复 PMF 时必须额外在中点上求值，并且由于该约定的 cell 是左闭右开的，含原子时还须使用 CDF 的左极限。在量化窗口内部（即 $u \in [y_{\min}, y_{\max}]$ ），两种约定的量化误差 $|q_{R_q, \varepsilon}(u) - u|$ 分别为至多 ε 与至多 $\varepsilon/2$ ；窗口外部两种约定都取饱和值，误差为 $u - y_{\max}$ 或 $y_{\min} - u$ ，随 $|u| \rightarrow \infty$ 无界，没有统一的点态上界，只能由有界支撑、尾概率或截断矩条件另行控制（这一饱和截断与量化窗口的张力见注 36；它与假设 1 无关，后者只规定近似 edge CDF $\hat{F}_{ka}$ 的值域与 clipping，并不定义任何截断误差，且作用于与输出量化器不同的随机对象）。无论如何，本文所有结论都不使用量化误差，只使用字母表基数 N 与父状态直径 $\Delta_a \leq 2R_q$ ，故按与数值网格对齐的便利性选择上取整。

量化后的层变量与量化 channel。 设第 ℓ 层由 (5) 的连续 max-plus 动力学产生原始输出 $\bar{X}^{(\ell)} \in \mathbb{R}^K$ ，其条件律由局部 channel K_a （定理 6）给出。令

$$X^{(\ell)} := q_{R_q, \varepsilon}(\bar{X}^{(\ell)}) \in (\mathcal{Y}^q)^K, \quad (23)$$

并约定：先执行连续 max-plus 运算（含 edge delay 与 node delay），再量化其输出；下一层以量化后的 $X^{(\ell)}$ 作为输入。（另一种约定是先量化各加数再取 max-plus；两者给出的有限状态过程一般不同，本文一律采用前者，因为它使量化只出现在层与层之间的接口上。）记 $Q_{R_q, \varepsilon}$ 为 $q_{R_q, \varepsilon}$ 诱导的确定性 Markov kernel $Q_{R_q, \varepsilon}(u, \cdot) = \delta_{q_{R_q, \varepsilon}(u)}(\cdot)$ （本文用 $Q_{R_q, \varepsilon}$ 而不用 Q ，因为 Q 已分别表示分位数函数、source-dependent 系数中的参考分布、 $\mathcal{T}(T_Y)$ 中的一般树分布以及层分布 Q_ℓ ），则第 a 个坐标的量化 channel 为复合

$$K_a^q := K_a Q_{R_q, \varepsilon}, \quad K_a^q(u, \cdot) = Q_{R_q, \varepsilon}(K_a(u, \cdot)) = \text{Law}(q_{R_q, \varepsilon}(\bar{X}_a) \mid X_{P_a} = u). \quad (24)$$

由于 $Q_{R_q, \varepsilon}$ 不依赖于输入 u ， K_a^q 是 K_a 与一个固定（确定性）后处理的复合，故 data processing 给出

$$\eta_{\text{TV}}(K_a^q) \leq \eta_{\text{TV}}(K_a), \quad \eta_{\text{KL}}(K_a^q, P_{U_a}) \leq \eta_{\text{KL}}(K_a, P_{U_a}). \quad (25)$$

理由是：对任意两个输入分布 μ, ν ， $\|\mu K_a Q_{R_q, \varepsilon} - \nu K_a Q_{R_q, \varepsilon}\|_{\text{TV}} \leq \|\mu K_a - \nu K_a\|_{\text{TV}}$ （ $Q_{R_q, \varepsilon}$ 是 Markov kernel，TV 在 Markov 作用下非扩张），除以 $\|\mu - \nu\|_{\text{TV}}$ 后取上确界即得第一式；KL 版本同理由 $\text{KL}(\mu K_a Q_{R_q, \varepsilon} \parallel \nu K_a Q_{R_q, \varepsilon}) \leq \text{KL}(\mu K_a \parallel \nu K_a)$ 得到。因此定理 6 给出的 $\delta_a \leq \omega_{D_a}(\Delta_a)$ 型 Dobrushin 上界对量化 channel 依然成立，本小节以及定理 8、推论 11 中的 δ_ℓ^* 都可以直接读作 K_a^q 的系数。

这里必须是逐层量化而非只量化输入层：下文的平凡上界 $T_\ell \leq (K-1) \log N$ 用的是第 ℓ 层输出的状态数，仅假设上一层输入被量化到 N 个状态并不能推出输出也只有 N 个状态。在多层递推（推论 11）中第 ℓ 层输出就是第 $\ell+1$ 层输入，因此逐层量化本来就是该递推所需的设定。

注 35（各层网格不同的情形）。若第 ℓ 层的输出网格格点数为 $N_\ell \geq 2$ 、输出坐标数为 $K_\ell \geq 2$ ，则不能简单地把下文的 N 一律读作 N_ℓ ：注入项 $B_\ell = \sum_{i \in \mathcal{P}_\ell} (\phi_{\ell i} - 1) H(X_i^{(\ell-1)})$ 中的熵是上一层坐标的熵，受 $\log N_{\ell-1}$ 控制，而平凡上界用的是本层输出的状态数 N_ℓ 。正确的写法是

$$T_\ell \leq \delta_\ell^*(T_{\ell-1} + \rho_\ell \log N_{\ell-1}), \quad T_\ell \leq (K_\ell - 1) \log N_\ell, \quad (26)$$

相应的非平凡性条件为

$$\delta_\ell^* \left(\frac{T_{\ell-1}}{\log N_\ell} + \rho_\ell \frac{\log N_{\ell-1}}{\log N_\ell} \right) < K_\ell - 1. \quad (27)$$

下文的推论 12 只处理 $N_\ell \equiv N$ 、 $K_\ell \equiv K$ 的同一网格情形，此时 (27) 退化为 (29)。

推论 12 (量化后的界与非平凡性条件). 在上述量化下 (N 由 (20) 定义, $N \geq 2$, $K \geq 2$),

(1) 熵项至多按 $\log N$ 增长: $H(X_i) \leq \log N$, 从而

$$B_\ell \leq \rho_\ell \log N, \quad \rho_\ell := \sum_{i \in \mathcal{P}_\ell} (\phi_{\ell i} - 1) \geq 0.$$

由 (20), $\varepsilon \downarrow 0$ 时 $N \uparrow \infty$, 故该上界发散。发散的并非 B_ℓ 本身: $\log N$ 只是有限状态熵的最坏情形上界, $\varepsilon \rightarrow 0$ 只说明该上界失去内容。对本身离散或退化的上游分布, 实际量化熵可以保持有界 (极端情形下 X_i 只取有限多个值, 熵与 ε 无关); 对具有足够正则密度的连续变量, 实际量化熵通常也按 $\log(1/\varepsilon)$ 增长, 此时上界的定性结论才反映真实行为。

(2) 收缩因子由父状态集合的 ℓ_∞ 直径控制, 而该直径由量化范围而非间距决定: $\Delta_a \leq 2R_q$, 故

$$\delta_\ell^* \leq \max_a \omega_{D_a}(2R_q),$$

与 ε 无关。

因此单层界的乘积形式给出

$$T_\ell \leq \delta_\ell^* (T_{\ell-1} + \rho_\ell \log N), \quad \delta_\ell^* \leq \max_a \omega_{D_a}(2R_q). \quad (28)$$

该界非平凡 (即 (28) 右侧严格小于平凡上界 $(K-1) \log N$, 见下面证明第 (3) 步) 的充分必要条件是

$$\delta_\ell^* \left(\frac{T_{\ell-1}}{\log N} + \rho_\ell \right) < K - 1. \quad (29)$$

分两种情形读 (29):

- 若 $T_{\ell-1}/\log N + \rho_\ell > 0$, 则 (29) 等价于

$$\delta_\ell^* < \frac{K-1}{T_{\ell-1}/\log N + \rho_\ell}; \quad (30)$$

一个只用 δ_ℓ^* 上界即可核验的充分条件是把左端换成 $\max_a \omega_{D_a}(2R_q)$ 。

- 退化情形 $T_{\ell-1}/\log N + \rho_\ell = 0$ (等价于 $T_{\ell-1} = 0$ 且 $\rho_\ell = 0$, 即上一层已无依赖且本层无 fan-out 复制): 此时 (29) 的左端为 $0 < K-1$ 自动成立 ($K \geq 2$), 不需对 δ_ℓ^* 作任何限制; 事实上 (28) 直接给出 $T_\ell \leq 0$, 即输出各坐标独立。

上述推导中每一步都是精确不等式变形, 不涉及 $O(1)$ 项或“同阶”替换: 除以 $\log N > 0$ 是等价变形, 这正是要求 $N \geq 2$ 的原因; 要求 $K \geq 2$ 则是因为 $K=1$ 时平凡上界本身为 0, 任何界都不可能严格更小。特别地, 当 fan-out 总量 ρ_ℓ 与输出数 K 同阶时, (30) 退化为要求 δ_ℓ^* 一致小于某个与 ε 无关的常数。最后强调 (29) 是把 B_ℓ 换成其最坏情形上界 $\rho_\ell \log N$ 之后得到的: 若实际量化熵远小于 $\log N$, 则该条件不满足时界仍可能非平凡。

证明. (1) 有限状态熵不超过 $\log$ (状态数)。 (2) 定理 6 中的 $\delta_a \leq \omega_{D_a}(\Delta_a)$ 只用到父状态集合的 ℓ_∞ 直径; 由 (19), 量化网格的直径至多为 $2R_q$ (与间距 ε 无关), 而 ω_{D_a} 非降, 故 $\delta_a \leq \omega_{D_a}(2R_q)$ 。把两者代入推论 11 的单层递推式即得。

(3) 平凡上界: 第 ℓ 层的 K 个输出坐标各取至多 N 个值, 故

$$T_\ell = \sum_{a=1}^K H(X_a^{(\ell)}) - H(X^{(\ell)}) \leq \sum_{a=1}^K H(X_a^{(\ell)}) - \max_a H(X_a^{(\ell)}) \leq (K-1) \log N,$$

其中用到 $H(X^{(\ell)}) \geq \max_a H(X_a^{(\ell)})$ (离散熵在增加坐标时不减)。这比 $K \log N$ 紧一个 $\log N$, 且在 $K = 1$ 时给出正确的 $T_\ell = 0$ (这也是非平凡性讨论要求 $K \geq 2$ 的原因)。把 (28) 的右端与 $(K - 1) \log N$ 比较、两边同除 $\log N > 0$ (由 $N \geq 2$)，即得 (29)；这是等价变形，故 (29) 既充分又必要。□

注 36 (两个方向相反的推动力). 推论 12 说明：细化网格 ($\varepsilon \downarrow$) 会放大目前可得的最坏情形 entropy 上界 $\log N$ ，却完全不改善 δ_ℓ^* ；反过来，缩小量化范围 R_q 能改善 δ_ℓ^* ，但会加重 (21) 的饱和：落在 $[-R_q, R_q]$ 之外的质量被压到两个端点格点上，量化后的过程与原连续过程的偏差随之增大 (有限状态结论本身仍然成立，因为 $q_{R_q, \varepsilon}$ 处处有定义，但它描述的已经是一个被显著截断的代理过程)。需要强调这里的张力发生在界的层面：没有额外分布假设时，不能由 $\log N \uparrow$ 推出实际 B_ℓ 必然增大或发散；对具有足够正则密度的连续变量，实际量化熵通常也按 $\log(1/\varepsilon)$ 增长，此时张力才是实质的。因此该有限状态界的正确用法是：先由问题本身确定一个物理合理的取值范围 R_q (例如高概率截断区间)，检验 $\max_a \omega_{D_a}(2R_q)$ 是否满足上述条件，再选取满足计算预算的 ε 。把 $\varepsilon \rightarrow 0$ 当作“逼近连续极限”会使界发散，得不到连续版本的结论。

这也解释了为什么本文把连续 pair 界 (定理 7) 与有限状态整层界 (定理 8) 分开陈述：前者不经过量化，因而不受本小节的张力影响。

6.6 与 tree projection 的连接：经典恒等式和新预算的组合

本小节的对象是概率质量函数，不是 CDF 数值表。沿用 §6.5 的量化器 (21)，令

$$R(y) := \mathbb{P}[q_{R_q, \varepsilon}(Y) = y], \quad y \in (\mathcal{Y}^q)^K, \quad (31)$$

即量化后输出向量的 PMF；它非负且 $\sum_y R(y) = 1$ (因为 $q_{R_q, \varepsilon}$ 处处有定义且取值于 $\mathcal{Y}^q$)。本节出现的 TC_R 、 I_R 、 D_{KL} 全部按这个 PMF 计算。这一点必须显式说明：本文前面各节计算的数值对象是网格上的联合 CDF 表 $\hat{F}_M$ 、 $\hat{F}_Y$ ，而 entropy、mutual information 与 KL projection 需要的是归一化非负的 PMF，直接把 CDF 表当成 PMF 会得到错误的熵与 KL。若实现从 CDF 表出发，则相应的 PMF 应由网格 cell 上的混合有限差分得到。这里必须把两个对象分开：由真实联合 CDF F_Y 差分得到的是精确 PMF (31)，由数值 CDF 表 $\hat{F}_Y$ 差分得到的只是它的一个数值近似。对 $y = (y_1, \dots, y_K)$ ，前者为

$$R(y) = \sum_{\sigma \in \{0,1\}^K} (-1)^{K-|\sigma|} F_Y(y_1 - (1 - \sigma_1)\varepsilon, \dots, y_K - (1 - \sigma_K)\varepsilon), \quad (32)$$

后者为

$$\hat{R}(y) := \sum_{\sigma \in \{0,1\}^K} (-1)^{K-|\sigma|} \hat{F}_Y(y_1 - (1 - \sigma_1)\varepsilon, \dots, y_K - (1 - \sigma_K)\varepsilon). \quad (33)$$

(32) 是一条恒等式 (下段给出证明)，而 (33) 只是一个定义：除非 $\hat{F}_Y = F_Y$ ，一般 $\hat{R} \neq R$ ，二者的差距见注 37。两式中最外侧 cell 按 (21) 的饱和规则读取：最小格点 $y_a = y_{\min}$ 处的那一维取整条左尾 (把 $y_a - \varepsilon$ 读作 $-\infty$ 、相应 CDF 值读作 0)，最大格点 $y_a = y_{\max}$ 处的那一维取整条右尾 (把该维阈值读作 $+\infty$ 、相应 CDF 值读作对其余坐标的边缘)。

(32) 与 (21) 是逐点相容的，而不是仅在无原子时近似相容：由 (22)，量化器把第 a 维的取值 cell 取成左开右闭区间 $(y_a - \varepsilon, y_a]$ (最外两个 cell 分别延伸到 $-\infty$ 与 $+\infty$)，故

$$\{q_{R_q, \varepsilon}(Y) = y\} = \left\{ Y \in \prod_{a=1}^K (y_a - \varepsilon, y_a] \right\}$$

(同样按上述尾部约定理解最外侧 cell)，其概率恰为矩形上的容斥式 (32)。这里全部阈值 $y_a - \varepsilon, y_a$ 都是网格点 (19) 本身，因此不需要在格点之外补算 CDF；又因为 cell 右端闭、左端开， $F_Y(u) = \mathbb{P}[Y \leq u]$ 的右连续版本直接给出所需概率，即使 Y 在格点上带原子也不需要左极限。若改用“取最近格点”的量化器，cell 端点变为中点 $(y_a - \varepsilon/2, y_a + \varepsilon/2)$ ，两条性质都会失效——这正是本文在 (21) 中选择上取整的原因。

这里需要把两件性质分开。总质量自动成立：在上述 $-\infty/+\infty$ 尾部约定下，把 (33) 对全部 N^K 个格点求和时，每一维的差分依次 telescoping，含 $-\infty$ 的下边界项取 0、含 $+\infty$ 的上边界项取相应边缘，故

$$\sum_{y \in (\mathcal{Y}^q)^K} \hat{R}(y) = \hat{F}_Y(+\infty, \dots, +\infty) = 1,$$

且该恒等式不要求 $\hat{F}_Y$ 是 K -增函数，也不要求它在网格内部数值准确——它只要求实现严格采用了上述边界约定。非负性则可能失败：数值 CDF 表未必是合法的 K -增函数（假设 1 下的截断、求积与 clipping 都不保证这一点），因此 (33) 得到的 $\hat{R}$ 可能出现负 cell，仍然不是合法 PMF。于是实现中的检验应这样理解：非负性是实质条件，必须显式检验，否则以 $\hat{R}$ 代入本小节的信息量根本没有定义；而求和是否为 1 只用来检查实现是否真的遵守了尾部约定以及浮点舍入的累积量级，若它显著偏离 1，说明顶角未按 $\hat{F}_Y(+\infty, \dots, +\infty) = 1$ 读取，而不是公式本身不归一。

注 37 (数值差分的误差放大：本小节预算的适用边界)。必须强调，本小节的 tree budget (命题 5 及其推论) 的理论对象是精确量化 PMF (31) (等价地 (32))，而不是由数值 CDF 表差分得到的 $\hat{R}$ (式 (33))。二者的差距不由前文的 CDF 误差预算自动控制：把 (33) 与 (32) 逐项相减， 2^K 个符号项给出的直接界只是

$$|\hat{R}(y) - R(y)| \leq 2^K \|\hat{F}_Y - F_Y\|_\infty,$$

把它对全部 N^K 个格点求和以估计 $\|\hat{R} - R\|_1$ 时还要再乘以 cell 数目。因此 $\|\hat{F}_Y - F_Y\|_\infty$ 的小并不蕴含 $\hat{R}$ 的 entropy、mutual information 或 KL 与 R 的相应量接近，而且熵与 KL 在 ℓ_1 下的稳定性也不是同一件事：

- 有限字母表上的熵有 Fannes–Audenaert 型一致连续性估计，它由 $\|\hat{R} - R\|_1$ (连同字母表大小 N^K) 控制 $|H(\hat{R}) - H(R)|$ ；mutual information 与 total correlation 是有限多个熵的线性组合，因而同样可控。但使用该估计有一个前提： $H(\hat{R})$ 只有在 $\hat{R}$ 已经通过非负性检验 (从而合法 PMF) 时才有定义。若 $\hat{R}$ 含负 cell，应先按下文的方式得到合法化的 $\hat{R}^+$ ，把连续性估计用于 $|H(\hat{R}^+) - H(R)|$ ，并把合法化本身引入的偏差 $\|\hat{R}^+ - \hat{R}\|_1$ 一并计入误差。
- KL 则没有这种由 ℓ_1 小推出的上界。Pinsker/Csiszár–Kullback 不等式 $\text{KL}(P\|Q) \geq 2\|P - Q\|_{\text{TV}}^2$ 的方向恰好相反——它由 KL 小推出 TV 小，不能反用。事实上取 $P_\delta = (\delta, 1 - \delta)$ 、 $Q = (0, 1)$ 有 $\|P_\delta - Q\|_{\text{TV}} = \delta \rightarrow 0$ 而 $\text{KL}(P_\delta\|Q) = +\infty$ 。要得到 KL 的上连续性，必须另加共同支撑、参考分布的正下界或似然比一致有界之类的条件。

要把定理 4 的闭合 CDF 预算真正接到本小节的信息量上，必须另行给出 (i) 从 CDF sup 误差到 PMF ℓ_1 误差的、与 N^K 相容的稳定性论证，或 (ii) 一个受控的合法化投影：先把可能带负值的 $\hat{R}$ 化为一个合法 PMF——注意此时不能直接谈“KL 最近点投影”，因为 KL 对含负分量的 signed array 未定义；可行的做法是在 ℓ_1 或 Euclidean (欧氏) 距离下投影到概率单纯形 (或取正部后归一化)，得到非负的 $\hat{R}^+$ 之后，才可以再讨论以 $\hat{R}^+$ 为参考的 KL 投影及其方向与支撑约束——并对合法化引入的额外 ℓ_1 偏差给出显式界。仅检验非负性 (连同尾部约定与求和的舍入量级) 只保证信息量有定义，不给出任何误差上界。本文不声称已完成 (i) 或 (ii)；本小节的所有结论都在精确 R 上陈述。

设 T_Y 是下游输出坐标 $\{1, \dots, K\}$ 上的一棵连通树 (例如由 Chow–Liu 从数据估计得到)，它与承载上游 TTNS 的树 T 一般不是同一个对象，本节全程用 T_Y 以避免混淆。把 T_Y 任意定向为以某个 $r \in \{1, \dots, K\}$ 为根的有根树，记 $\text{pa}(v)$ 为 v 在该定向下的父节点。定义按 T_Y 分解的分布族为

$$\mathcal{T}(T_Y) := \left\{ Q : Q(y) = Q_r(y_r) \prod_{v \neq r} Q_{v|\text{pa}(v)}(y_v | y_{\text{pa}(v)}) \right\}, \quad (34)$$

其中 Q_r 是 $\mathcal{Y}^q$ 上的任一 PMF， $Q_{v|\text{pa}(v)}(\cdot | u)$ 是对每个 $u \in \mathcal{Y}^q$ 给定的一个 PMF。这里刻意采用有根条件分解而不是对称形式 $\prod_a Q_a(y_a) \prod_{(a,b) \in E(T_Y)} Q_{ab}(y_a, y_b) / (Q_a(y_a) Q_b(y_b))$ ：后者在

$Q_a(y_a) = 0$ 的状态上出现 0/0, 因而在含零概率状态的有限字母表上 没有定义 (例如 $K = 2$ 、全部质量集中在 $(0, 0)$ 时, 状态 $(1, 1)$ 处即为 0/0), 而离散化后出现零 cell 是常态, 不能靠附加“严格正”假设排除。(34) 处处有定义: 当 $Q_{\text{pa}(v)}(u) = 0$ 时该父状态不可达, $Q_{v|\text{pa}(v)}(\cdot | u)$ 可任意指定而不改变联合分布 Q , 因而 $\mathcal{T}(T_Y)$ 作为分布集合是良定义的; 在 Q 严格正时 (34) 与上述对称形式逐点相等, 故经典 Chow–Liu 结论不受影响。约定 $K = 1$ 时 $E(T_Y) = \emptyset$ 、 $\mathcal{T}(T_Y)$ 为全体 PMF。

用 R 的真实节点 marginals 和 tree-edge marginals 构造的 tree projection 记为 $R^{T_Y} \in \mathcal{T}(T_Y)$, 即取 $R_r^{T_Y} = R_r$ 、 $R_{v|\text{pa}(v)}^{T_Y}(\cdot | u) = R_{v|\text{pa}(v)}(\cdot | u)$ (在 $R_{\text{pa}(v)}(u) = 0$ 的不可达父状态上任意取一个 PMF); 它同时是 R 在 $\mathcal{T}(T_Y)$ 上的 KL projection [6]。经典 Chow–Liu 恒等式为 [6]

$$D_{\text{KL}}(R \| R^{T_Y}) = \text{TC}_R(Y_1, \dots, Y_K) - \sum_{(a,b) \in E(T_Y)} I_R(Y_a; Y_b).$$

它本身不是本文原创。

对每条候选 tree edge 定义有限状态父信息预算

$$\mathcal{B}_{ab} = \beta_{ab} [H(C_{ab}) + I(A_{ab}; B_{ab} | C_{ab})].$$

命题 5 (tree 结构损失的预算区间). 在上述条件下,

$$\begin{aligned} \max \left\{ 0, \text{TC}_R(Y) - \sum_{(a,b) \in E(T_Y)} \mathcal{B}_{ab} \right\} &\leq D_{\text{KL}}(R \| R^{T_Y}) \\ &\leq \text{TC}_R(Y) \\ &\leq \delta^* \left[\text{TC}(X_{\mathcal{P}}) + \sum_{i \in \mathcal{P}} (\phi_i - 1) H(X_i) \right]. \end{aligned}$$

证明. pair 信息预算给出 $I_R(Y_a; Y_b) \leq \mathcal{B}_{ab}$ 。把它代入 Chow–Liu 恒等式, 并使用 KL 非负性, 得到第一行。第二行来自 tree-edge mutual information 非负; 第三行是 fan-out 信息预算定理 8。□

7 相关工作

本节给出定位而非完整综述。以下条目按来源分别核对: 期刊与会议条目的作者、卷期页码与 DOI 按 Crossref 记录核对; 预印本条目 ([1, 2, 17, 26]) 按 arXiv 原始记录核对, 其 DOI 由 DataCite 而非 Crossref 注册。[22] 与 [20] 均已正式发表于 *Physical Review Research* (以正式刊为准, 同时保留 arXiv 号); [13] 已被 COLT 2026 接收, 正文按接收状态引用, 会议论文集页码待出版后补。正式投稿时仍需按目标期刊的引用格式重排, 核对其余预印本是否已有正式出版版本, 并核对是否有更新的版本或勘误。

7.1 max-plus 系统与随机最长路

max-plus 代数与 $(\max, +)$ 线性系统的系统性处理见 Baccelli、Cohen、Olsder 与 Quadrat 的专著 [3]。本文的层间映射 $Y_a = \max_{k \in P_a} (X_k + E_{ka}) + D_a$ 正是随机 $(\max, +)$ 递推的单层形式, 区别在于: 该专著关注 Lyapunov 指数与遍历性等长时行为, 本文关注固定层数下联合分布的可计算表示与误差。

随机最长路分布的近似有很长的历史。Clark [5] 给出相关正态变量最大值的矩公式, 是后续 statistical static timing analysis (SSTA) 中矩传播方法的源头; Blaauw 等的综述 [4] 总结了 EDA 领域从矩传播到 canonical form 的工程做法。Mishaghi、Koskin 与 Blokhina [17] 在 gate-level SSTA 中给出了 block-based 传播的精确解析解: 其设定是相关高斯 arrival signals 经过一个 gate, gate delay 单独给定, 所得的 gate 输出 ($\max$ 之后再加 delay) 分布被精确地写成非高斯形式, 并用高斯梳 (Gaussian comb) 分解把该非高斯分布重新表示为若干高斯分量

之和，以便继续向下一级传播。这说明“在 max-plus/SSTA 中精确传播非高斯分布”本身已有直接相关工作，本文不主张这一点为新。两者的区别在于：[17] 的上游是逐 gate 给定的相关高斯 arrival signals (低维参数化)，传播沿电路图逐级进行；本文的上游是一个给定的 TTNS 张量表示，并且输出是含共享父的多维 joint CDF，其计算代价由联合结构图的树宽给出条件性上界。

Hagstrom [16] 证明了 PERT 网络完工时间分布的精确计算在计算上是难的，这是注 19 中不平凡性讨论的依据。**树宽已被用于随机最长路分布，本文不主张这一点为新。** Ando [1] 已经研究常数树宽 DAG 上随机边长的最长路长度分布函数：该文给出一个确定性 FPTAS (在树宽 $\leq k$ 为常数时以 $O(k^2 n (16(k+1)mn^2/\epsilon)^{4k^2+6k+2})$ 计算 $\Pr[X_{\max} \leq x]$ 的 ϵ -近似)、一个至多 $n-1$ 重的重复定积分表示，以及在 edge 长度服从 i.i.d. 标准指数分布时的 $((4k+2)mn)^{O(k)}$ 精确算法。与本文的区别是：[1] 的对象是单个标量 $s-t$ 最长路长度的一维分布函数，参数图是问题图本身，随机性只来自 edge 长度；本文的对象是一层的多维联合 CDF (含 node delay 与共享父引起的输出间相关)，参数图是把 TTNS 树、fan-in/fan-out 与输出集合合成的联合结构图 $\mathcal{G}_S/\mathcal{G}_S^+$ ，上游随机性由一个给定的 TTNS 张量表示携带。

与本文时间上最接近的工作是 Ando [2]：它把 #P-难性从离散 edge 长度推广到 i.i.d. 连续 edge 长度，并给出以底层无向图树宽 k 为参数的 $O(n^{2k^2+2k+2})$ 算法。该结果与本文定理 5 的对象、随机性来源、参数图与指数形式均不相同，详细对比见注 20；它是本文非平凡性的背景，而非本文结论的特例。与整条 SSTA 路线相比，本文不做矩近似，而在 CDF 域给出精确恒等式 (定理 1)，并把可计算性归结为单一结构参数 (定理 5)。

7.2 张量网络密度表示

TT 分解与其现代形式见 Oseledets [19]；把张量列车用于密度估计的代表工作是 TTDE [18]。张量网络与概率图模型的结构对应 (含非负分解与 treewidth 的关系) 见 Robeva 与 Seigal [23]；基于张量列车的高维分布逼近与采样见 Dolgov、Anaya-Izquierdo、Fox 与 Scheichl [14]。Roa-Villescas 等 [22] 给出了以张量网络收缩统一处理概率图模型推断 (配分函数、边缘分布、MAP) 并结合可微编程的一般框架，说明“用张量网络收缩做概率推断、边缘化与复杂度分析”已是成熟框架，本文不主张这一点为新。本文与这一路线的关系是：把 TTNS 作为给定的上游表示，研究它经过 max-plus 层之后的像如何精确刻画与近似——被收缩的因子中含有由 max 运算与 node delay 生成的 edge-CDF 因子 $\Phi_{ka}(\xi_k, v_a) = F_{ka}(y_{v_a}^{(a)} - x_{\xi_k}^{(k)})$ 。标准 PGM $\rightarrow$ TN 字典允许一般的局部因子，因而完全能够容纳这类二元因子；本文的工作不是扩展该字典的表达能力，而是从共享父的 max-plus 事件中系统地推导出这些 edge-CDF 因子，并分析由此得到的特定联合结构图。定理 5 使用的 sum-product 与 treewidth 论证本身是这一领域的标准工具。

与本文更近的一条线是把多元函数的局部因子结构直接编译成张量网络、再据此分析高维积分复杂度。Peng、Gray 与 Chan [20] 把多变量函数的 arithmetic circuit 映射为张量网络，并按 circuit 结构给出高维积分的收缩代价分析。本文 §5 的联合结构图属于同类思路：局部因子 (这里是 edge-CDF 因子 Φ_{ka}) 决定图，图的 treewidth 决定收缩代价。区别在于本文的因子不是给定 circuit 的算术门，而是由共享父的 max-plus 事件 $\{Y_a \leq y_a\}$ 推导出来的，且上游被限定为一个给定的 TTNS 密度；该文不含本文的共享父 stochastic max-plus joint-CDF 定理。

还需要区分两种同名的“max-plus”。[22] 等工作中的 tropical / max-plus 张量网络指的是把张量元素取在 $(\max, +)$ 半环上、用半环收缩求解 MPE/MAP 一类优化问题：那里 max 出现在收缩算子里。本文的 max-plus 是随机动力学 (5) $Y_a = \max_{k \in P_a} (X_k + E_{ka}) + D_a$ ：max 出现在被建模的随机变量里，而一旦把事件 $\{Y_a \leq y_a\}$ 转写成 edge-CDF 因子的乘积 (定理 1)，实际执行的收缩就是普通的 sum-product 积分，半环仍是 $(+, \times)$ 。二者名称相似但数学角色不同，本文并不是把张量网络的半环换成 max-plus。

7.3 信息收缩与强数据处理不等式

Dobrushin 系数与 KL contraction 的经典关系见 Cohen 等 [7]；带输入约束的强数据处理不等式 (SDPI) 与 F_I 曲线见 Polyanskiy 与 Wu [10, 11] 以及 Calmon、Polyanskiy 与 Wu [12]。引理 6 依赖的唯一外部结果是固定输入 contraction coefficient 的互信息刻画 [11, Theorem 4] (其 input-independent 版本为该文 eq. (17)，有限字母表情形见 [8, Exercise III.3.12])。本文不使用乘积信道的 input-independent 系数张量化；该等式一般不成立，反例与失效机理见注 30，其中

也说明为何经 $\eta_{\text{KL}} = \eta_{\chi^2}$ [11, Theorem 3] 与最大相关张量化 [25, Theorem 1] 的路线不能用于此处。噪声计算电路中的信息衰减 (Evans 与 Schulman [15]) 给出了“每层收缩、多层累计”这一论证模式的早期范例, 本文推论 11 属于同一模式在 max-plus 层上的实例。SDPI 与 Φ -Sobolev 不等式的系统处理见 Raginsky [21]。total correlation 的定义与基本性质见 Watanabe [24], tree 逼近的 KL 恒等式见 Chow 与 Liu [6]。

“total correlation + 逐维 SDPI”这一组合本身不是本文首创。Yuan、Jeong 与 Aghazadeh [26] 在离散扩散模型的误差分析中, 已经把乘积转移核 $q_{t|s}^{\otimes D}$ 与 source-dependent KL contraction coefficient $\eta_{\text{KL}}(p_s, q_{t|s})$ 用于逐维 KL 误差传播 (其 Theorem 3.1 给出 masking/uniform 两类前向过程的收缩系数), 并在附录的多维推广中引入 total-correlation 型修正项以刻画“各维近似独立时误差收缩最有效”这一现象; 其 SDPI 依据同样是 Raginsky [21]。Dmitriev、Huang 与 Wei [13] 则在离散扩散的 τ -leaping 采样复杂度分析中引入 *effective total correlation*, 并证明该量控制 masking 扩散的收敛速率 (可远小于平凡界 $d \log S$)。二者都表明“total correlation 这一泛函 + 逐维收缩系数”的组合在别处已被使用。本文与 [26] 的具体区别有三点:

- (i) **是否存在复制结构。**[26] 的乘积转移把 D 个维度 一一对应地映射, 输入维与输出维之间没有 fan-out; 本文的 max-plus 层允许同一个父块 X_i 被 ϕ_i 个不同的下游节点同时读取, 正是这一复制结构产生了定理 8 中的注入项 $\sum_i (\phi_i - 1) H(X_i)$ ——该项在无复制时为零, 因而在 [26] 的设定下不出现。
- (ii) **局部信道的来源。**[26] 的局部信道是扩散过程的逐维转移核; 本文的局部信道是 $Y_a = \max_{k \in P_a} (X_k + E_{ka}) + D_a$, 其 contraction 系数由 max 映射的 ℓ_∞ 非扩张性与 node-delay 分布的平移 TV 模量显式给出 (定理 6), 是一个可由建模量直接计算的界, 而非抽象假设。
- (iii) **结论用途。**[26] 用于解释随机性的纠错效应; 本文用于给出层间依赖的预算与多层非零上界残余项 (推论 11), 并进一步接到 Chow–Liu 恒等式上界定 tree projection 的结构损失。

因此本文可主张的是 (i)–(iii) 这一具体组合在 max-plus fan-out 场景下的量化, 而不是“total correlation 经局部信道收缩”这一一般思路。需要说明的是: [26, 13] 都没有证明本文引理 6 形式的不等式 $\text{TC}(Y) \leq (\max_a \eta_a) \text{TC}(U)$; 把该结论归给它们同样是不准确的。准确的表述只是: total-correlation 型修正项与逐维 SDPI 已被用于乘积转移的多维 KL 误差分析与采样复杂度分析。

7.4 本文的定位

上述四条线索中, $(\max, +)$ 递推、张量网络收缩、SDPI 与 Chow–Liu 恒等式都是成熟工具, 本文不主张其中任何一件为新结果。可以合理主张的只有它们在本设定下的具体组合与量化, 即下面四条:

- (1) 在给定的 TTNS 表示下, 构造含共享父节点的多输出 max-plus 层的精确 joint-CDF 收缩表示 (定理 1), 以及 node-delay 的张量积分解 (命题 1);
- (2) 把局部投影误差、TTNS sensitivity、node-delay 求积、输出网格插值与边界钳制组织成一个闭合的单层误差预算 (定理 4), 并给出该预算在固定网格点数下的显式正下界 (命题 4);
- (3) 构造为本文 TTNS max-plus 设定定义的联合结构图 $\mathcal{G}_S/\mathcal{G}_S^+$ (定义 4), 使 TTNS 树结构、fan-in/fan-out 与输出集合 S 共同以单一参数进入复杂度结论 (定理 5): 树宽给出一个条件性的收缩复杂度上界, 并可同时恢复与完整输出规模一致的下界 (注 18);
- (4) 在 max-plus fan-out 场景中, 把固定输入 SDPI 与父块复制结构结合, 得到具体的信息预算 (定理 8) 与多层非零上界残余项 (推论 11), 并显式界定其有限状态版本的非平凡量化窗口 (推论 12)。

本文明确不主张为原创的内容。为避免误读, 以下各项均为已有结果或标准工具, 本文只是使用它们: Fubini 定理与独立分量的卷积表示; 张量网络收缩代价受 treewidth 控制 ([23, 22]); 树宽可用于随机最长路的分布计算 ([1, 2]); Dobrushin 系数、数据处理不等式、强数据处理

不等式与 total correlation 的链式法则 ([7, 10, 11, 21, 24])；Chow–Liu 恒等式 ([6])；以及 source-dependent KL contraction coefficient 与 total-correlation 型修正项在乘积转移多维误差分析中的使用 ([26, 13])；在 max-plus/SSTA 中精确传播非高斯分布 ([17])。

本文不使用“首次”“首个”“此前无人提出”或等价措辞。若在后续版本中使用“to the best of our knowledge”，必须紧跟上面 (1)–(4) 中某一条被精确限定的对象（例如“据我们所知，尚无工作把 TTNS 树结构、fan-out 与输出集合合成单一联合结构图并以其树宽给出多输出 max-plus 层 joint CDF 计算代价的条件性上界”），而不能用于本小节列出的任何一般性工具。

8 适用范围与局限

8.1 本文结论的适用范围

四条定理共同支持以下层间传播主张。

- 若上游层已经由 TTNS 表示，则 max-plus 层的 joint CDF 有精确收缩公式（定理 1）；共享父节点不破坏局部一维投影，共享依赖保留在同一个局部积分变量中。
- 当 node delay 各分量独立时，外层期望是逐轴卷积算子的张量积（命题 1）。该分解带来的节省有一个必须保留的限定：在已持有完整的 G^K 中间数组 $\hat{F}_M$ 、且每轴用 n_D 个求积点的前提下，额外的逐轴卷积代价为 $O(Kn_D G^K)$ 而非 $O(n_D^K G^K)$ ，即对 K 为线性而非指数。这不等于整个 joint CDF 的计算对 K 是线性的——完整输出数组本身仍有 G^K 个元素，其代价由定理 5 支配。若只需单个 joint CDF 点、又不持有 $\hat{F}_M$ 或其他低秩表示，仅凭 Fubini 分解一般不能把函数求值次数从 n_D^K 降到 Kn_D 。
- 局部投影近似误差按 TTNS sensitivity 加权进入 CDF 误差；同一输入配置下的全部 sensitivity 可由两次 sweep 同时算出（命题 2），而误差预算实际需要的有序 hybrid sensitivity 在把 telescoping 顺序取为后序遍历后可由三次 sweep 同时算出（命题 3），因此该误差分解可以作为可执行的自适应精化判据。
- 截断、局部求积与 edge CDF 近似（三者经 sensitivity 加权，合为 ϵ^{loc} ），加上外层 node-delay 求积、卷积网格插值与边界钳制（三者经非扩张算子 telescoping 直接相加，即 $\epsilon^{\text{eq}}, \epsilon^{\text{grid}}, \epsilon^{\text{bdry}}$ ），合成一个闭合的单层预算（定理 4），并给出显式收敛率（推论 3）。
- 联合 CDF 的计算代价有一个由联合结构图树宽参数化的条件性上界（定理 5），并可同时恢复与完整输出规模一致的下界（注 18）；平方 TTNS 不改变联合结构图及其 treewidth 指数；它把 rank 与物理域大小从 r, m 替换为 r^2, m^2 ，故若把代价重新表示成原始 r, m 的函数，相应幂次加倍（推论 9）。这里的下界来自材料化整张输出表所需的 G^s 个元素，不是对实例复杂度的一般 treewidth 下界：特殊因子即使联合图树宽很高也可能容易收缩。凡需要精确复杂度处应引用定理 5 的分项表达式；把两项合并成单一指数时须取 $W^{\text{tw}(\mathcal{G}_S^+)+2}$ 而非 $+1$ （注 17）。表 §5.5 给出的具体拓扑数值由一个确定性审计脚本生成，联合结构图顶点数超过 21 时为上界而非精确树宽。
- 在局部 delay 独立且父状态直径有限时，max-plus channel 的信息 contraction 由一维 node-delay 平移 TV 模量显式控制（定理 6）。
- 整层 total correlation 的收缩因子可取为各局部 channel 在其自身输入边缘下 KL contraction coefficient 的最大值（引理 6、定理 8），不含随层宽显式增长的惩罚因子；多层累计中初始依赖按层数几何衰减，但每层新增的 fan-out 注入使总上界一般停在一个非零渐近上界（上界残余项）上（推论 11 与注 34）；该残余项是上界表达式的极限，不蕴含实际 total correlation 的非零下界。该结论不依赖乘积信道 input-independent 系数的张量化（后者一般不成立，见注 30）。
- 在有限网格上，经典 tree projection 恒等式可以与上述信息预算组合，得到 tree 结构损失的上下预算区间。

8.2 不由本文结论推出的内容

以下几条本文明确不予主张，列出以便读者界定范围。

- 本文不涉及非凸 TTNS 参数优化的全局收敛性； $R_\ell^{TY} \rightarrow Q_\ell$ 一步是优化问题，不在本文三条主线之内。
- 不在缺少 C^2 光滑性时宣称梯形公式有二阶收敛（注 14）。
- Chow–Liu 恒等式、Pinsker 不等式、DPI/SDPI、Dobrushin 系数与 product-channel contraction 均为经典工具，本文不主张其为新结果。
- 不从 $\delta_a \leq 1$ 推出严格信息衰减；严格衰减需验证 $\delta_a < 1$ ，或使用 source-dependent / nonlinear SDPI。
- 不把有限网格 total correlation 界直接当作原始连续 TTNS 分布的界；两者的关系受推论 12 的量化窗口约束。
- 定理 5 是“给定树分解即可达到”的条件性上界；精确计算树宽本身是 NP-难的（注 19）。

8.3 必须保留的技术边界

1. **局部噪声独立性。**定理 1 允许 node-delay 向量相关，因为它只对 D 的联合分布取外层期望；但命题 1 的张量积分解与定理 8 的信息预算都要求不同输出的局部 delay 随机源独立。若 $D_a = D_b = Z$ 是同一个非退化随机变量，而父输入都是常数，则 $I(U_a; U_b) = 0$ ，但 $Y_a = Y_b = Z$ 且 $I(Y_a; Y_b) = H(Z) > 0$ （离散 Z 时）。因此相关公共噪声可以自行注入输出依赖，原信息预算不再成立。
2. **连续共享父变量。**若 U_a 和 U_b 精确共享一个非原子连续变量，则 $I(U_a; U_b)$ 通常为无穷，因为联合分布位于 product space 的对角子流形上。所以不能把有限状态公式

$$I(U_a; U_b) = H(C_{ab}) + I(A_{ab}; B_{ab} | C_{ab})$$

机械改成 differential entropy。连续情形应使用本文给出的 $I(C_{ab}; Y_a)$ 、 $I(C_{ab}; Y_b)$ 和 conditional MI 版本，或者先明确量化尺度再分析有限网格变量。

3. **compact-support noise 的退化界。**若 $D_a \sim \text{Uniform}[0, w_a]$ 且 $\Delta_a \geq w_a$ ，则平移模量上界为 1。这不是证明失败，而是说明仅凭全局直径和该 node noise 无法保证严格 contraction。此时可以从局部条件 CDF 直接计算更紧的 δ_a ，但不能假设 edge noise 必然把它降到 1 以下。
4. **无界输入。**若 $\Delta_a = \infty$ ，则全局 Dobrushin 系数对常见 additive-noise channels 往往等于 1。这时应使用有限支撑/高概率截断后的定理，或引用带 input constraint 的 nonlinear SDPI；不能写全局指数衰减 [10, 12]。
5. **没有普适的正下界。**仅凭上一层 total correlation 和 DAG topology，无法给下一层 $\text{TC}(Y)$ 或 tree 损失提供正下界：把独立 node noise 放大到足够强，可以让各输出任意接近独立。因此 tree 损失下界中保留实际 $\text{TC}_R(Y)$ 不是形式缺陷，而是一般情形下不可消除的信息。
6. **TTNS 与信息定理的角色。**定理 8 与推论 11 对任何上一层分布成立，并不依赖 TTNS。TTNS 的作用是：在相关联合结构图具有可控 treewidth、或所需目标只涉及低维 marginal / pair table 时，使局部 channel、marginals、pair tables 与有限网格 entropy 可以通过结构化收缩计算（定理 5）。TTNS 表示本身不保证高维完整联合 PMF 或其 entropy 可高效计算——完整 K 维输出表仍有 G^K 个元素。不应把一个一般的 channel theorem 说成“只有 TTNS 才成立”。相应地，真正依赖 TTNS 的是定理 1、4 与 5。

7. **量化窗口。**有限状态整层界的非平凡性受推论 12 的约束：细化网格会放大 fan-out 熵项目前可得的最坏情形上界，而完全不改善收缩因子。使用该界时必须先固定物理合理的取值范围，再选取量化间距，不能把 $\varepsilon \rightarrow 0$ 当作趋向连续极限。注 36 同时指出，这条张力发生在界的层面，不是关于实际量化熵的断言。

8.4 可以扩张的方向

本文定理可以自然扩张到以下情况，但正式论文中应逐一声明条件。

- 上游不是单棵 TTNS，而是 independent TTNS forest；此时 C_T 替换为 forest 中各棵树收缩的乘积。
- 对精确 CDF 收缩，node-delay 向量 D 可以有联合分布；若要使用信息预算，则需把公共噪声显式作为共享 latent variable 加入右侧预算。
- K 可以是任意有限正整数；完整 joint table 审计中的 $K = 3$ 只是计算限制。
- 平方 TTNS 密度 $p = \psi^2/Z$ 可以通过 doubled network 得到同类收缩公式，但 sensitivity 常数应针对 doubled contraction 重新定义。
- 连续变量的 tree projection 可以写成密度版本，但 KL、微分熵和共享父奇异性更容易产生技术细节；正文建议把 fan-out 累计界和 tree 预算明确写成有限网格版本，把连续 pair 条件互信息界单列。
- 若希望在 uniform delay 下获得非平凡系数，可以研究基于实际 source distribution 的 $\eta_{\text{KL}}(K_a, P_{U_a})$ 或 nonlinear F_I curve；这需要新的证明或可验证有限维优化，不能把全局 δ_a 直接替换成经验数。

8.5 尚待完成的工作

以下几项是本文有意留待后续的，列出以便界定当前稿件的完成度。

- 数值实验。本文只做理论；与实现的一致性核对（注 3、5、推论 5-8）是对现有代码的只读比对，不构成对定理 5 复杂度标度的实测。定理 4 各项常数的实际量级、推论 9 的平方标度、命题 2 与 3 的实测加速比都需要独立实验。§5.5 的树宽表是唯一的例外：它只是小图组合计算，已由确定性审计脚本给出可复算入口，但它核对的是图的树宽，不是实际运行时间。
- 顶点数超过 21 的联合结构图的精确树宽。§5.5 后八行为 min-fill / min-degree 上界；若要把“该拓扑至少这么贵”写成结论，需要接入专门的精确树宽求解器（如 BT/QuickBB 或 PACE 参赛实现），本文未做。
- 引理 6 只用到 [11, Theorem 4] 对一般（非有限）字母表的版本；该文 Appendix A.3 给出一般情形的证明，本文按其陈述使用。若审稿要求，可把本文的有限状态推论（推论 11、12）显式限制到有限字母表以规避该技术条件。
- $\eta_{\text{KL}}(K_a, P_{U_a})$ 的可计算上界。本文只用 $\eta_{\text{KL}}(K_a, P_{U_a}) \leq \delta_a$ ；固定输入系数的更紧估计（如经 η_{χ^2} 与 [9, Theorem 11] 的加权界）尚未纳入。
- §7 的 bib 条目：现有条目已按 §7 开头说明的来源（期刊条目经 Crossref、预印本经 arXiv/DataCite）核对，尚待完成的是投稿时按目标期刊格式重排，以及跟踪各预印本是否已正式出版。
- 英文版本。

8.6 主线的两种组织方式

本文按“精确收缩 → 误差预算 → 复杂度 → 信息预算”的顺序展开，便于逐步引入记号。投稿时若篇幅受限，建议改为如下顺序，把最不依赖附加假设的结果前置：

- (1) TTNS max-plus 精确 CDF 收缩 (定理 1)
- (2) 树宽复杂度判据 (定理 5)
- (3) 闭合单层误差预算 (定理 4)
- (4) 连续 pair 信息预算 (定理 7)
- (5) 有限状态整层与多层界 (定理 8、推论 11) .

理由是 (1)–(4) 都不需要量化，而 (5) 受推论 12 的量化窗口约束；把连续 pair 界置于有限状态界之前，可以让读者先看到不受该约束影响的结论。命题 2、3、1 与局部误差的细节 (定理 3 及其推论) 适合放入附录。Chow–Liu 恒等式全程标为经典结果。

9 符号表

符号	含义
X	上游随机向量。
Y	单层 max-plus 传播后的下游随机向量。
d	上游维数。本文中 d 只表示维数，不再表示 node-delay 取值。
K	单层下游输出维数。
$t = (t_1, \dots, t_K)$	node-delay 向量 D 的一个实现值。
P_a	下游节点 a 的父节点集合。
$\mathcal{P}$	全部父节点的并集 $\bigcup_a P_a$ 。
H_k	受上游节点 k 影响的下游节点集合。
E_{ka}	从上游节点 k 到下游节点 a 的 edge delay。
D_a	下游节点 a 的 node delay。
F_{ka}	edge delay E_{ka} 的 CDF。
$\hat{F}_{ka}$	F_{ka} 的数值近似，取值限定在 $[0, 1]$ (假设 1)。
$b_{k,i}$	上游坐标 k 的第 i 个一维基函数。
A	TTNS core 收缩诱导的完整系数张量。
$\mathcal{C}_T$	TTNS 多线性收缩函数。
$T = (V, E)$	承载 TTNS 的树结构。
$M_{k,i}(y, t)$	max-plus CDF 的第 k 个局部投影向量的第 i 个分量。
S_k	第 k 个局部投影的 TTNS sensitivity 向量。
$\delta_T(k), \deg_T(k)$	树 T 中与节点 k 相邻的边集合及其基数。
$\deg_T^{\max}$	树 T 的最大度数 $\max_k \deg_T(k)$ 。
$U_{k \rightarrow k'}$	environment sweep 中沿树边 $\{k, k'\}$ 的消息 (命题 2)。
$\hat{U}_{c \rightarrow \text{pa}(c)}$	用近似输入 $\hat{z}$ 计算的上行消息 (命题 3)。
$V_{p \rightarrow c}$	hybrid 下行消息：路径祖先取 z 、编号在前的兄弟子树取 $\hat{z}$ 、在后的取 z (命题 3)。
u_{-k}^{hyb}	第 k 个有序 hybrid 环境 $(\hat{z}_1, \dots, \hat{z}_{k-1}, z_{k+1}, \dots, z_d)$ ，标号取 T 的后序遍历。
$I_{k,i} = [\alpha_{k,i}, \beta_{k,i}]$	局部投影积分使用的截断区间。
$h_{k,i}$	局部投影求积步长。
$B_{k,i}^{(2)}$	局部 integrand 二阶导数上界。
$\varepsilon_{k,i,a}^{\text{cdf}}$	edge CDF 插值或近似误差。
$\tau_{k,i}$	截断区间外的基函数绝对质量 (尾部项)。

符号	含义
$\Lambda_{k,i}$	梯形权重下的基函数绝对质量。
$E_k(y, t)$	第 k 个坐标上三类局部误差之和。
$F_M, \hat{F}_M$	加 node delay 之前的中间联合 CDF 及其数值近似 (命题 1)。
$\mathcal{K}_{\mu_a}^{(a)}$	沿第 a 轴与 μ_a 的精确卷积算子; $\mathcal{K}_{\hat{\mu}_a}^{(a)}$ 为把 μ_a 换成离散近似 $\hat{\mu}_a$ 后的版本。
$\mathcal{Y}_a$	第 a 个输出坐标轴上的有限计算网格 $\{y_a^{(1)} < \dots < y_a^{(G)}\}$; h_a^{out} 为其最大间距。
π_a	把第 a 坐标钳制到 $[y_a^{\min}, y_a^{\max}]$ 的点映射 (定义 2)。
Π_a	沿第 a 轴在 $\mathcal{Y}_a$ 上的分段线性插值算子。
$\tilde{\mathcal{K}}_a$	实现所使用的逐轴卷积算子 $\tilde{\mathcal{K}}_a = (\text{离散求积}) \circ \Pi_a \circ \pi_a$ (定义 2); $\tilde{F}_Y = \tilde{\mathcal{K}}_K \circ \dots \circ \tilde{\mathcal{K}}_1 \hat{F}_M$ 为实现实际输出的近似。
$\theta_a^-(G), \theta_a^+(G)$	函数 G 在第 a 轴网格左端以下、右端以上的振幅 (越界钳制的代价, 引理 4)。
$\hat{L}_a$	$\hat{F}_M$ 关于第 a 坐标的 Lipschitz 常数。
$\varrho_a(n_D)$	W_1 距离 $W_1(\mu_a, \hat{\mu}_a)$ 本身, n_D 为该轴求积点数 (其速率上界见式 (6))。
ε^{loc}	局部投影误差经 sensitivity 加权后的贡献。
ε^{nq}	node-delay 外层求积误差 $\sum_a \hat{L}_a \varrho_a(n_D)$ 。
$\varepsilon^{\text{grid}}$	逐轴卷积内部使用有限网格分段线性插值产生的误差。
$\varepsilon^{\text{bdry}}$	把网格外求值钳制到首尾网格点产生的误差 $\sum_a [\theta_a^- + \theta_a^+]$ 。
ε^{itp}	从计算网格插值到其他求值点的最终插值误差 (定理 4 的可选附加项)。
K_a	下游节点 a 的局部 max-plus Markov kernel。
$K^{\otimes}$	整层乘积信道 $\prod_a K_a$ 。
$\mathcal{K}_\ell$	第 ℓ 层传播诱导的 Markov kernel。
δ_a	局部 channel K_a 的 Dobrushin coefficient $\eta_{\text{TV}}(K_a)$ 。
$\eta_{\text{KL}}(K_a)$	局部 channel 的 input-independent KL contraction coefficient; $\eta_{\text{KL}}(K_a) \leq \delta_a$ 。
$\eta_{\text{KL}}(K_a, Q)$	局部 channel 在固定输入参考分布 Q 下的 source-dependent KL contraction coefficient (定义 5); $\eta_{\text{KL}}(K_a, Q) \leq \eta_{\text{KL}}(K_a)$ 。
$\eta_{\text{KL}}(K^{\otimes})$	整层乘积信道的 input-independent KL contraction coefficient。本文不使用它, 且它一般不等于 $\max_a \eta_{\text{KL}}(K_a)$ (注 30)。
η^*	整层 KL 收缩因子 $\max_a \eta_{\text{KL}}(K_a, P_{U_a})$ (定理 8)。
δ^*	整层 Dobrushin 上界 $\max_a \delta_a$, 满足 $\eta^* \leq \delta^*$ 。
$\mathcal{U}_a$	节点 a 允许的父状态集合 (假设 3)。
Δ_a	允许父状态集合 $\mathcal{U}_a$ 的 ℓ_∞ 直径。
$\omega_{D_a}(t)$	node delay 分布在平移距离不超过 t 时的最大 TV。
A_{ab}, B_{ab}, C_{ab}	节点 a, b 的独占父变量和共享父变量。
ϕ_i	上一层父节点 i 被多少个下游节点读取, 即 fan-out。
Γ	整层 product channel 的 Dobrushin 上界 $1 - \prod_a (1 - \delta_a)$ 。
B_ℓ	第 ℓ 层的 fan-out entropy 注入上界。
T_ℓ	第 ℓ 层输出的 total correlation。
L	层数 (推论 11)。本文中 L 只表示层数; $L_a, \hat{L}_a$ 是带下标的 Lipschitz 常数。
R_q, ε	量化半径与量化间距: 网格 $\mathcal{Y}^q \subset [-R_q, R_q]$ (式 (19)), 格点数 $N = \lfloor 2R_q/\varepsilon \rfloor + 1$ (式 (20))。
$q_{R_q, \varepsilon}$	带饱和的上取整逐坐标量化器 $\mathbb{R} \rightarrow \mathcal{Y}^q$ (式 (21)), 取值 cell 为左开右闭区间 (式 (22)), 与式 (32) 的混合有限差分逐点相容。

符号	含义
$Q_{R_q, \varepsilon}$	$q_{R_q, \varepsilon}$ 诱导的确定性 Markov kernel $Q_{R_q, \varepsilon}(u, \cdot) = \delta_{q_{R_q, \varepsilon}(u)}$ 。不写作 Q ，以免与层分布 Q_ℓ 、分位数函数、 $\eta_{\text{KL}}(K_a, Q)$ 中的参考分布及 $Q \in \mathcal{T}(T_Y)$ 冲突。
K_a^q	量化 channel $K_a Q_{R_q, \varepsilon}$ (式 (24))，满足 $\eta_{\text{TV}}(K_a^q) \leq \eta_{\text{TV}}(K_a)$ (式 (25))。
q, G	上游一维求积点数与每个输出坐标轴上的网格点数。
$\tilde{G}^{(k)}$	投影 core (定义 3)。
ξ_k, α_e, ν_a	离散化 sum-product 中的上游求积指标、bond 指标与输出网格指标。
$\mathcal{G}_S$	关于输出子集 S 的联合结构图 (定义 4)； $\mathcal{G}_S^+$ 为额外把 $\{\nu_a\}_{a \in S}$ 补成团后所得的图。
$\text{tw}(\cdot)$	图的树宽。
r, m	最大 bond dimension $r = \max_{e \in E} r_e$ ($E = \emptyset$ 时约定 $r = 1$ ，见式 (4)) 与最大物理维 $m = \max_k m_k$ 。
W	最大变量域大小 $\max\{q, r, m, G\}$ (式 (10))；平方 TTNS 情形记 $W_2 = \max\{q, r^2, m^2, G\}$ (推论 9)。
W	(16) 中 SDPI 变分刻画所用的辅助随机变量 (与 W 无关)。
$\Delta_T^{\max}$	树 T 的最大度数，等于 $\deg_T^{\max}$ 。
R	量化后输出向量的精确 PMF $R(y) = \mathbb{P}[q_{R_q, \varepsilon}(Y) = y]$ (式 (31))，等价地由真实 F_Y 差分的式 (32))，不是 CDF 数值表。
$\hat{R}$	由数值 CDF 表 $\hat{F}_Y$ 差分得到的数值混合差分数组 (式 (33))，即一个 PMF candidate：尾部约定下其总和自动为 1，但未必非负，故只有通过非负性检验后才可称为 PMF；一般 $\hat{R} \neq R$ ，适用边界见注 37。
T_Y	下游输出坐标上的 tree projection 树，与上游 TTNS 树 T 不同。
$\mathcal{T}(T_Y)$	按树 T_Y 分解的分布族，用有根条件分解定义 (式 (34))，含零概率状态时仍良定义)。
R^{T_Y}	R 到 tree family $\mathcal{T}(T_Y)$ 的 KL projection。
D_{KL}	Kullback-Leibler divergence。
TV	total variation distance。
TC	total correlation。

References

- [1] E. Ando. The distribution function of the longest path length in constant treewidth DAGs with random edge length. arXiv preprint arXiv:1910.09791, 2019 (rev. 2022). [arXiv:1910.09791](#).
- [2] E. Ando. The complexity of computing path length distributions with edges i.i.d. random via local uniformity. arXiv preprint arXiv:2607.10195, 2026. [arXiv:2607.10195](#).
- [3] F. Baccelli, G. Cohen, G. J. Olsder, and J.-P. Quadrat. *Synchronization and Linearity: An Algebra for Discrete Event Systems*. Wiley, Chichester, 1992. 作者提供的在线版本见 [book-online](#)。
- [4] D. Blaauw, K. Chopra, A. Srivastava, and L. Scheffer. Statistical timing analysis: From basic principles to state of the art. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 27(4):589–607, 2008. DOI: [10.1109/TCAD.2007.907047](#).

- [5] C. E. Clark. The greatest of a finite set of random variables. *Operations Research*, 9(2):145–162, 1961. DOI: [10.1287/opre.9.2.145](https://doi.org/10.1287/opre.9.2.145).
- [6] C. K. Chow and C. N. Liu. Approximating discrete probability distributions with dependence trees. *IEEE Transactions on Information Theory*, 14(3):462–467, 1968. DOI: [10.1109/TIT.1968.1054142](https://doi.org/10.1109/TIT.1968.1054142).
- [7] J. E. Cohen, Y. Iwasa, Gh. Rautu, M. B. Ruskai, E. Seneta, and Gh. Zbaganu. Relative entropy under mappings by stochastic matrices. *Linear Algebra and its Applications*, 179:211–235, 1993. DOI: [10.1016/0024-3795\(93\)90331-H](https://doi.org/10.1016/0024-3795(93)90331-H).
- [8] I. Csiszár and J. Körner. *Information Theory: Coding Theorems for Discrete Memoryless Systems*. Academic Press, New York, 1981.
- [9] A. Makur and L. Zheng. Bounds between contraction coefficients. In *53rd Annual Allerton Conference on Communication, Control, and Computing*, pages 1422–1429, 2015. DOI: [10.1109/ALLERTON.2015.7447178](https://doi.org/10.1109/ALLERTON.2015.7447178).
- [10] Y. Polyanskiy and Y. Wu. Dissipation of information in channels with input constraints. *IEEE Transactions on Information Theory*, 62(1):35–55, 2016. DOI: [10.1109/TIT.2015.2482978](https://doi.org/10.1109/TIT.2015.2482978).
- [11] Y. Polyanskiy and Y. Wu. Strong data-processing inequalities for channels and Bayesian networks. In *Convexity and Concentration*, pages 211–249. Springer, 2017. DOI: [10.1007/978-1-4939-7005-6_7](https://doi.org/10.1007/978-1-4939-7005-6_7).
- [12] F. P. Calmon, Y. Polyanskiy, and Y. Wu. Strong data processing inequalities for input constrained additive noise channels. *IEEE Transactions on Information Theory*, 64(3):1879–1892, 2018. DOI: [10.1109/TIT.2017.2782359](https://doi.org/10.1109/TIT.2017.2782359).
- [13] D. Dmitriev, Z. Huang, and Y. Wei. Efficient sampling with discrete diffusion models: sharp and adaptive guarantees. To appear in *Proceedings of the Conference on Learning Theory (COLT)*, 2026. [arXiv:2602.15008](https://arxiv.org/abs/2602.15008).
- [14] S. Dolgov, K. Anaya-Izquierdo, C. Fox, and R. Scheichl. Approximation and sampling of multivariate probability distributions in the tensor train decomposition. *Statistics and Computing*, 30(3):603–625, 2020. DOI: [10.1007/s11222-019-09910-z](https://doi.org/10.1007/s11222-019-09910-z).
- [15] W. S. Evans and L. J. Schulman. Signal propagation and noisy circuits. *IEEE Transactions on Information Theory*, 45(7):2367–2373, 1999. DOI: [10.1109/18.796377](https://doi.org/10.1109/18.796377).
- [16] J. N. Hagstrom. Computational complexity of PERT problems. *Networks*, 18(2):139–147, 1988. DOI: [10.1002/net.3230180206](https://doi.org/10.1002/net.3230180206).
- [17] D. Mishaghi, E. Koskin, and E. Blokhina. Gate-level statistical timing analysis: Exact solutions, approximations and algorithms. *arXiv preprint arXiv:2401.03588*, 2024. [arXiv:2401.03588](https://arxiv.org/abs/2401.03588).
- [18] G. S. Novikov, M. E. Panov, and I. V. Oseledets. Tensor-train density estimation. In *Proceedings of UAI 2021*, PMLR 161:1321–1331, 2021. [Proceedings page](#).
- [19] I. V. Oseledets. Tensor-train decomposition. *SIAM Journal on Scientific Computing*, 33(5):2295–2317, 2011. DOI: [10.1137/090752286](https://doi.org/10.1137/090752286).
- [20] R. Peng, J. Gray, and G. K.-L. Chan. Arithmetic circuit tensor networks, multivariable function representation, and high-dimensional integration. *Physical Review Research*, 5(1):013156, 2023. doi:[10.1103/PhysRevResearch.5.013156](https://doi.org/10.1103/PhysRevResearch.5.013156); 预印本 [arXiv:2209.07410](https://arxiv.org/abs/2209.07410).

- [21] M. Raginsky. Strong data processing inequalities and Φ -Sobolev inequalities for discrete channels. *IEEE Transactions on Information Theory*, 62(6):3355–3389, 2016. DOI: [10.1109/TIT.2016.2549542](https://doi.org/10.1109/TIT.2016.2549542).
- [22] M. Roa-Villescas, X. Gao, S. Stuijk, H. Corporaal, and J.-G. Liu. Probabilistic inference in the era of tensor networks and differential programming. *Physical Review Research*, 6(3):033261, 2024. doi:[10.1103/PhysRevResearch.6.033261](https://doi.org/10.1103/PhysRevResearch.6.033261); 预印本 [arXiv:2405.14060](https://arxiv.org/abs/2405.14060).
- [23] E. Robeva and A. Seigal. Duality of graphical models and tensor networks. *Information and Inference: A Journal of the IMA*, 8(2):273–288, 2019. DOI: [10.1093/imaiai/iaay009](https://doi.org/10.1093/imaiai/iaay009).
- [24] S. Watanabe. Information theoretical analysis of multivariate correlation. *IBM Journal of Research and Development*, 4(1):66–82, 1960. DOI: [10.1147/rd.41.0066](https://doi.org/10.1147/rd.41.0066).
- [25] H. S. Witsenhausen. On sequences of pairs of dependent random variables. *SIAM Journal on Applied Mathematics*, 28(1):100–113, 1975. DOI: [10.1137/0128010](https://doi.org/10.1137/0128010).
- [26] W. Yuan, S. Jeong, and A. Aghazadeh. On the error-correcting effects of stochasticity in discrete diffusion. arXiv preprint [arXiv:2605.26582](https://arxiv.org/abs/2605.26582), 2026. [arXiv:2605.26582](https://arxiv.org/abs/2605.26582).